# HgFinance

## 전략을 스스로 성장시키는 투자 자동화 프로젝트

Hermes 기반 개인화 헤지펀드 멀티 에이전트

https://github.com/HgFinance/multi_agent

# Agenda 목차

| 01

## 프로젝트 개요

문제 정의 및 필요성
솔루션 비교
차별화 요소

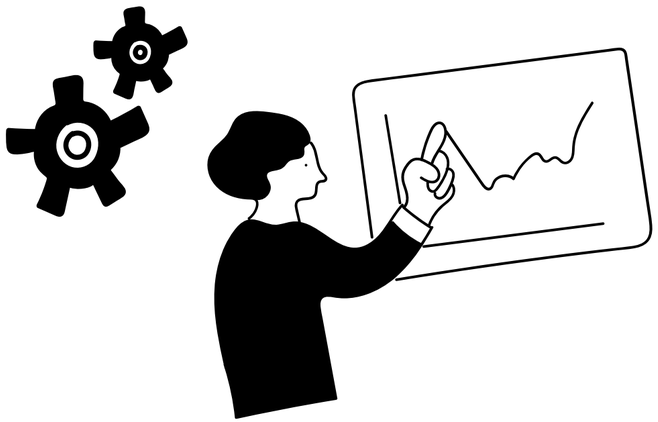

| 02

## 프로젝트 내용

프로젝트 팀 구성
프로젝트 일정
시스템 Overview
핵심 기능
멀티 에이전트 아키텍처
부서별 산출물
시연 영상

| 03

## 프로젝트 고도화

시스템 구성도
MLOps
LLMOps
Memo Harness
CEO Hermes

| 04

## 인사이트

자체 평가
향후 개선방안

| 05

## 부록

# 프로젝트 개요

## <HTS 조건검색식>

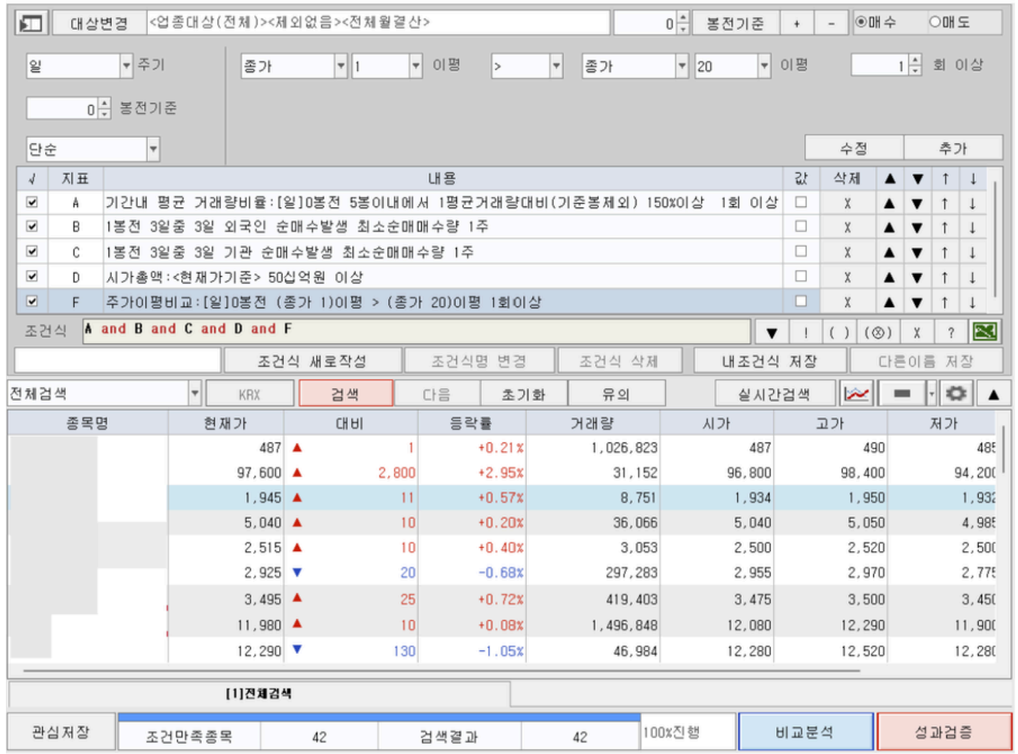


| 항목 | 조건 |
|---|---|
| ① 거래량 | 오늘 거래량 > 5일 평균 거래량의 150% |
| ② 외국인 순매수 | 최근 3일 외국인 순매수 지속 |
| ③ 기관 순매수 | 최근 3일 기관 순매수 지속 |
| ④ 이평선 돌파 | 종가 > 20일 이동평균선 |
| ⑤ 시가총액 | 500억 이상 (너무 작으면 세력 매매 추적 어려움) |

## <조건감시 주문>

자연어 질의

**"10% 오르면 팔아줘"**

# 문제 정의 및 필요성

사용자 페르소나별 Needs

**주식 초보** "일 끝나고 주식창 보니 수익이 손실로 바뀌어..."

- 관심 종목의 적절한 **매매 시점**을 판단하기 어려움
- **차트와 기술적 지표**를 이해하고 활용하지 못함
- 직장·일상과 병행하며 **장중 시장을 계속 확인하기 어려움**

+

**트레이더** "차트 보느라 밥 먹을 타이밍도 놓친다"

- 원하는 매매 시점과 조건이 명확해도 **HTS 조건식**으로 일일이 설정하기 **번거로움**
- 여러 종목의 차트를 **동시에 모니터링** 필요
- 매매 시점을 놓치지 않기 위한 **상시 모니터링 부담**

사람의 시간은 제한되어 있지만, 시장은 기다려주지 않는다.
내가 안 보면, 매매 타이밍을 놓친다.

↓

**모든 종목을 추적하고 스스로 개선하는 투자비서가 있다면?**

- 사용자의 투자 의도에 맞춰 **전종목을 실시간 추적**하고 관리
- AI 에이전트가 협업하며 **자동으로 성장하는** 개인화 투자 조직

# 솔루션 비교

자연어 기반 투자 실행 기능 비교

| 비교 항목 | TradingAgents | AI Hedge Fund | FinRobot | HgFinance |
|---|---|---|---|---|
| **목표** | 토론형 투자 의사결정 | 가상 헤지펀드 운용<br>포트폴리오 실행 | 금융 분석·리서치<br>자동화 | 자연어 조건주문 기반<br>투자 운영 |
| 자연어 활용<br>**대화형 매매** | X<br>(분석가 토론만) | X<br>(신호 생성만) | X<br>(분석·백테스트 질의) | O<br>(전략 문장 → 해석하여 주문) |
| **기술적 분석 조건주문** | X | X | X | O |
| **조건 감시·자동 실행** | △ | △ | △ | O |
| **자가 개선 루프** | X | X | X | O |

TradingAgent: Xiao, Y., Sun, E., Luo, D., & Wang, W. (2025). TradingAgents: Multi-Agents LLM Financial Trading Framework. arXiv:2412.20138 — https://arxiv.org/abs/2412.20138

# 차별화 요소

- **기존 트레이딩 에이전트** : 보유한 내부 종목에 대한 실시간 판단만 가능

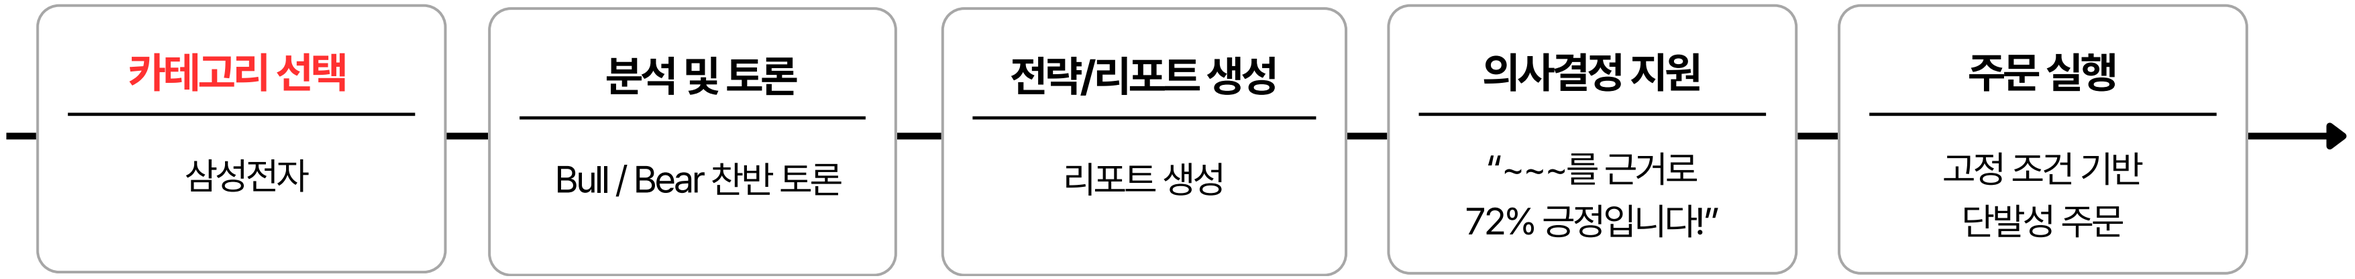


- **HgFinance** : 기존 트레이딩 에이전트를 종속 | 자연어 조건주문을 통한 추적 편의성 | 로그를 통한 퀀트 전략 개선 자동화

# 프로젝트 내용

# 프로젝트 팀 구성

역할 분담

## 조재일

헤지펀드 마스터플랜 설계
부서별 권한 분리 원칙 수립
데이터 수집 파이프라인 구축
시계열 데이터베이스 최적화
전략 발굴·백테스트 자동화
자동 주문 파이프라인 구축

리서치 본부
퀀트/백테스팅 본부

## 김동규

멀티에이전트 오케스트레이션 설계
MLOps/LLMOps 최적화
모델 양자화 성능 비교
에이전트 출력 신뢰성 강화
리스크 검증·QA 감사
LLM 파인튜닝

리스크 본부
QA/감사 본부

## 류영주

CEO 라우팅·조직 운영
에이전트 개선 워크플로우 구축
사용자 입력 생명주기 설계
백엔드 BFF 개발
데이터베이스 관리
부하·비용 모니터링 및 최적화

CEO Office
HR 본부

## 윤도현

주문 실행·OMS·브로커 연동
모의계좌·포트폴리오 관리
프론트엔드 개발
사용자 페르소나 테스트
GPU 모니터링 및 최적화
파인튜닝 데이터셋 구축

트레이딩 본부
회계/포트폴리오 본부

# 프로젝트 일정

파이프라인 설계 및 고도화 5주 마일스톤

## 1주차 (7/27~7/31)

### 서비스 기획

- PoC
- 문제 정의, 시장 조사
- 개발 로드맵 마스터플랜 수립

## 2주차 (8/3~8/7)

### 데이터 수집 아키텍처 설계

- 데이터 수집 파이프라인 구축
- 시스템 아키텍처 설계
- 에이전트 고도화 방안 탐색
- LLM 모델 선정
- 클라우드 인스턴스 사양 결정

## 3주차 (8/10~8/14)

### 모델링 및 서비스 구축

- AWS 프로덕션 환경 통합
- 헤르메스 에이전트 연결
- FE, BE 설계 및 구현

## 4주차 (8/18~8/23)

### 프로젝트 고도화

- FE, BE 구현 및 개선
- 부서별 직원 구조 개편
- LLM 고도화 성능 측정 실험
- 모니터링 및 최적화

## 5주차 (8/24~8/28)

### 테스트 및 QA 프로젝트 마무리

- 장 중 테스트
- 조건 주문 파이프라인 실행
- 발표 준비, 시연영상 촬영

# 시스템 Overview

자연어 기반 업무 분기 체계와 주요 Use Case

★ 사용자는 시스템 구조를 알 필요 없이, 자연어 하나로 조회 → 분석 → 실행까지 요청할 수 있다.

# 핵심 기능 **자연어 조건 주문** 시나리오 예시

### ① 사용자 쿼리

**"에브리봇 120분봉 엔빌로프(20, 25) 상단에서 매도해줘."**

=우리가 정해둔 고점까지 오르면 알아서 팔아줘.

### ② 자연어 이해(NLP)

- **주체** : 에브리봇
- **지표** : 엔빌로프(20,25) 상단
- **액션** : 매도
- **조건** : 가격이 상단 돌파 시
- **시간축** : 120분봉

### ③ 조건 구조화 (AST)


{ "symbol" : "EVERYBOT",
"indicator": "envelope",
"period": 20, "rate": 0.25,
"target": "UPPER",
"action" : "SELL",
"condition": "CROSS_ABOVE" }


### ④ 조건 엔진 등록 & 실시간 감시

**조건 상세**

| | |
|---|---|
| **종목명** | 에브리봇(EVERYBOT) |
| **시간봉** | 120분봉 |
| **지표** | 엔빌로프 (20, 25%) 상단 |
| **조건** | 종가가 엔빌로프 상단을 상향 돌파 시 |
| **액션** | 매도 |
| **감시주기** | 1분 |
| **상태** | 감시중 |

**현재 조건 요약**

- 엔빌로프(20, 25) 상단선 : 청록색 선
- 종가(현재가) : 빨간색 캔들
- 상향 돌파 감지 시 : 자동 매도 주문 실행

# 핵심 기능 자연어 조건 주문 시나리오 예시

# Multi-agent Architecture 에이전트 조직 부서별 역할

## HgFinance 조직 분류

### 1. CEO
- 부서별 실행 과제 분기
- 각 부서의 결과 종합 리포트 발행
- 최종 판단 제공

### 2. 리서치 본부
- 종목·시황에 대한 정확한 분석 답변
- 분석 완료 여부와 신뢰 가능한 결론 제공

### 3. 퀀트·백테스트 본부
- 퀀트 트레이딩 전략 배포 및 운용
- 백테스트 기반의 기대 성과 지표 제공

### 5. 리스크 관리 본부
- 사용자 Mandate 분석 후 성향에 따른 Risk 한도 설정
- 법률 문서 LLM-Wiki

### 4. 트레이딩 본부
- PAPER(모의) 매매 실행
- 주문의 접수·체결·정정·취소·거부 상태 조회

### 6. 회계·포트폴리오 본부
- 거래 원장 조회
- 자산·실현손익·평가손익·수수료 등 회계정보 정리

### 7. AI QA/감사 본부
- 에이전트, llm의 호출 성공, 지연, 토큰량 측정
- Discord 채팅창 피드백

### 8. HR 인사 본부
- 등록 Agent의 상태 관리
- Agent 자기 개선 후보 제안 (채용·배치·인력 계획)

# Multi-agent Architecture Hermes Agent + Worker&Runner

- 모든 에이전트는 LangGraph로 연결되어 협업 및 정보 공유
- 각 본부 Agent 부서장이 LLM Worker 와 결정론 함수 Runner를 관리·조율

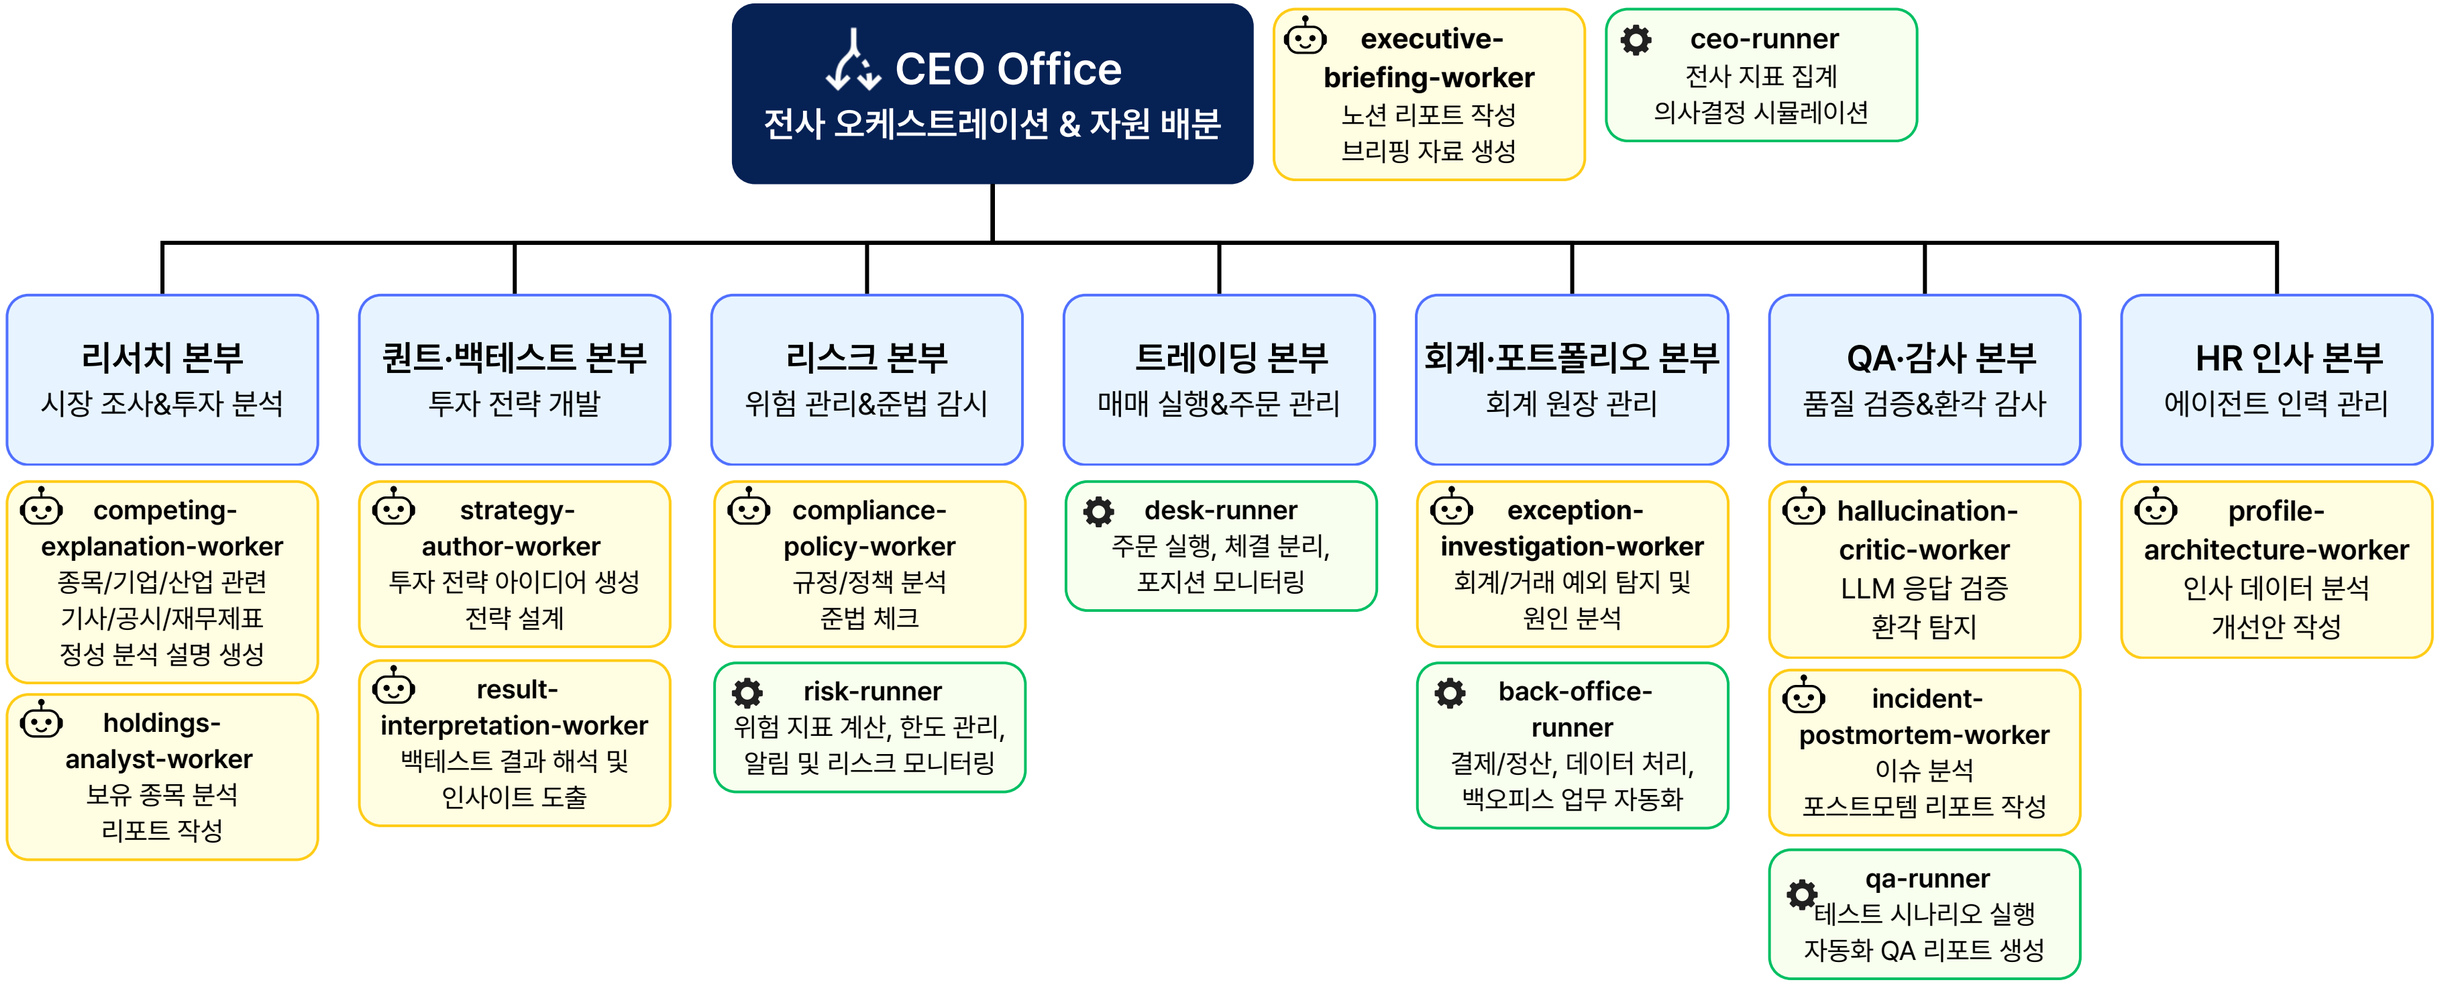

# Multi-agent Architecture

전체 실행 파이프라인

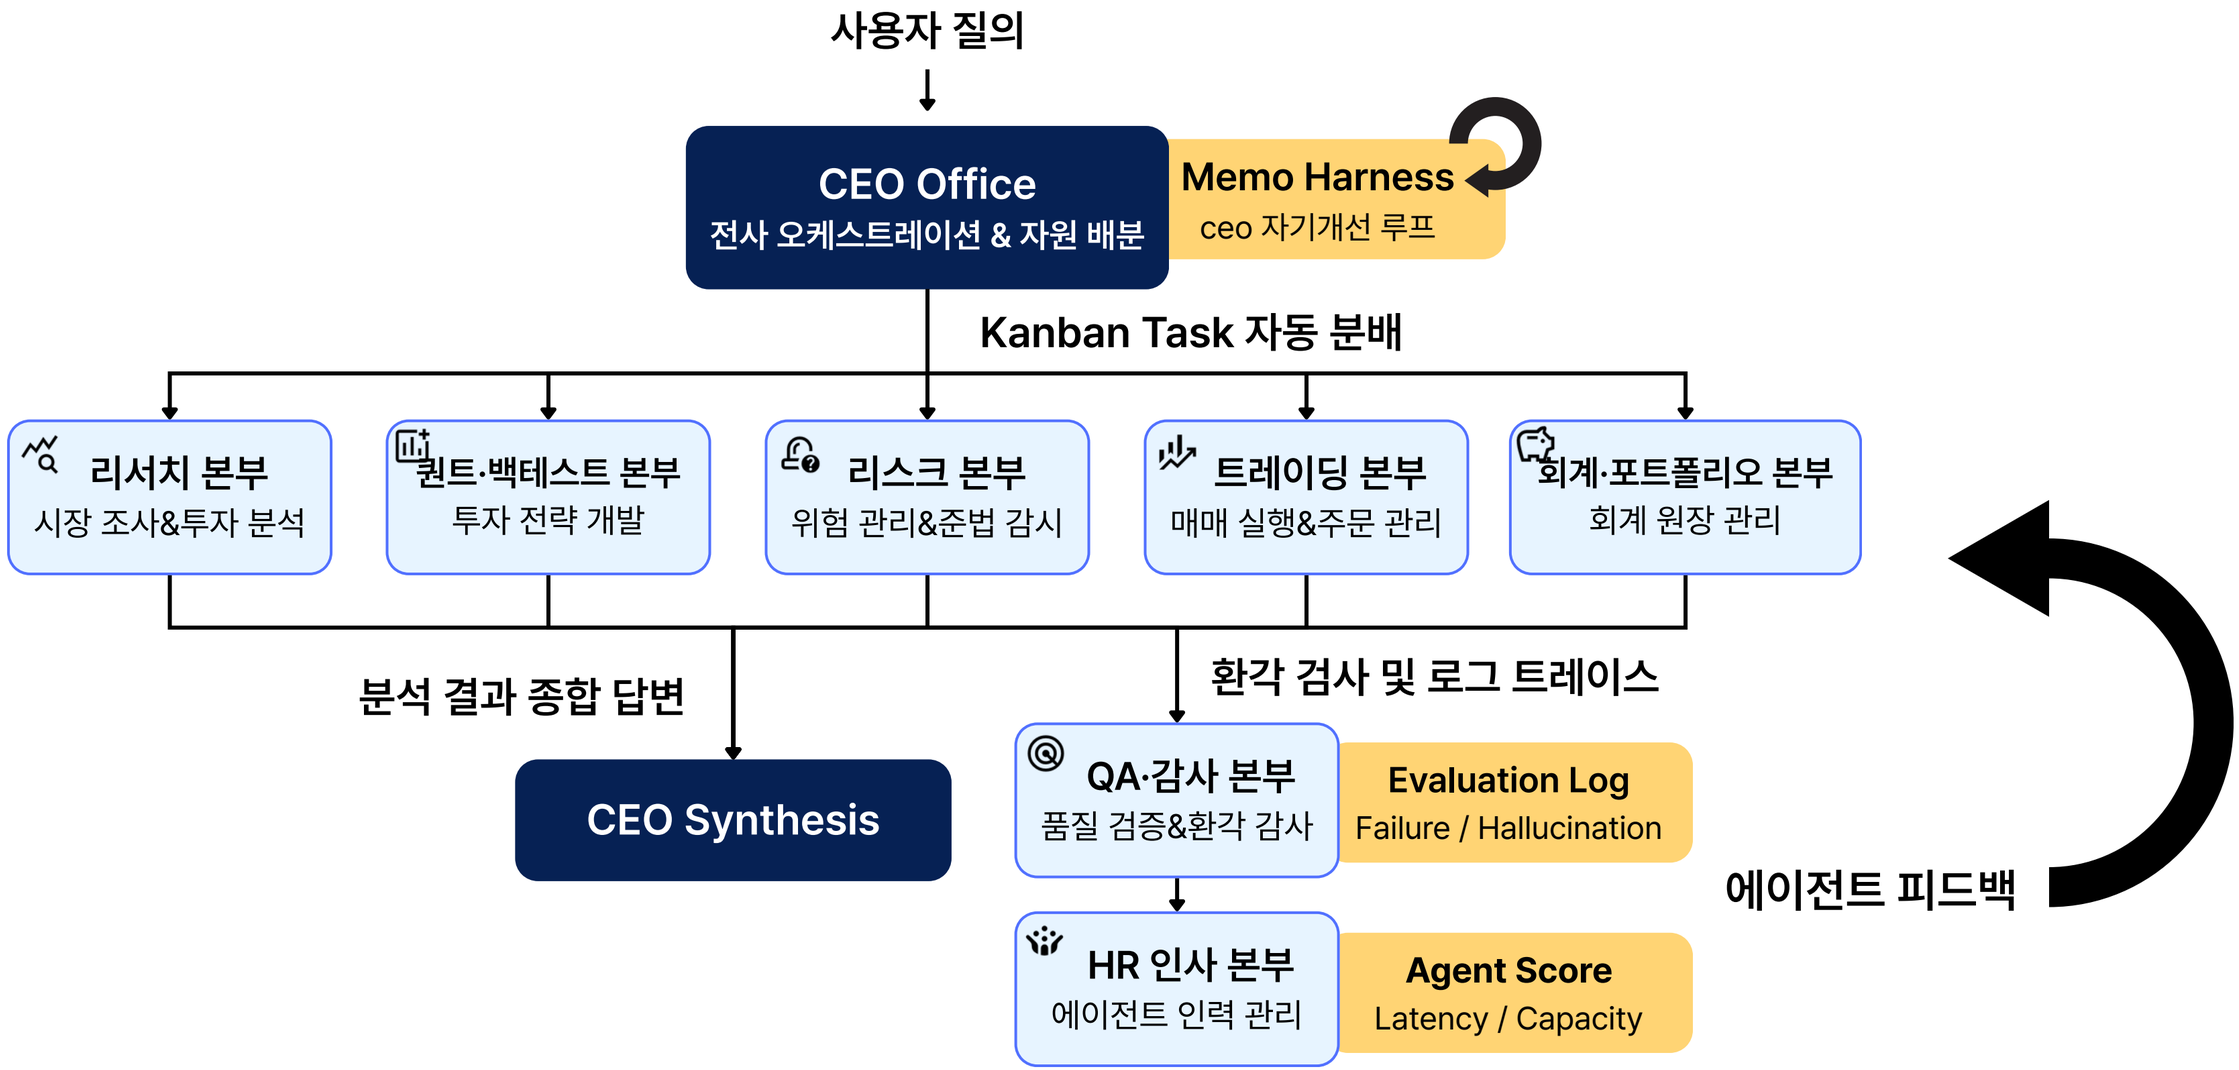

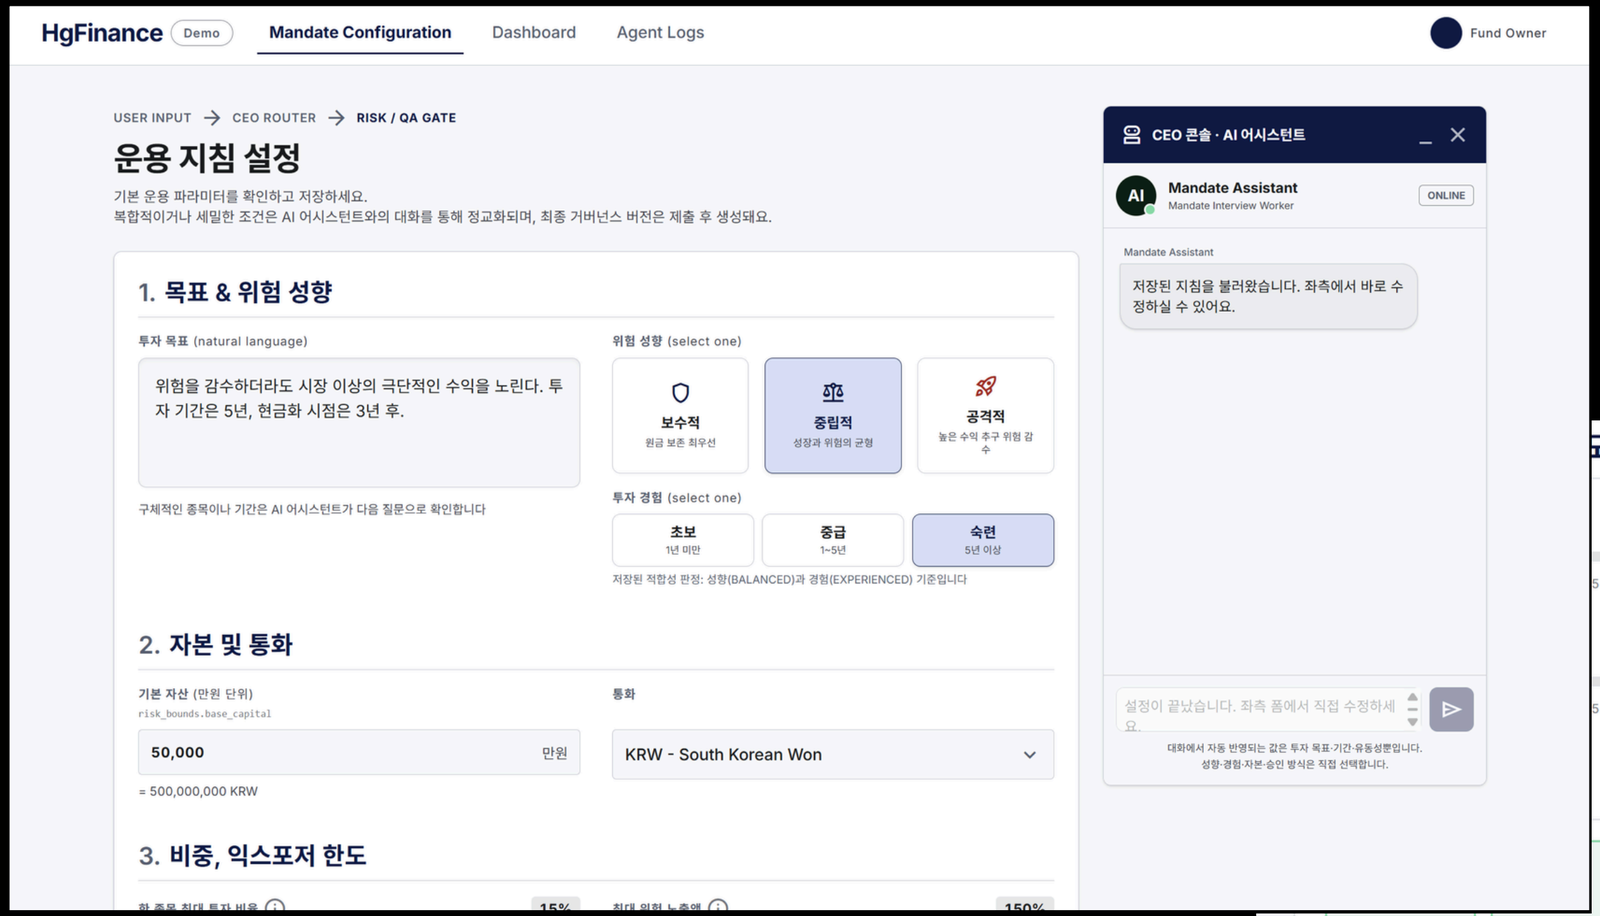


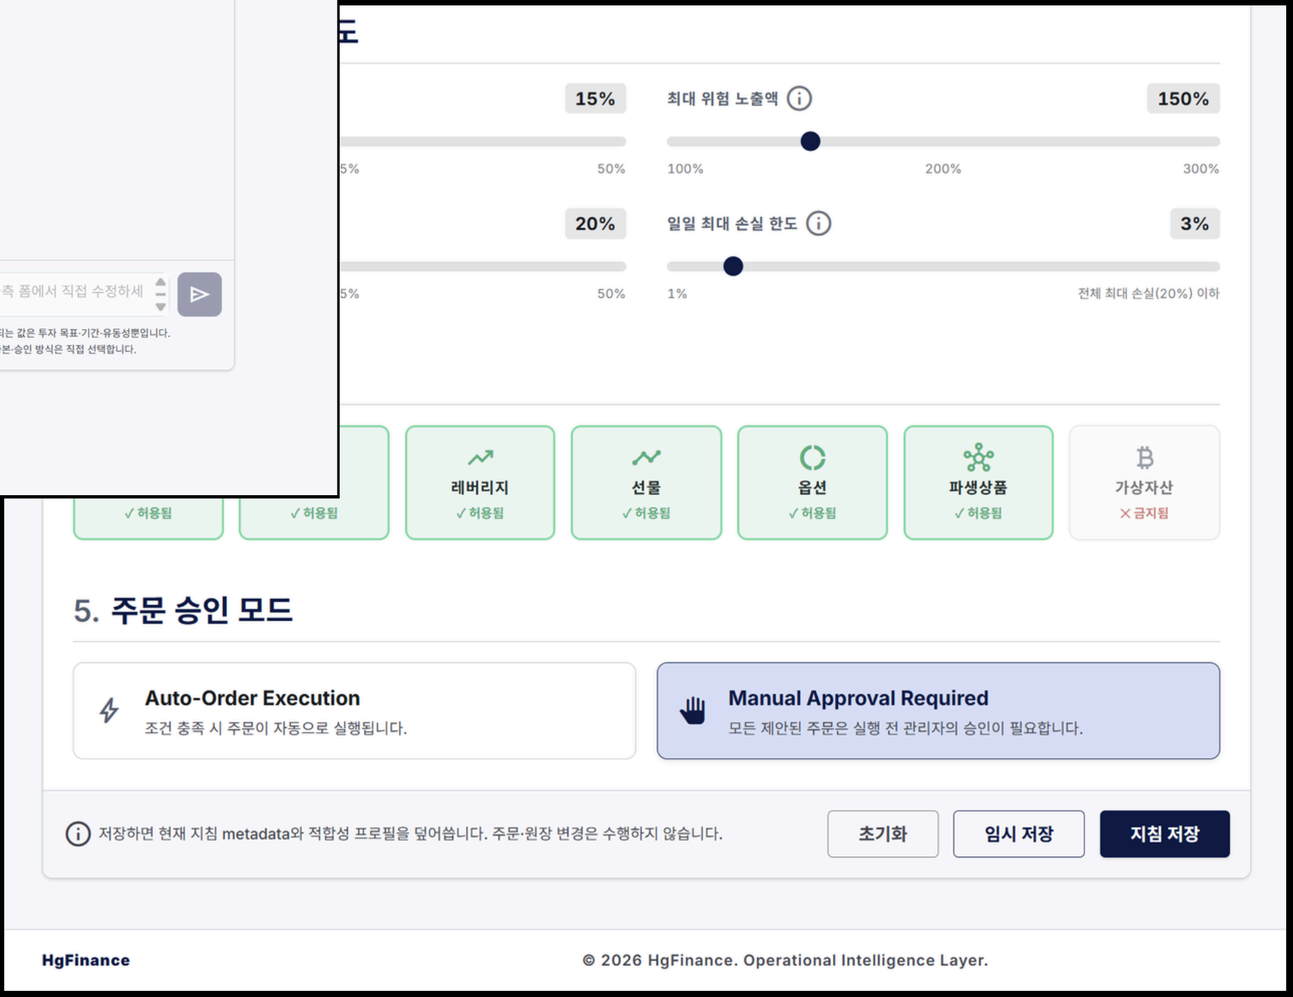


# 사용자 투자 지침(Mandate) 설정

- 투자 성향 (보수적/중립적/공격적)
- 원금 및 손실 한도
- 투자할 금융상품 선택

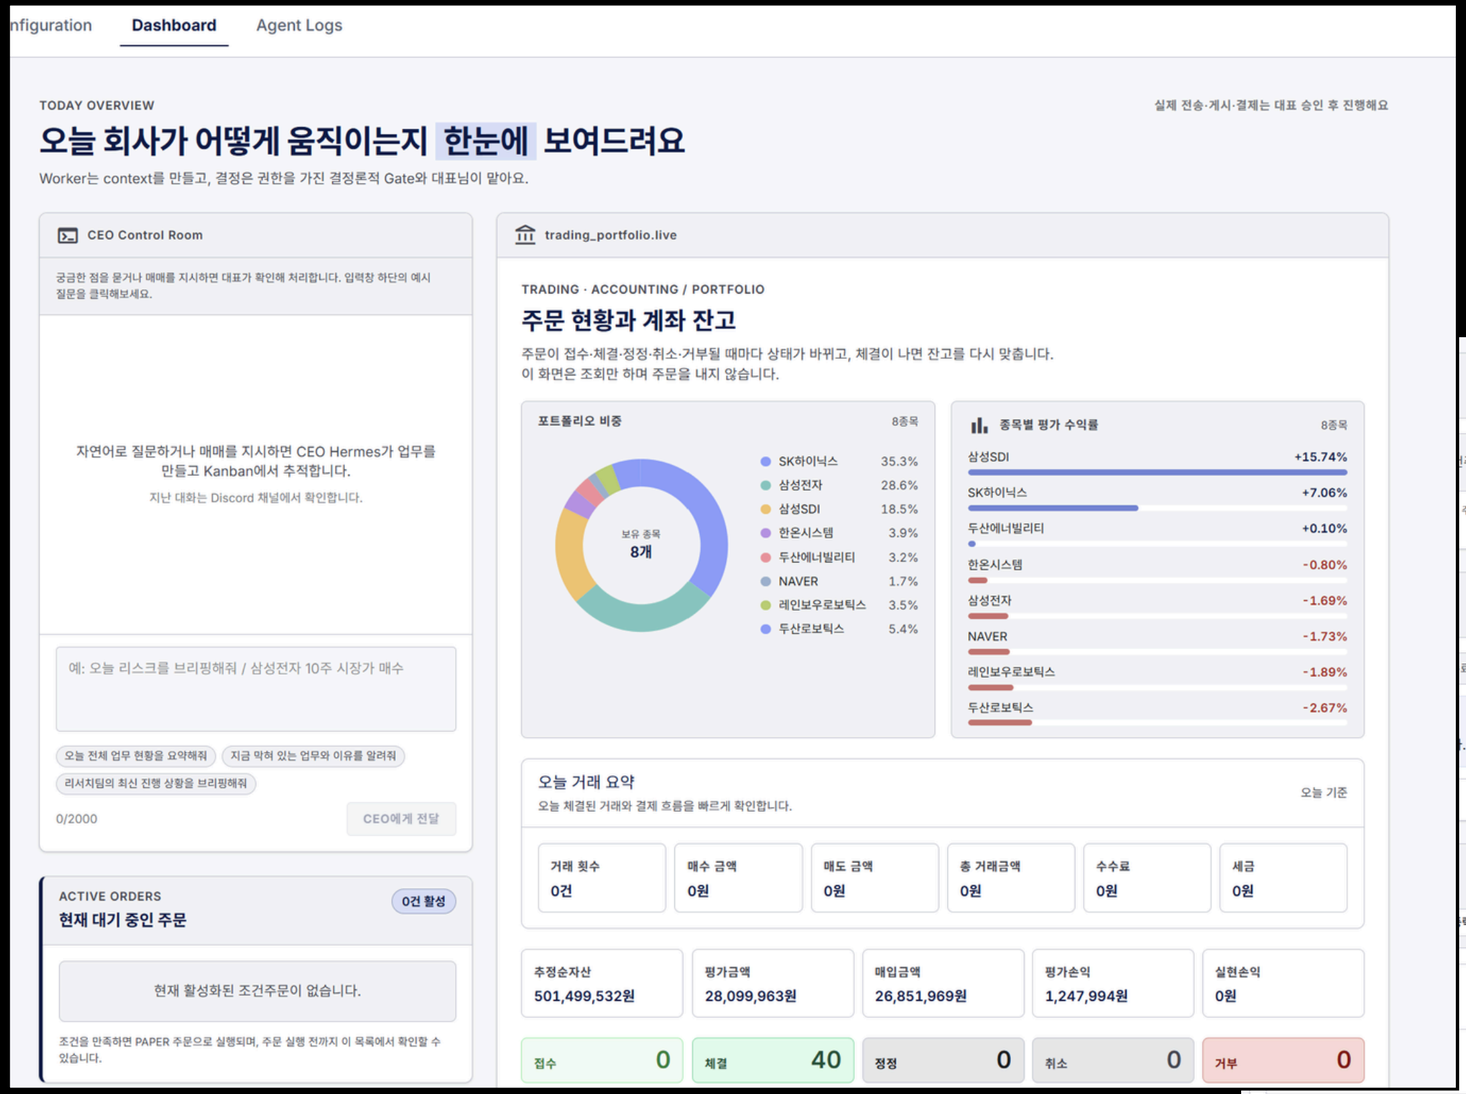


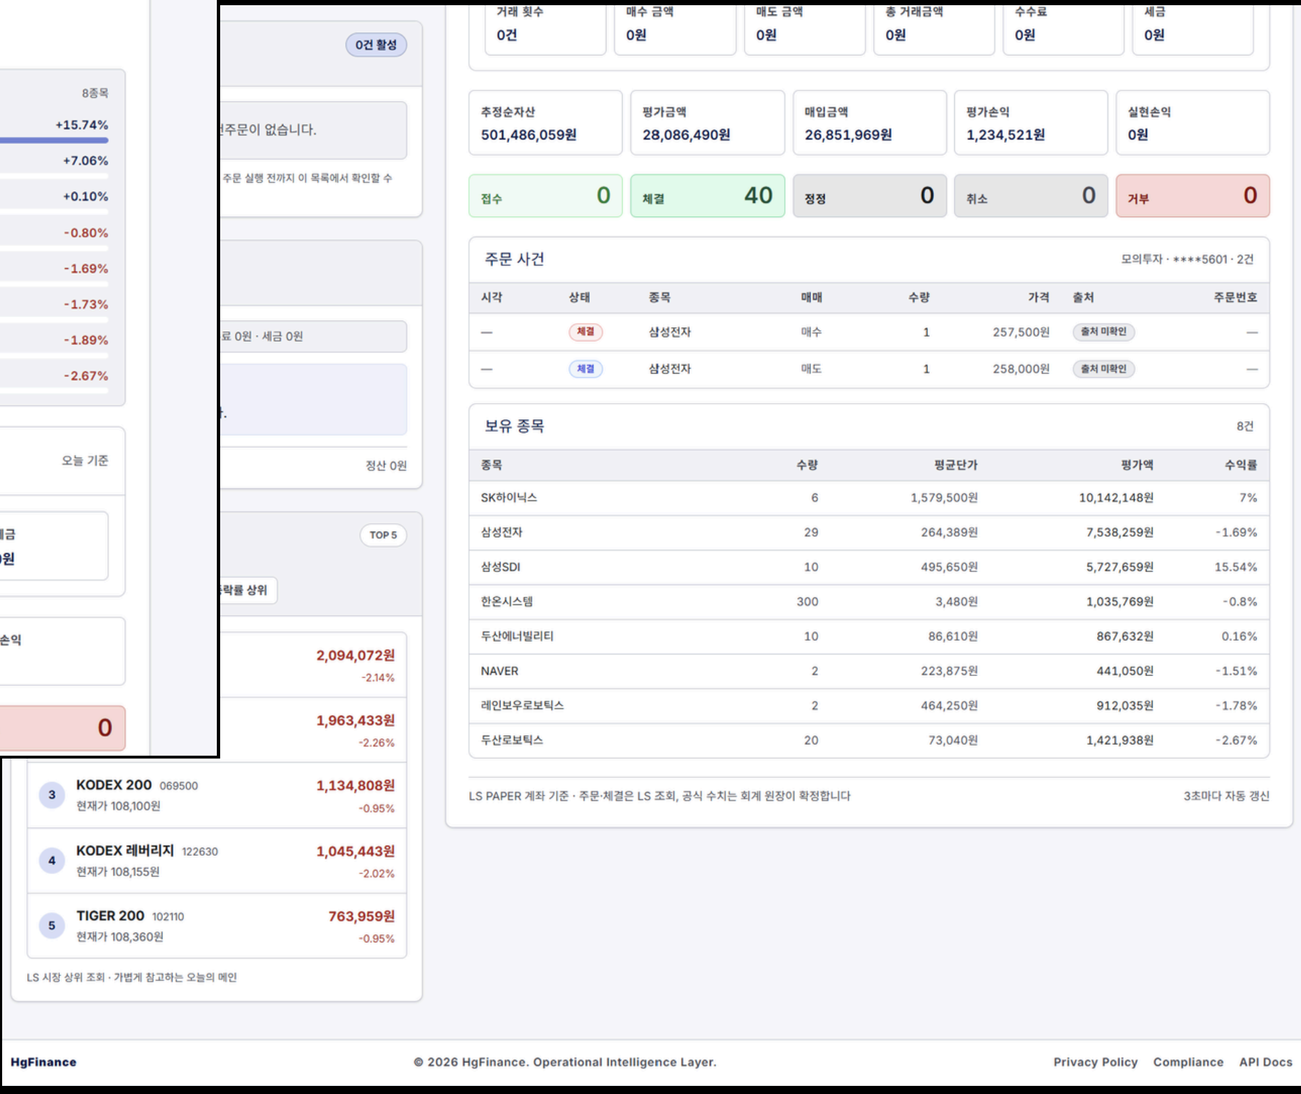


# 투자 대시보드

- 주문 현황, 계좌 잔고 등 다양한 정보 확인

AGENT ACTIVITY · 8 DEPARTMENTS

RUNTIME CONNECTED | BFF POLLING CONNECTED

# 부서별 에이전트의 움직임을 실시간으로 확인하세요

BFF snapshot과 수신된 runtime event를 기준으로 각 부서의 상태와 에이전트의 최근 작업 로그를 표시합니다.

## Hermes Agent Kanban

보드 새 창으로 열기

원본 Kanban 상태는 카드의 Hermes 배지에서 확인할 수 있습니다.

UPDATED 08. 28. 오후 12:15

### TODO 7

아직 시작하지 않은 작업

HERMES · TODO
**CEO delegated accounting analysis**
Accounting / Portfolio · 08. 27. 오후 11:56
t_91033f05

HERMES · TODO
**CEO delegated risk analysis**
Risk · 08. 27. 오후 11:56
t_0f5b7559

HERMES · TODO
**CEO delegated trading analysis**
Trading · 08. 27. 오후 11:56
t_1c433b89

HERMES · TODO

### READY 8

실행을 기다리는 작업

HERMES · READY
**Strategy Hermes 추적: 시가총액 상위 10개 종목의 5일선·20일선 골든크로스 전략을 만들고 백테스트해줘. 결과 근거 없으면 HOLD해.**
CEO Office · 08. 28. 오전 09:55
t_f575b1a3

HERMES · READY
**Strategy Hermes 추적: <@1536991290842030130> 시가총액 상위 10위까지 종목 티커 가져와서 5일선 20일선 골든 크로스시 매수 매수가 대비 3%시 매도하는 전략 생성하고 백테스트 해줘**
CEO Office · 08. 28. 오전 09:45
t_07848d3b

### IN PROGRESS 82

Hermes가 처리 중인 작업

HERMES · BLOCKED
**CEO delegated risk analysis**
Risk · 08. 27. 오후 03:19
t_1fae8288

HERMES · BLOCKED
**Strategy Hermes 추적: <@1536991290842030130> 유니버스 시총 상위종목 100개 종목으로 밑에 전략 생성하고 백테스트 해줘 시장 상승 추세 확인 ↓ 정배열 종목 탐색 ↓ 변동성 압축 확인**
CEO Office · 08. 27. 오후 02:41
t_208f15ff

HERMES · BLOCKED
**CEO delegated risk analysis**
Risk · 08. 27. 오후 02:30

### DONE 1220

완료로 기록된 작업

HERMES · DONE
**QA post-response audit**
AI QA / Audit · 08. 28. 오전 10:30
t_f1807b86

HERMES · DONE
**CEO final synthesis**
CEO Office · 08. 28. 오전 10:29
t_8f8ada66

HERMES · DONE
**사용자 PAPER 조건주문 AST 해석 및 즉시 활성화**
Trading · 08. 28. 오전 10:28
t_a48f309d

실시간 에이전트 칸반 보드

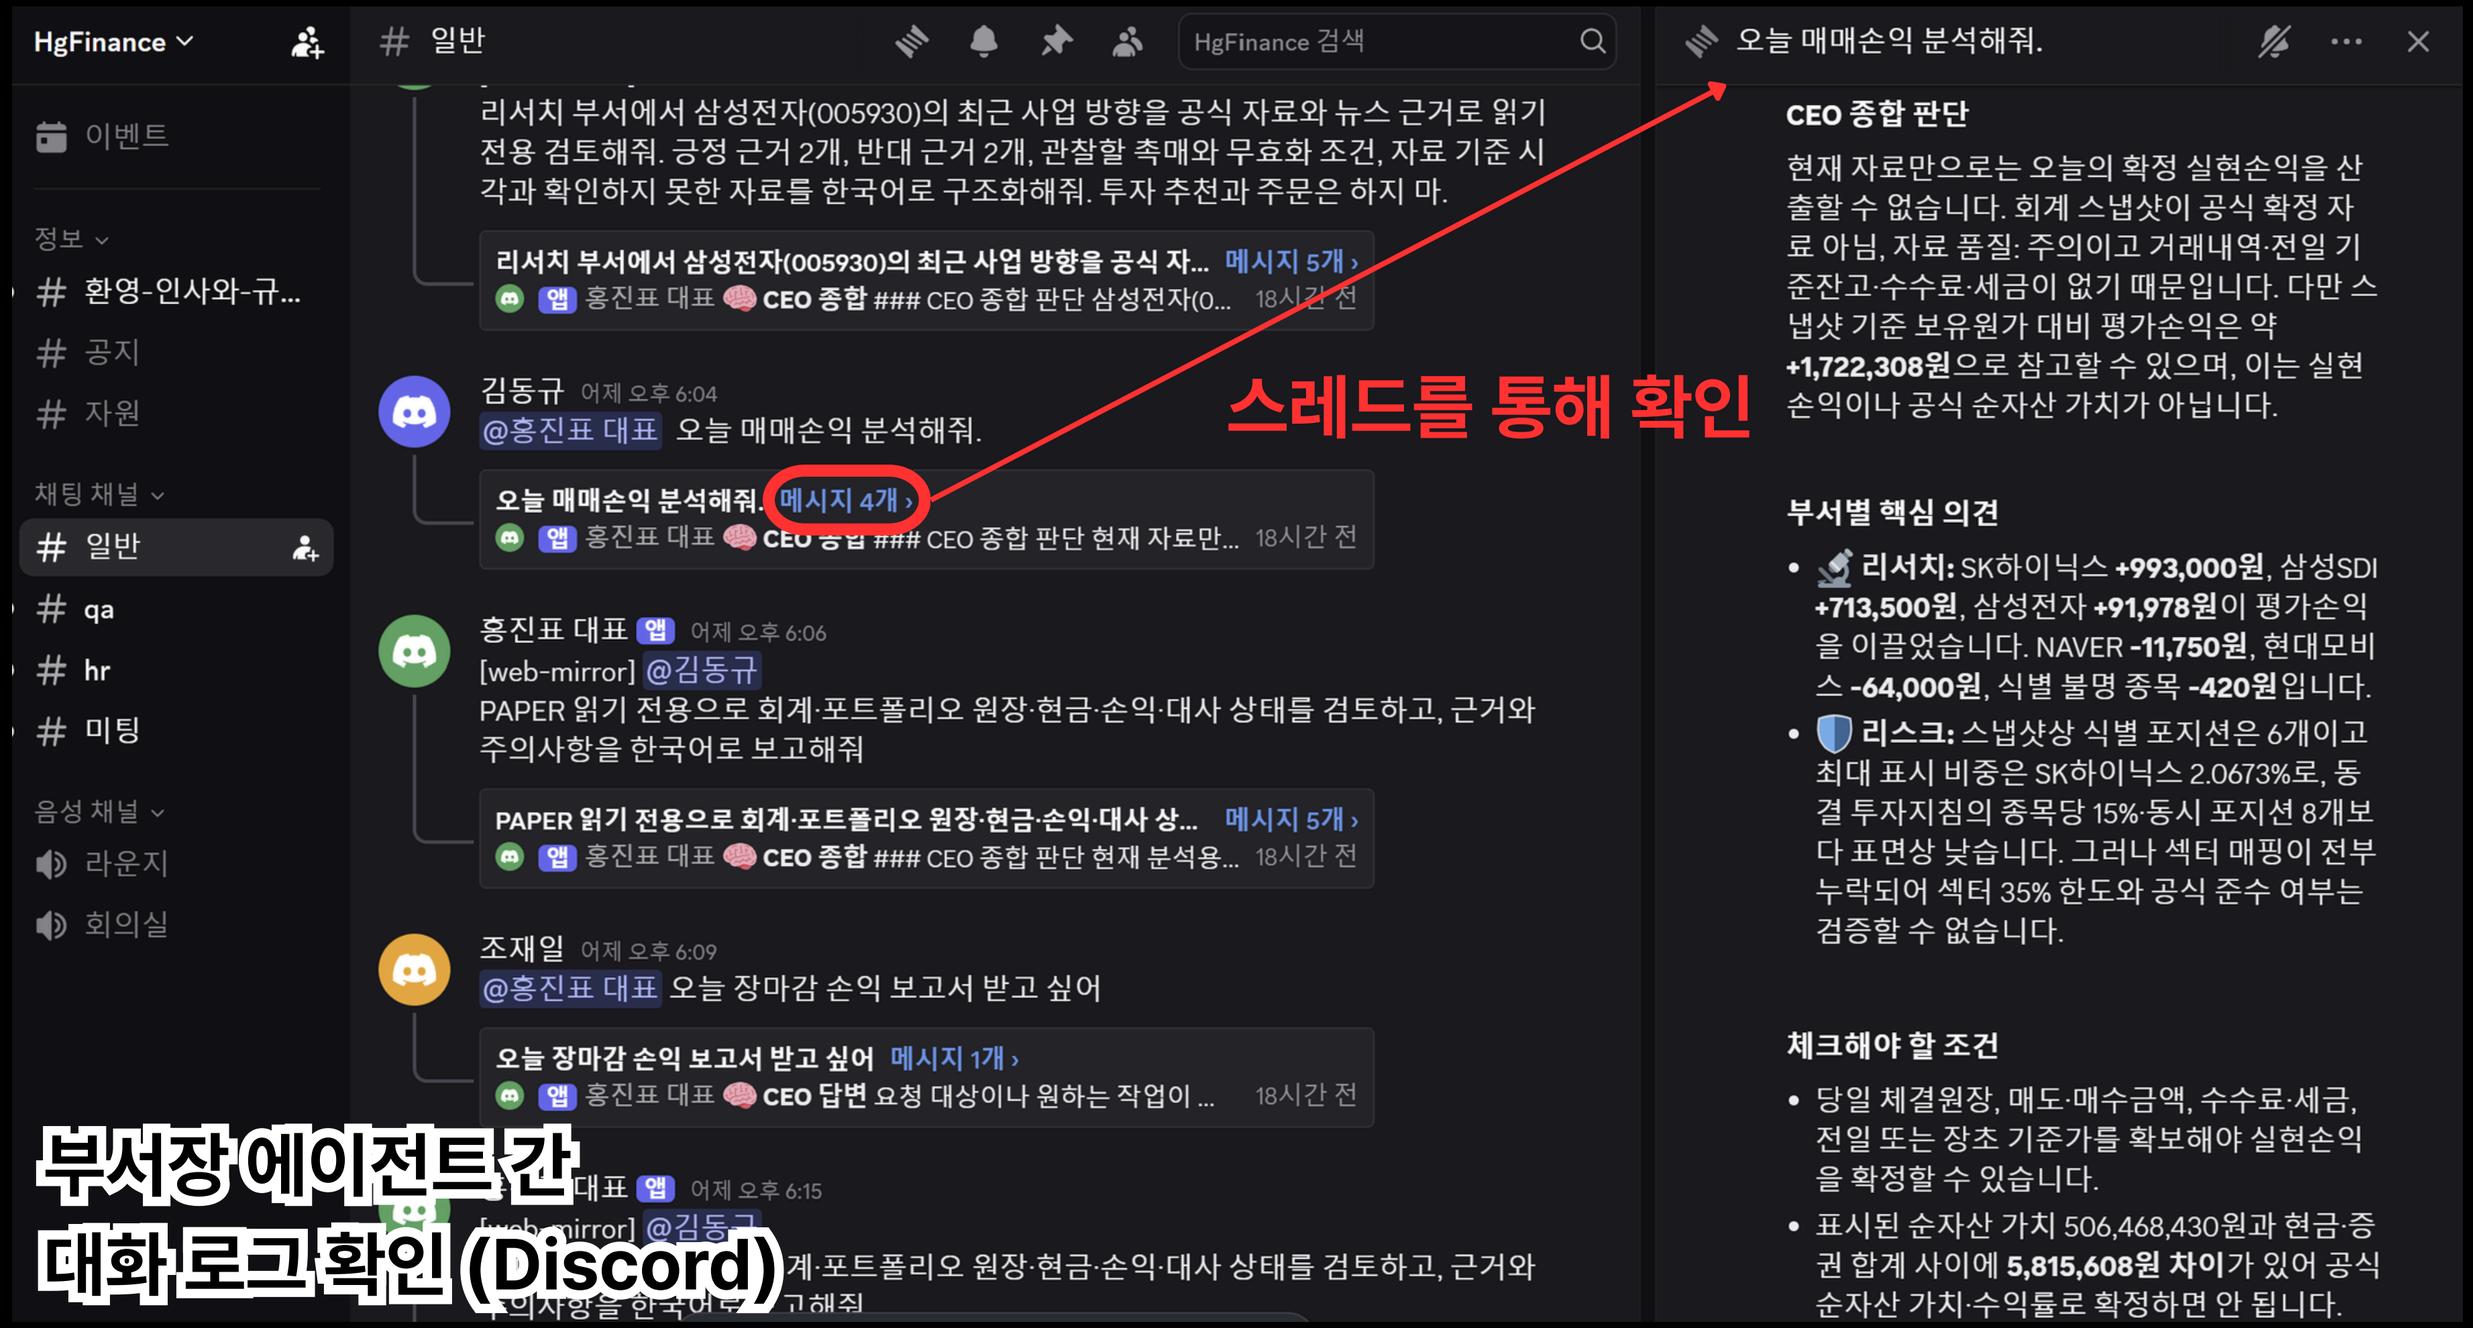
HgFinance
이벤트
정보
환영-인사와-규...
공지
자원
채팅 채널
일반
qa
hr
미팅
음성 채널
라운지
회의실
일반
HgFinance 검색
리서치 부서에서 삼성전자(005930)의 최근 사업 방향을 공식 자료와 뉴스 근거로 읽기 전용 검토해줘. 긍정 근거 2개, 반대 근거 2개, 관찰할 촉매와 무효화 조건, 자료 기준 시각과 확인하지 못한 자료를 한국어로 구조화해줘. 투자 추천과 주문은 하지 마.
리서치 부서에서 삼성전자(005930)의 최근 사업 방향을 공식 자... 메시지 5개 ›
앱 홍진표 대표 CEO 종합 ### CEO 종합 판단 삼성전자(0... 18시간 전
김동규 어제 오후 6:04
@홍진표 대표 오늘 매매손익 분석해줘.
오늘 매매손익 분석해줘. 메시지 4개 ›
앱 홍진표 대표 CEO 종합 ### CEO 종합 판단 현재 자료만... 18시간 전
홍진표 대표 앱 어제 오후 6:06
[web-mirror] @김동규
PAPER 읽기 전용으로 회계·포트폴리오 원장·현금·손익·대사 상태를 검토하고, 근거와 주의사항을 한국어로 보고해줘
PAPER 읽기 전용으로 회계·포트폴리오 원장·현금·손익·대사 상... 메시지 5개 ›
앱 홍진표 대표 CEO 종합 ### CEO 종합 판단 현재 분석용... 18시간 전
조재일 어제 오후 6:09
@홍진표 대표 오늘 장마감 손익 보고서 받고 싶어
오늘 장마감 손익 보고서 받고 싶어 메시지 1개 ›
앱 홍진표 대표 CEO 답변 요청 대상이나 원하는 작업이 ... 18시간 전
대표 앱 어제 오후 6:15
계·포트폴리오 원장·현금·손익·대사 상태를 검토하고, 근거와
스레드를 통해 확인
오늘 매매손익 분석해줘.
CEO 종합 판단
현재 자료만으로는 오늘의 확정 실현손익을 산출할 수 없습니다. 회계 스냅샷이 공식 확정 자료 아님, 자료 품질: 주의이고 거래내역·전일 기준잔고·수수료·세금이 없기 때문입니다. 다만 스냅샷 기준 보유원가 대비 평가손익은 약 +1,722,308원으로 참고할 수 있으며, 이는 실현손익이나 공식 순자산 가치가 아닙니다.
부서별 핵심 의견
리서치: SK하이닉스 +993,000원, 삼성SDI +713,500원, 삼성전자 +91,978원이 평가손익을 이끌었습니다. NAVER -11,750원, 현대모비스 -64,000원, 식별 불명 종목 -420원입니다.
리스크: 스냅샷상 식별 포지션은 6개이고 최대 표시 비중은 SK하이닉스 2.0673%로, 동결 투자지침의 종목당 15%·동시 포지션 8개보다 표면상 낮습니다. 그러나 섹터 매핑이 전부 누락되어 섹터 35% 한도와 공식 준수 여부는 검증할 수 없습니다.
체크해야 할 조건
당일 체결원장, 매도·매수금액, 수수료·세금, 전일 또는 장초 기준가를 확보해야 실현손익을 확정할 수 있습니다.
표시된 순자산 가치 506,468,430원과 현금·증권 합계 사이에 5,815,608원 차이가 있어 공식 순자산 가치·수익률로 확정하면 안 됩니다.
부서장 에이전트 간
대화 로그 확인 (Discord)

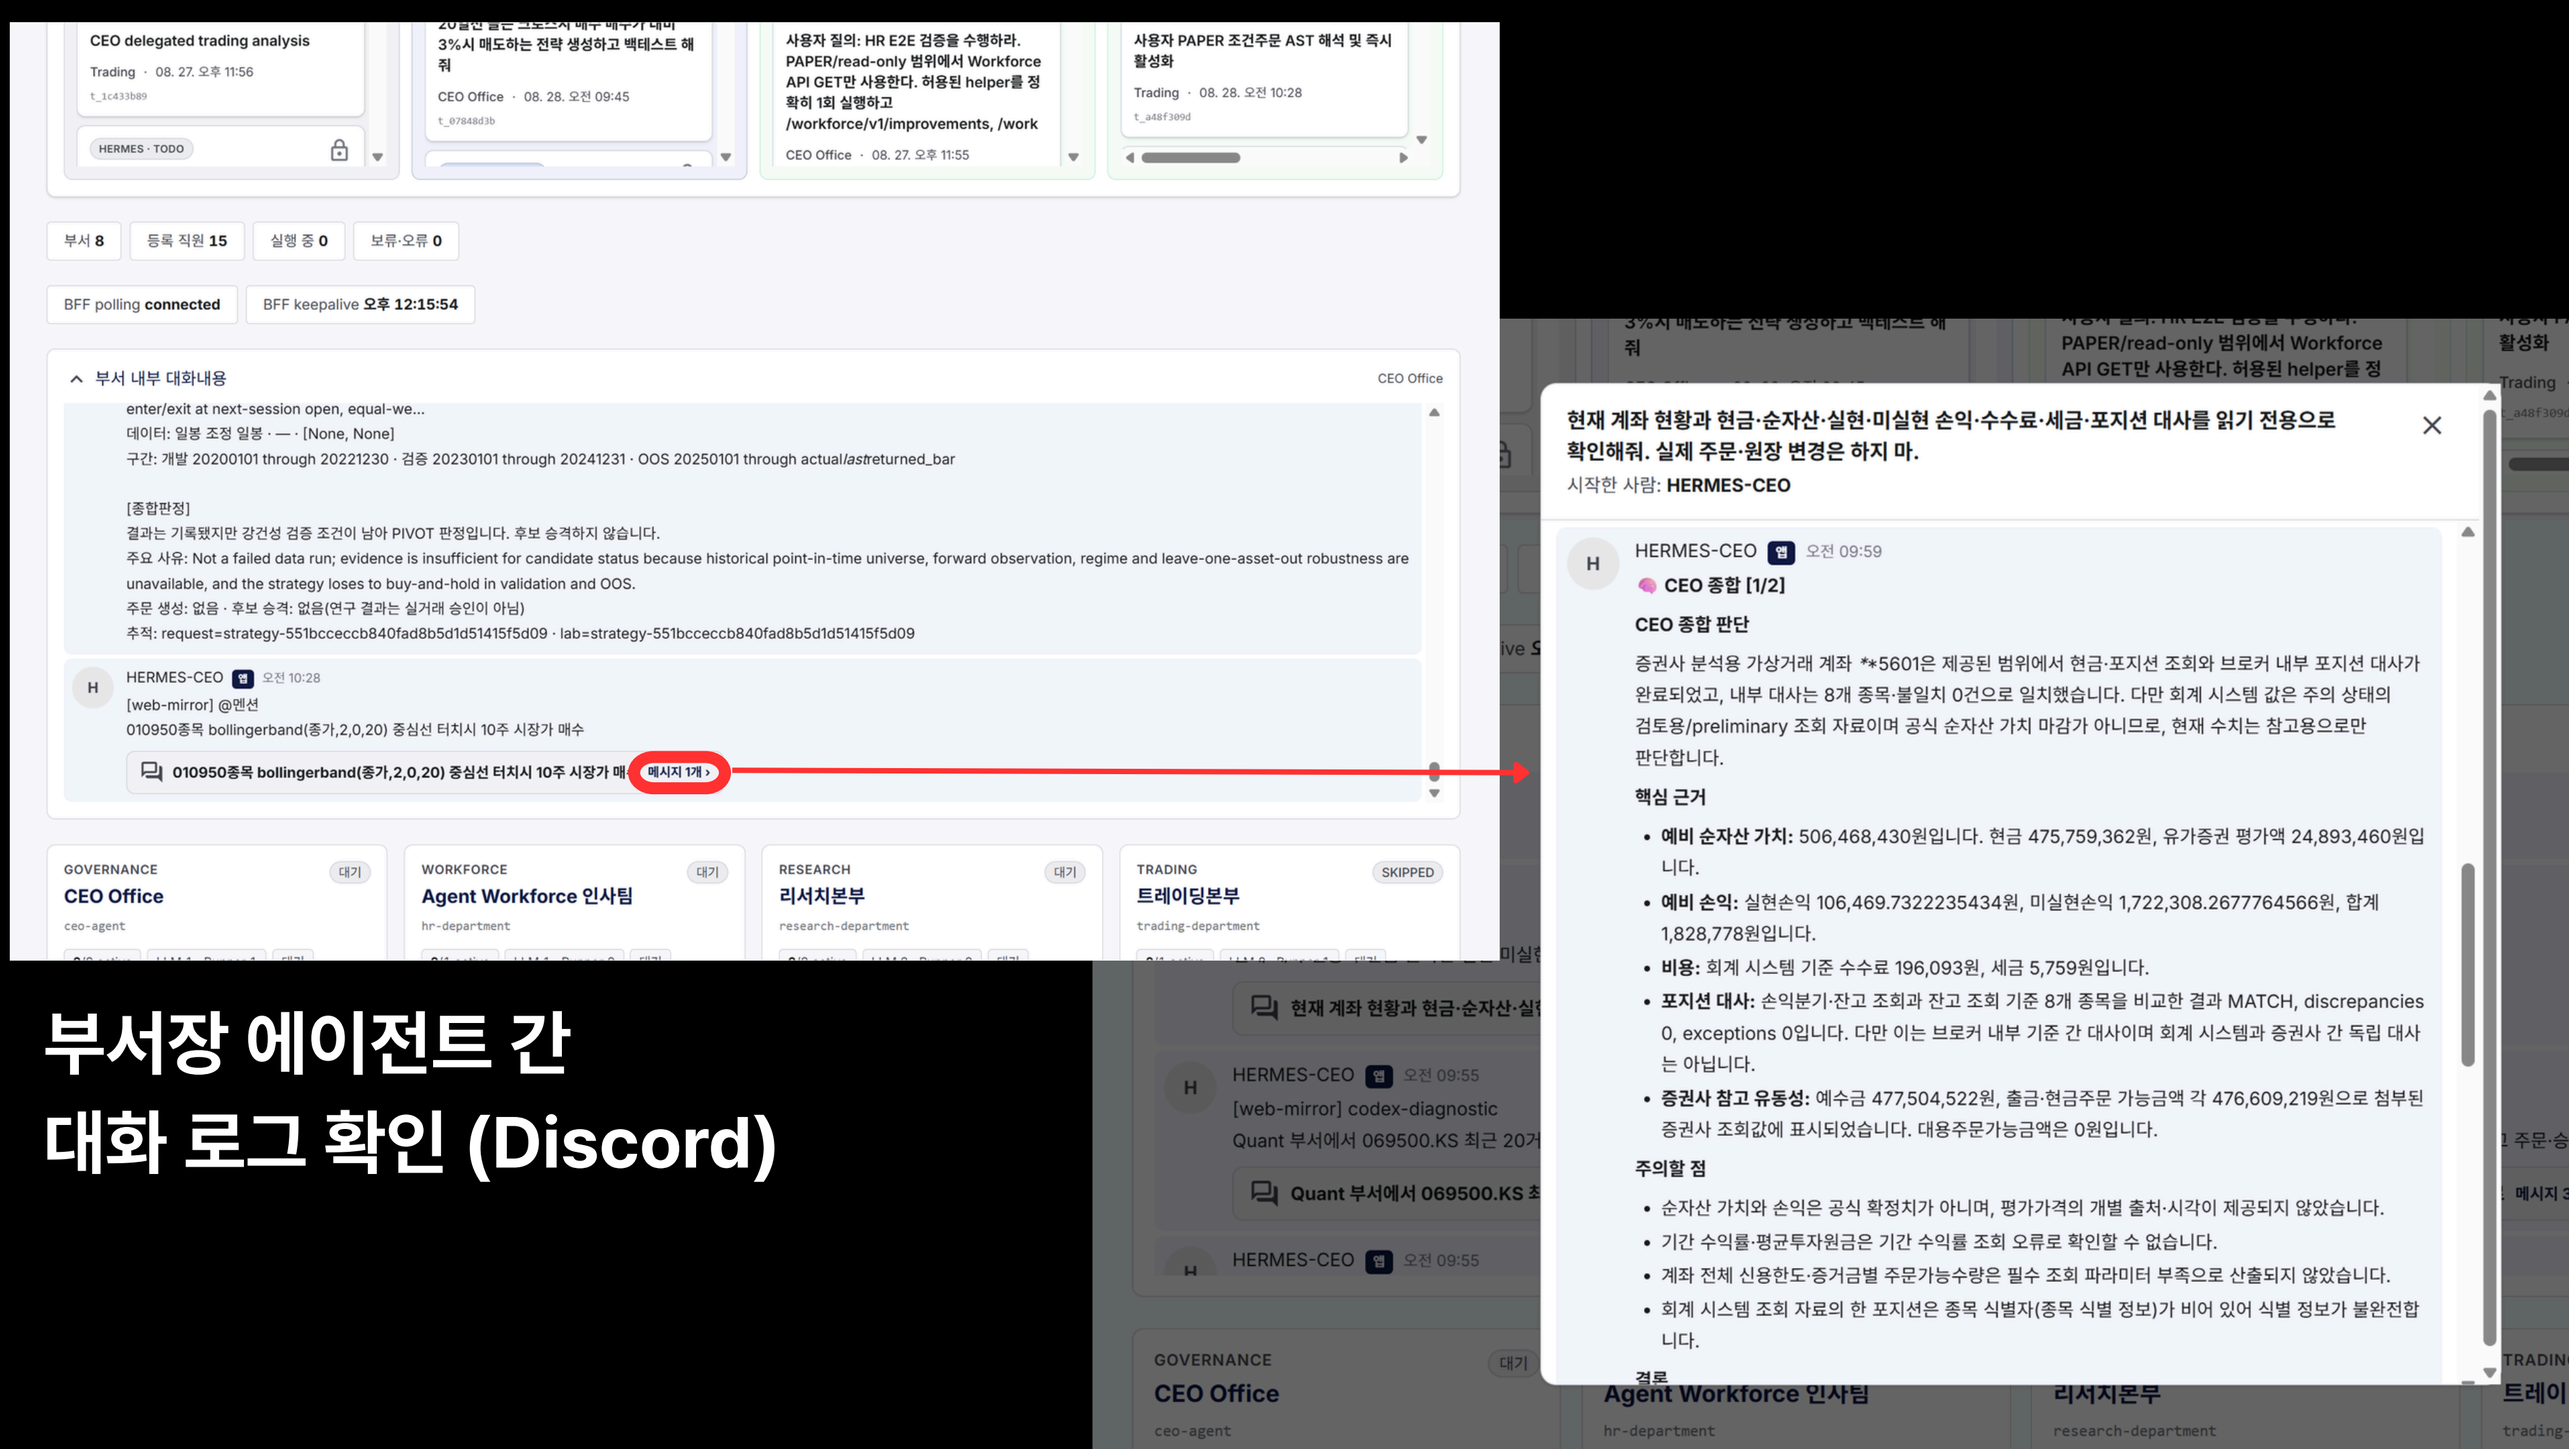


# 부서장 에이전트 간 대화 로그 확인 (Discord)

# CEO 에이전트

- 종합 리포트 발행

SELECTED DEPARTMENT

## CEO Office

ceo-agent

langgraph · qwen2.5-14b-instruct-awq · ceo.worker-context.v1

대기

등록 Worker **2** | 업무 중 **0**

**직원 Registry + 실시간 상태** 2명 · 업무 중 0명

1 **지시·결과 흐름** Dispatch · Result Storage

result_storage

RECENT OUTPUTS

### 결과물 창고

| 결과물 | 구분 | 발행 시각 |
|---|---|---|
| CEO 종합 보고 · 2026-08-28 01:30:00Z | 저녁 브리핑 | 8. 28. 오전 10:30 |
| CEO 종합 보고 · 2026-08-28 01:01:09Z | 저녁 브리핑 | 8. 28. 오전 10:01 |
| CEO 종합 보고 · 2026-08-28 00:59:25Z | 저녁 브리핑 | 8. 28. 오전 09:59 |
| CEO 종합 보고 · 2026-08-28 00:59:43Z | 저녁 브리핑 | 8. 28. 오전 09:59 |
| CEO 종합 보고 · 2026-08-28 00:58:55Z | 저녁 브리핑 | 8. 28. 오전 09:58 |
| CEO 종합 보고 · 2026-08-27 18:21:09Z | 저녁 브리핑 | 8. 28. 오전 03:21 |

### 주의할 점과 최근 판단

지금 확인이 필요한 경고와 최근에 내려진 판단을 함께 보여줍니다.

**주의할 일**

- 실행 중인 LangGraph가 없으면 직원은 이동하거나 대화하지 않습니다.
- Event 목록은 Registry 계약이며 live message와 구분됩니다.
- 포트폴리오 결과는 비바인딩·수동 검토 대상이며 주문·승인을 수행하지 않습니다.
- 현재 BFF 프로세스가 실제 LangGraph runtime event를 관찰 중입니다.

**최근에 내려진 판단**

2026. 8. 12. 오후 4:29
사용자가 추천 포트폴리오를 승인했습니다. 이 승인으로 주문은 제출되지 않습니다.

2026. 8. 12. 오후 4:25
추천 결과가 준비되었습니다. 주문·승인·원장 변경은 수행하지 않았습니다.

2026. 8. 12. 오후 4:25
CEO 오피스의 Executive briefing and cross-department handoff analyst가 검토를

# CEO 에이전트 (Discord)

- 각 부서에 업무 분배

프론트엔드 사용자 질의 → 디스코드 미러링

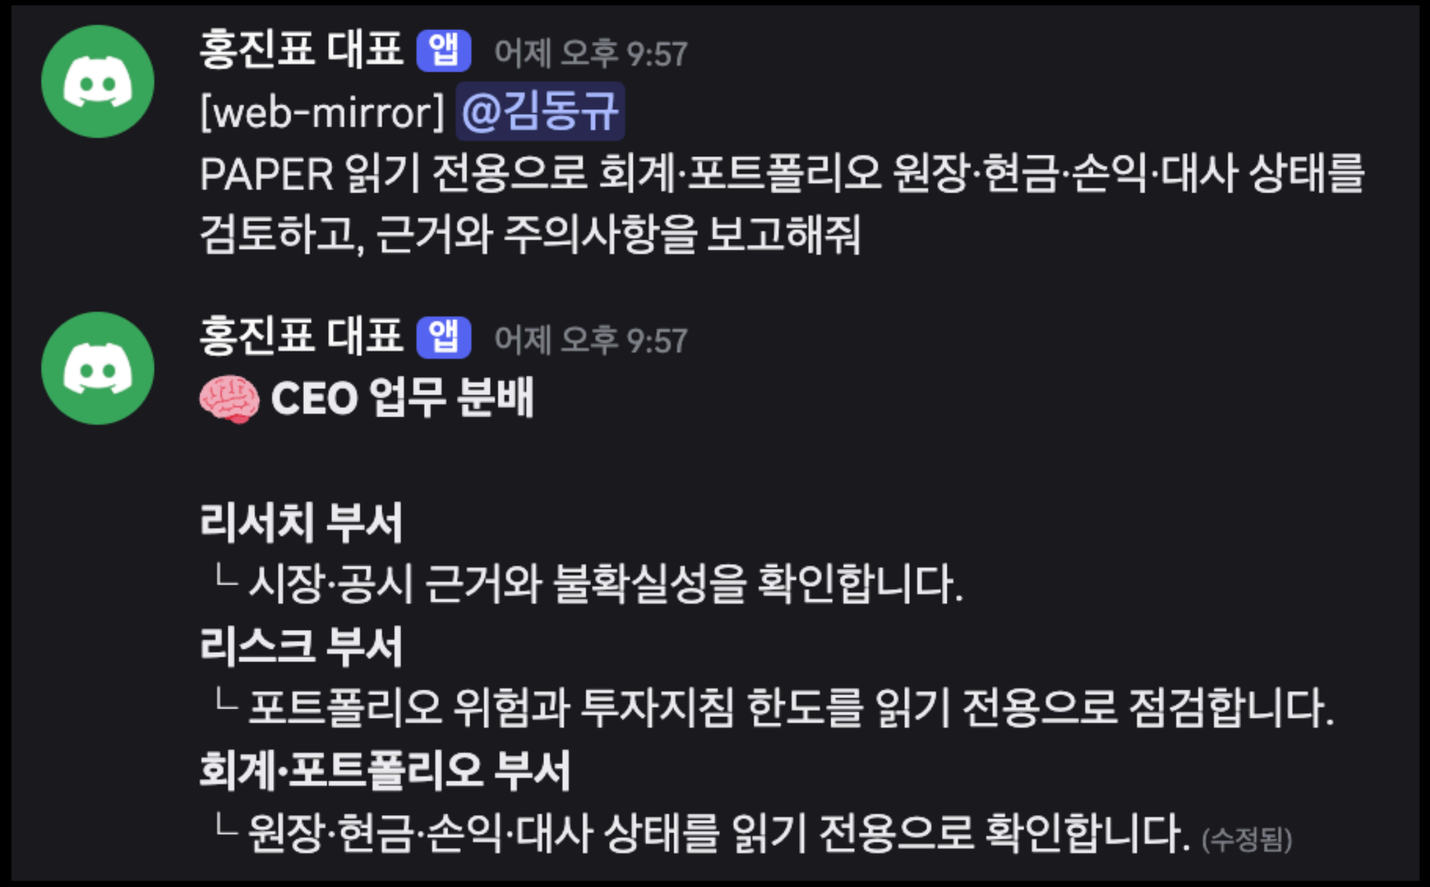


## MemoHarness

업무 분배
자가개선 파이프라인

- **사용자 쿼리** : PAPER 읽기 전용으로 회계 포트폴리오 원장 현금 손익 대사 상태를 질의
- **Task 분배** : 리서치 부서, 리스크 부서, 회계/포트폴리오 부서
- **피드백** : False

# 리서치 본부

- 최근 분석 결과 표시

SELECTED DEPARTMENT

## 리서치본부

대기

research.hypothesis_pipeline

### 최근 분석 결과

**질문 · HERMES-CEO** 2026년 8월 28일 오전 09:53

[web-mirror] codex-diagnostic
삼성전자 최신 악재와 투자 리스크를 분석해줘. 최신 근거가 없으면 확인 필요로 표시하고 주문은 하지 마.

H

HERMES-RESEARCH 2026년 8월 28일 오전 09:53

🔬 **리서치 부서**

✅ 분석을 완료했습니다.

**핵심 판단**

삼성전자(005930)의 2026년 상반기 연결 실적은 매출 305.4조원, 영업이익 146.7조원으로 전년 동기 대비 각각 약 98.7%, 1,191.4% 증가해 사업 방향 자체는 강하게 개선됐습니다. 다만 최근 악재는 실적 붕괴보다 높은 기대치, 중국 메모리 자립·경쟁 심화, AI 투자비용 및 주주환원 정책 불확실성에 집중됩니다. 이는 분석 의견이며 주문이나 매수·매도 권고가 아닙니다.

**핵심 근거**

- **공식 실적**: DART 2026.08.14 반기보고서(연결, 2026.01~06)에서 매출 305.37조원, 영업이익 146.73조원, 순이익 118.85조원을 확인했습니다. 영업이익률은 약 48.0%로 전년 7.4%보다 크게 높아졌습니다. (https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003699)
- **재무 완충력**: 2026.06.30 연결 기준 자산 759.48조원, 부채 180.17조원, 자본 579.31조원으로 계산상 부채비율은 약 31.1%입니다. 단, 현금흐름·사업부별 이익의 지속성은 별도 검토가 필요합니다.
- **최근 악재 1 — 경쟁/수요**: 2026.08.27 보도는 중국 메모리·장비 자립 우려와 AI 투자 부담을 삼성전자 리스크로 지적했습니다. 중국 내 자국산 메모리 채택이 확대되면 가격·점유율 압력이 커질 수 있습니다. (https://www.forbeskorea.co.kr/news/articleView.html?idxno=402454)
- **최근 악재 2 — 자본배분·기대치**: 2026.08.21 DART에 자기주식 취득 결정이 접수됐지만, 세부 조건과 실제 집행은 원문 재확인이 필요합니다. 8.27 보도는 자유현금흐름에 따른 환원 규모 조율 가능성과 높은 시장 기대를 주가 부담 요인으로 설명했습니다. (https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260821000616, https://www.cbci.co.kr/news/articleView.html?idxno=601511)

**주의할 점**

- **실적의 지속성**: 상반기 이익 급증이 메모리 가격·제품 믹스 등 사이클 요인인지, 구조적 경쟁력인지 아직 분리해 확인해야 합니다.
- **AI 투자 회수 위험**: 데이터센터 전력·부품 비용과 정치적 규제가 AI 설비투자 속도를 낮출 수 있다는 보도가 있습니다. (https://www.newspim.com/news/view/20260825000951)
- **확인 필요**: DART viewer는 이번 조회에서 목차 중심으로 반환되어 사업부별 실적, 자사주 취득 규모·기간, 현금흐름 세부 항목은 원문 확인이 필요합니다. 또한 보유수량·평균단가·투자기간이 없어 개인 포트폴리오 위험도는 판단할 수 없습니다.

**결론**

현재 확인 가능한 근거만으로는 '실적 방향은 개선'이지만 '위험이 해소됐다'고 말할 수는 없습니다. 특히 중국 경쟁, AI 투자비용, 기대치·주주환원 불확실성을 다음 분기에서 메모리 가격·고객 인증·현금흐름·자사주 실제 집행으로 재확인할 필요가 있습니다. 주문은 제출하지 않았습니다.

# 리서치 본부 (Discord)

조재일 리서치부장 앱 어제 오후 9:57

🔬 리서치 부서

✅ 분석을 완료했습니다.

**회계·손익 요약**

- 기준시각: 2026-08-27 02:23:48 UTC(가격은 약 02:23 UTC, 미식별 종목은 02:18 UTC)입니다.
- 재계산 합계: 취득원가 23,171,151.73원, 평가액 24,893,460원, 미실현손익 +1,722,308.27원(+7.43%)입니다. 수수료·세금·배당·환율 효과는 반영되지 않았습니다.
- 종목별 미실현손익: NAVER -11,750원(-2.62%), SK하이닉스 +993,000원(+10.48%), 삼성전자 +91,978원(+1.20%), 현대모비스 -64,000원(-12.36%), 미식별 종목 -420원(-0.39%), 삼성SDI +713,500원(+14.40%)입니다.
- 현금 475,759,362원, 보고 순자산 가치 506,468,430원입니다. 현금+증권은 500,652,822원으로 순자산 가치보다 5,815,608원 적습니다. 스냅샷 자체가 비권위적이라고 명시하므로 원장·미결제·평가조정·수수료 등의 원인을 확인해야 합니다.

**Sources**

[1] https://www.pinpointnews.co.kr/news/articleView.html?idxno=481244 (2026-08-27)
[2] https://www.pinpointnews.co.kr/news/articleView.html?idxno=481197 (2026-08-27)
[3] https://n.news.naver.com/mnews/article/011/0004655804?sid=101 (2026-08-27)
[4] https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003699 (삼성전자 반기보고서, 2026-08-14)
[5] https://dart.f/... (수정됨)

핀포인트뉴스

[코스피 지수선물 옵션] 삼성전자·SK하이닉스 올랐...

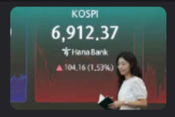


27일 개별주식선물 시장에서 삼성전자와 SK하이닉스가 상승한 가운데 전력기기와 방산, 2차전지 관련 종목의 강세가 두드러졌다. 효성중공업과 HD현대일렉트릭, 삼성전기, 삼성SDI 등도 큰 폭으로 올랐다.한국거래소에 따르면 이날 삼성전자 선물은 전날보다 4500원 ...

핀포인트뉴스

[거래소 기관] 매수 1위 삼성SDI...현대차·현대모비...

유가증권시장에서 기관 투자자들이 삼성SDI와 삼성전기, 두산에너빌리티 등 주요 대형주를 사들인 반면 SK하이닉스와 현대차, 현대모비스 등은 내다팔았다. 2차전지와 전력기기, 원전 관련주에 매수세가 몰린 가운데 자동차와 일부 대형 기술주는 매도 우위를 보...

# 리서치 본부 (Notion 리포트)

## 리서치 부서 업무·성과 요약

### 핵심 결과

### 긍정 근거

1. **HBM4 수율 개선 및 공급 확대 목표**: 서울경제는 2026년 8월 10일 삼성 HBM4 수율이 양산 초기 60% 미만에서 약 80%에 접근했고, 3분기 HBM4 매출을 전 분기 대비 3배 이상 늘리는 목표를 전했다고 보도했습니다. 출처: 서울경제, 2026-08-10, https://n.news.naver.com/mnews/article/011/0004650134?sid=102
2. **사업 간 통합 역량 강화**: 같은 기사에 따르면 메모리·파운드리·첨단 패키징의 일괄 대응이 수율 안정화 배경으로 거론되며, HBM4E 신뢰성 테스트 수율 70% 이상 및 생산능력 확대가 언급됐습니다. 이는 회사의 통합형 AI 반도체 전략과 맞닿지만, 기사상 업계 분석·전언으로 구분해야 합니다. 출처: 서울경제, 2026-08-10, https://n.news.naver.com/mnews/article/011/0004650134?sid=102

### 반대 근거

1. **수요·밸류체인 변동성**: 서울경제는 2026년 8월 3~7일 외국인이 삼성전자·SK하이닉스 등 반도체·전자부품 5개 종목을 약 5조 9183억 원 순매도했다고 보도하며, 하이퍼스케일러 AI 투자 지속성에 대한 의구심을 위험 요인으로 제시했습니다. 출처: 서울경제, 2026-08-10, https://n.news.naver.com/mnews/article/011/0004650134?sid=102
2. **경쟁 및 수요 훼손 가능성**: 같은 기사에는 애플의 중국 CXMT 메모리 도입 추진과 메모리 가격 상승에 따른 PC·스마트폰 출하 감소가 언급되어, 중국 경쟁·고가 메모리로 인한 고객 수요 둔화가 통합 전략의 성과를 제한할 수 있습니다. 해당 내용은 기사 보도이며 별도 공식 확인은 하지 못했습니다. 출처: 서울경제, 2026-08-10, https://n.news.naver.com/mnews/article/011/0004650134?sid=102

### 관찰할 촉매·무효화 조건

- **촉매**: 다음 실적·공식 공시에서 HBM4 실제 출하·매출, 수율, 고객 인증 및 파운드리·패키징 연계 수주가 수치로 확인되는지 관찰합니다.
- **무효화 조건**: 공식 수치가 기사 목표에 못 미치거나 HBM4 고객 인증·출하 지연, 수율 재하락, AI 메모리 투자 축소와 가격 하락이 확인되면 긍정적 사업 방향 가설은 약화됩니다.

### 자료 기준과 확인하지 못한 자료

조회 기준은 2026년 8월 27일입니다. DART 최근 공시 목록에서 삼성전자의 2026년 8월 21일 공정공시(rcept_no 20260821800763), 8월 14일 반기보고서(rcept_no 20260814003699) 등을 확인했습니다. 출처: 금융감독원 DART, 2026-08-21 및 2026-08-14, https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260821800763 및 https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003699. 그러나 DART 원문은 목차만 반환되어 공시의 수치·세부 사업 내용은 확인하지 못했습니다. HBM4 수율·매출 목표, CXMT·외국인 수급 내용도 서울경제 기사 본문에 의존했으며 회사 공식 발표로 독립 검증하지 못했습니다.

## 자료·안전 주의사항

- 확인된 자료와 확인하지 못한 자료를 구분해 기록했습니다.
- 이번 업무는 읽기 전용 조사이며 투자 추천·주문·승인·원장 변경을 수행하지 않았습니다.

# 퀀트/백테스트 본부

- 최근 발굴한 전략 요약 및 설명
- 백테스트를 통한 수치 비교

SELECTED DEPARTMENT

## 퀀트·백테스트본부

미호출

quant.adopted_strategy

PAPER ONLY - no real orders

QUANT · ADOPTED ALPHA STRATEGY

### spike-fade-v2-state-gate (frozen)

OFF

컨테이너를 찾을 수 없습니다

학습 세션 52일 · 피처 43개로 게이트(상위 25%)를 통과해 채택된 최종 알파 전략입니다.

한국 시장에서 장중 급등 종목의 다음 1시간은 평균적으로 하락한다. 원인은 두 겹: 복권처럼 급등주에 몰리는 개인투자자의 과잉반응(행동재무학의 MAX 효과), 그리고 변동성완화장치(VI) 단일가 경매가 되돌림의 약 40%를 기계적으로 수행하는 시장 구조. 즉 심리적 엔진과 제도적 엔진을 동시에 가진 엣지.

$ backtest - -window 개발기록 · 37거래일

| 지표 | 값 |
|---|---|
| 거래당 평균 | +98.96 bp |
| 일평균 | +58.57 bp |
| 90% 신뢰하한 | +34.5 bp |
| 승률 / 양수 세션 | 60.3% / 73 % |
| 거래 수 | 219 건 |

**자세히 보기**

백테스트 성과 · 모델 구성 · 설정 변수

세션 2026-08-24

**실시간 페이퍼 성과 (오늘 세션)**

| 체결 | 미체결 | 평균 체결 성과 | 슬롯당 성과 |
|---|---|---|---|
| 0건 | 3건 | 체결 없음 | +0.00bp |

live-2026-08-24.json · 2026. 8. 24. 오전 10:18:47 기준 · PAPER 전용, 실제 주문이 아닙니다.

**모델 구성 (XGBoost)**

| 방향 | 목적함수 | 트리 수 | 피처 수 | base_score |
|---|---|---|---|---|
| Long | reg:squarederror | 300 | 43 | [-5.2980904E1] |
| Short | reg:squarederror | 300 | 43 | [-2.5018675E1] |

**전략에 포함되는 변수**

| 변수 | 값 | 설명 |
|---|---|---|
| lambda1_gate_threshold | 0.197711 | 이 값을 넘는 신호만 진입을 허용하는 게이트 |
| gate_percentile | 25% | 게이트 임계값을 정할 때 쓴 상위 분위 |
| training_sessions | 52일 | 이 팩 학습에 쓰인 거래일 수 |
| target_session / previous_session | 2026-08-24 / 2026-08-21 | 이 팩이 대상으로 하는 세션과 직전 세션 |
| sealed_final_sessions_loaded | false | 아직 최종 확정 전 데이터 포함 - 참고용 |

# 퀀트/백테스트 본부 (Notion 리포트)

## 퀀트·백테스트 검토 결과 · 2026-08-27 03:40:33

| | |
|---|---|
| CEO 승인 | ☐ |
| # MDD | 비어 있음 |
| QA 승인 | ☐ |
| Risk 승인 | ☐ |
| # Sharpe | 비어 있음 |
| trade_case_id | 비어 있음 |
| 생성 시각 | 2026년 8월 27일 오후 12:40 |
| 서술 | 결론: KODEX 200 ETF(069500.KS)의 최근 20거래일 원시 일별 종가·거래량 데이터는 확인되었습니다. 다만 이 reference desk는 도구가 반환한 값을 재계산하지 않으며, 검증된 파생 지표가 도구 출력에 포함되지 않았으므로 누적수익률·일간수익률 변동성·최대낙폭 수치는 제시하지 않습니다.<br><br>근거 — mcp__research__global_history:<br>- symbol: 069500.KS<br>- currency: KRW<br>- range: 3mo<br>- interval: 1d<br>- count: 64<br>- queried_at: 2026-08-27T03:39:43.638601<br>- 반환 항목: ts, close, volume<br>- 최근 20개 관측치: 반환된 64개 중 마지막 20개 원시 관측치(첫 close 87635.0, 마지막 close 109950.0)<br>- citation: db97c8bb7d98035a<br><br>보류 사유 및 한계:<br>1. 도구 출력은 close와 volume 원시 시계열이며 누적수익률·변동성·최대낙폭의 검증된 산출값을 제공하지 않습니다.<br>2. 본 결과에는 보정주가/배당 반영 여부와 거래일 날짜 라벨이 명시되지 않아 총수익률 해석 및 날짜별 검증에 한계가 있습니다.<br>3. 따라서 수치를 임의로 만들거나 재계산하지 않고, 해당 성과 요약은 보류합니다. |

# 트레이딩 본부

- 주문 현황, 계좌 잔고 확인

SELECTED DEPARTMENT

미호출

## 트레이딩본부

1 **오늘 거래와 포트폴리오** 체결 · 결제 · 보유 · 손익

trading_portfolio.live

TRADING · ACCOUNTING / PORTFOLIO

### 주문 현황과 계좌 잔고

주문이 접수·체결·정정·취소·거부될 때마다 상태가 바뀌고, 체결이 나면 잔고를 다시 맞춥니다.
이 화면은 조회만 하며 주문을 내지 않습니다.

**포트폴리오 비중** 8종목

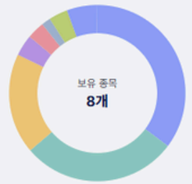


| | |
|---|---|
| SK하이닉스 | 35.3% |
| 삼성전자 | 28.6% |
| 삼성SDI | 18.5% |
| 한온시스템 | 3.9% |
| 두산에너빌리티 | 3.2% |
| NAVER | 1.7% |
| 레인보우로보틱스 | 3.5% |
| 두산로보틱스 | 5.4% |

**종목별 평가 수익률** 8종목

| | |
|---|---|
| 삼성SDI | +15.94% |
| SK하이닉스 | +6.81% |
| 두산에너빌리티 | +0.33% |
| 한온시스템 | -0.65% |
| 레인보우로보틱스 | -1.68% |
| NAVER | -1.73% |
| 삼성전자 | -2.07% |
| 두산로보틱스 | -2.53% |

**오늘 거래 요약** 오늘 기준

오늘 체결된 거래와 결제 흐름을 빠르게 확인합니다.

| 거래 횟수 | 매수 금액 | 매도 금액 | 총 거래금액 | 수수료 | 세금 |
|---|---|---|---|---|---|
| 0건 | 0원 | 0원 | 0원 | 0원 | 0원 |

| 추정순자산 | 평가금액 | 매입금액 | 평가손익 | 실현손익 |
|---|---|---|---|---|
| 501,464,109원 | 28,064,540원 | 26,851,969원 | 1,212,571원 | 0원 |

| 접수 | 체결 | 정정 | 취소 | 거부 |
|---|---|---|---|---|
| 0 | 40 | 0 | 0 | 0 |

**주문 사건** 모의투자 · ****5601 · 2건

| 시각 | 상태 | 종목 | 매매 | 수량 | 가격 | 출처 | 주문번호 |
|---|---|---|---|---|---|---|---|
| — | 체결 | 삼성전자 | 매수 | 1 | 257,500원 | 출처 미확인 | — |
| — | 체결 | 삼성전자 | 매도 | 1 | 258,000원 | 출처 미확인 | — |

**보유 종목** 8건

| 종목 | 수량 | 평균단가 | 평가액 | 수익률 |
|---|---|---|---|---|
| SK하이닉스 | 6 | 1,579,500원 | 10,124,187원 | 6.81% |
| 삼성전자 | 29 | 264,389원 | 7,509,322원 | -2.07% |
| 삼성SDI | 10 | 495,650원 | 5,747,616원 | 15.94% |
| 한온시스템 | 300 | 3,480원 | 1,037,267원 | -0.65% |
| 두산에너빌리티 | 10 | 86,610원 | 869,129원 | 0.33% |

# 트레이딩 본부 (Notion 리포트)

## Exact user instruction

010950 1분뒤 시장가 1주 매수

## Result

Ticker : 010950
Status : BUY
체결 수량 : 1주
주문 유형 : MARKET
평균 체결가 : 148,800원
브로커 주문 ID : paper:e1ec7cb8-2508-50c8-8914-20537fe91293
처리 상태 : COMPLETED
회계 반영 : 완료
검증 시각 : 2026-08-28T06:18:59.272886+00:00
권위 근거 : trading.user_directives directive_id=13ad0c23-924d-4837-99a7-465bd7d43f7f
조건 규칙 ID : 3813a40a-6ba9-423c-a603-ba08cce5b487
미확인 항목 : 없음
QA 검증 : PASS (hgfinance.semantic-qa.v1)

# 시연영상

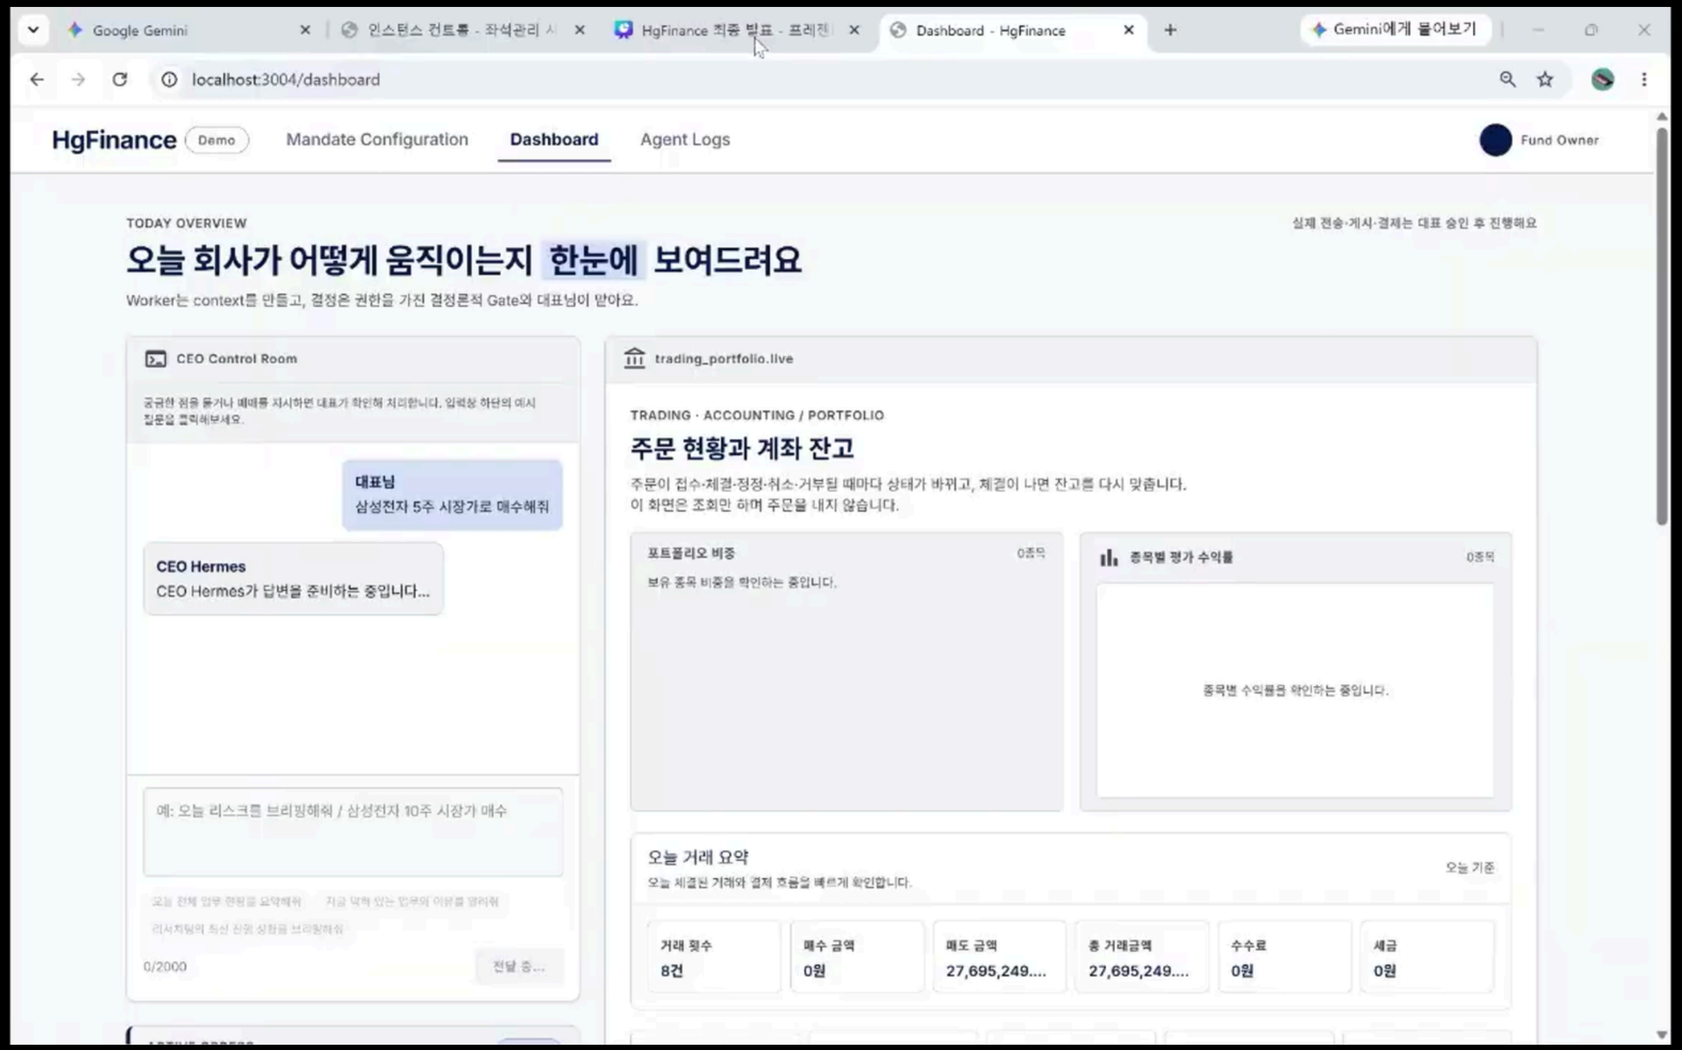


https://drive.google.com/drive/folders/19DzT7aTL-9EWN7TTwQeBzJQUJqaWBgR2?usp=drive_link

# 회계/포트폴리오 본부

- 계좌 원장, 거래 내역 확인

ACCOUNTING · GENERAL LEDGER

## 회계본부 관리 계좌 현황

회계기간
2026-07-30 ~ 2026-08-28

### 계좌 원장

자산 · 손익 · 비용 · 거래 현황

| 구분 | 계정과목 | 금액 · 건수 | 산출 기준 |
|---|---|---|---|
| 자산 | 추정순자산 | 501,469,846원 | 보유자산 평가액과 예수금 등을 반영한 추정치 |
| | 보유자산 평가금액 | 28,070,277원 | 8종목 · 오후 12:25 기준 |
| | 보유자산 매입원가 | 26,851,969원 | 현재 보유분의 취득원가 |
| | 기말 예수금 | 477,504,522원 | 기간 마지막 거래 직후 잔액 |
| 손익 | 실현손익 | 0원 | 매도로 확정 · 제비용 반영 |
| | 평가손익 | 1,218,308원 | 보유 중 · 미확정 |
| | 총손익 | 1,218,308원 | 실현손익 + 평가손익 |
| 거래비용 | 수수료 | 449원 | 조회 기간 합계 |
| | 세금 | 4,938원 | 거래세·소득세·주민세 |
| | 비용 합계 | 5,387원 | 실현손익에 이미 반영 · 중복 차감 안 함 |
| 거래 현황 | 거래 건수 | 40건 | 조회 기간 전체 |
| | 배당 수입 | 0원 | 조회 기간 합계 |

### 거래 내역

개별 거래가 필요할 때 펼쳐보세요

40건 · 최근순

| 거래일시 | 적요 | 종목 | 수량 | 단가 | 거래금액 | 수수료 | 세금 | 손익 | 예수금 잔액 |
|---|---|---|---|---|---|---|---|---|---|
| 08.28 | 보통매수 매수 | 삼성전자 005930 | 1 | 257,500 | 257,500 | | | | 477,504,522 |
| | 보통매도 매도 | 삼성전자 005930 | 1 | 258,000 | 258,000 | | | | 477,762,060 |
| 08.27 10:00:21 | 당일 매매 매도 | 현대모비스 012330 | 1 | 451,500 | 451,500 | 67 | 902 | | |
| | 보통매수 매수 | SK하이닉스 000660 | 2 | 1,609,000 | 3,218,000 | | | | 477,504,485 |
| | 보통매도 매도 | 삼성전자 005930 | 1 | 248,250 | 248,250 | | | | 480,722,967 |
| 08.26 | 보통매수 매수 | 삼성전자 005930 | 1 | 260,250 | 260,250 | | | | 486,680,172 |
| | 보통매수 | 삼성전자 | 1 | 260,000 | 260,000 | | | | 486,940,422 |
| 합계 · 40건 | | | | | | 449 | 4,938 | | 477,504,522 |

# 회계/포트폴리오 본부 (Discord)

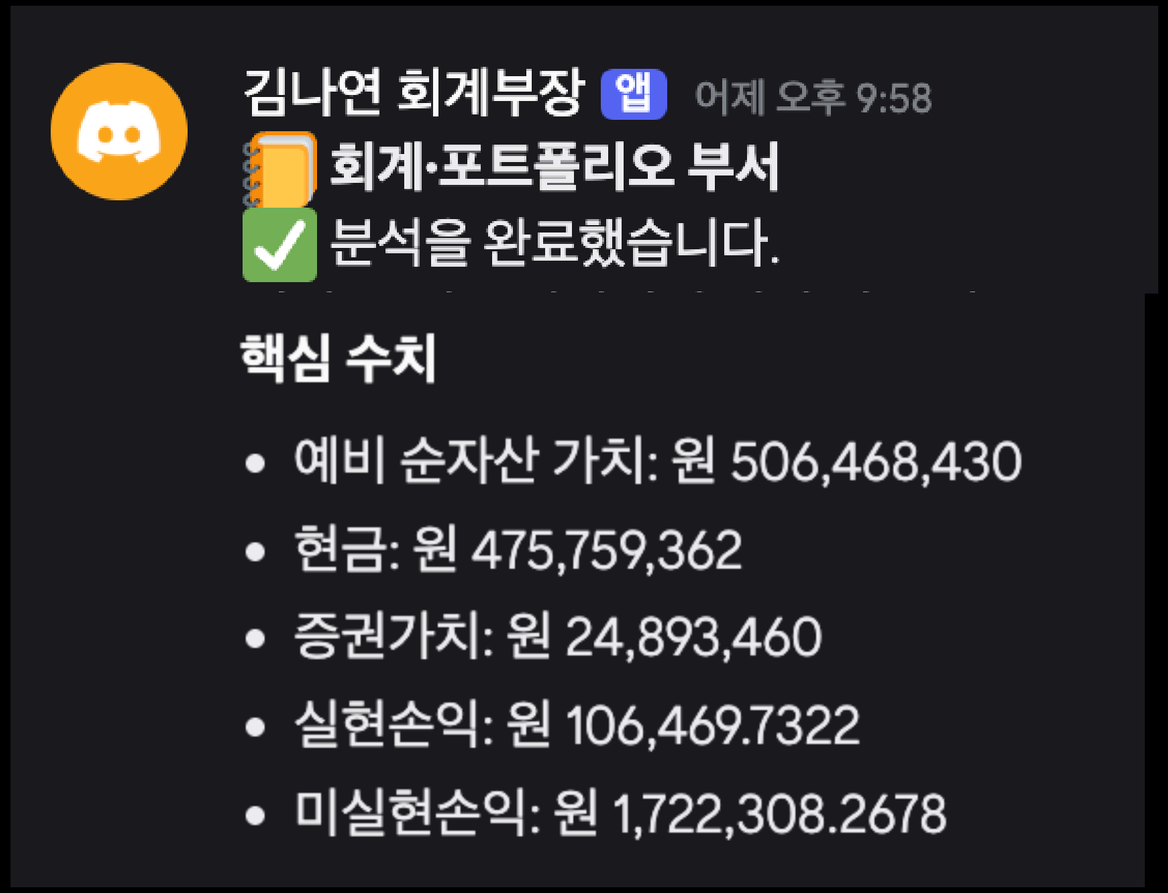

# 회계/포트폴리오 본부 (Notion 리포트)

## 검토 결과

범위: 가상거래 분석용 가상거래 계좌(마스킹 ****5601), 펀드/장부/전략 구분은 제공되지 않음.

기준 시각·출처:

- 회계 시스템 검토용 조회 자료: 2026-08-27T02:23:48.068921+00:00 UTC. 원장(회계 시스템 원장, Supabase) 기반이며 공식 확정 아님, 자료 품질 상태: 주의입니다.
- 증권사 부착 증거: 2026-08-27T17:54:19.280962+00:00 UTC, 증권사 증권사 조회 API 증권사 잔고 조회, 분석용 가상거래, 증권사 조회 기록 등. 브로커 자료도 공식 확정 아님·공식 확정 자료 아님이며 회계 시스템을 대체하지 않습니다.

1. 회계 시스템 예비 계좌·순자산 가치

- 예비 순자산 가치: 506,468,430 원
- 현금: 475,759,362 원
- 증권가치: 24,893,460 원
- 총손익: 1,828,778.00 원 = 실현손익 106,469.7322235434 + 미실현손익 1,722,308.2677764566
- 실현손익: 106,469.7322 원
- 미실현손익: 1,722,308.2678 원
- 회계 시스템 수수료: 196,093 원
- 회계 시스템 세금: 5,759 원

1. 회계 시스템 포지션(롱)

- NAVER(035420): 2주, 시장가치 436,000 원, 미실현손익 -11,750 원
- SK하이닉스(000660): 6주, 시장가치 10,470,000 원, 미실현손익 993,000 원
- 삼성전자(005930): 29주, 시장가치 7,757,500 원, 미실현손익 91,978.2678 원
- 현대모비스(012330): 1주, 시장가치 454,000 원, 미실현손익 -64,000 원
- 종목 식별자·명칭 미제공 종목 식별 정보: 12단위, 시장가치 105,960 원, 미실현손익 -420 원
- 삼성SDI(006400): 10주, 시장가치 5,670,000 원, 미실현손익 713,500 원
- 숏 포지션: 회계 시스템 조회 자료상 별도 숏 포지션 없음.

1. 유동성·결제·신용/마진

증권사의 적용 가능한 커버리지는 CSPAQ12200, CSPAQ12300, CSPAQ22200 모두 정상·완료입니다(증권사 조회 기록, 증권사 조회 기록, 증권사 조회 기록).

- 브로커 예수금: 477,504,522 원
- D+1 예수금: 477,504,430 원
- D+2 예수금: 473,399,477 원
- 출금가능금액: 476,609,219 원
- 현금 주문가능금액: 476,609,219 원
- 대체 주문가능금액: 0 원
- 미수금·대출·담보부족: 모두 0으로 보고됨
- D+1 예상정산: -92 원, D+2 예상정산: -4,104,953 원

# 리스크 관리 본부

- 사용자 설정 한도 위반 시 차단 또는 경고 부여

## 리스크관리본부

1 **사용자 Mandate와 주문 전 확인** 허용 범위 · 한도 · Risk Gate

risk.mandate_guardrails

**Mandate가 허용 범위를 정합니다**
사용자 목표가 구조화된 Mandate Version으로 저장되면 허용 시장·자산군·종목·섹터·거래시간이 주문의 첫 번째 경계가 됩니다.

**위험 노출은 주문 후 상태로 계산합니다**
새 주문만 보지 않고 현재 포지션과 대기 중인 노출을 함께 반영해 종목·섹터·전체 Gross Exposure가 한도를 넘는지 확인합니다.

**축소 가능한 초과와 차단을 구분합니다**
Notional·섹터·집중도·회전율처럼 수량을 줄여 통과할 수 있는 경우와 유니버스·Restricted List·손실·거래상태 위반처럼 즉시 차단해야 하는 경우를 구분합니다.

**위험 확대는 사용자 승인으로 묶습니다**
Mandate보다 느슨한 한도나 자동 실행으로 바꾸는 것은 기존 주문에 조용히 적용하지 않고 새 정책 버전과 사용자 재승인을 요구합니다.

**현재 사용자 Mandate**
위험을 감수하더라도 시장 이상의 극단적인 수익을 노린다. 투자 기간은 5년, 현금화 시점은 3년 후.

**현재 적용 중인 Mandate 한도**

| 기준 자본 | 종목 최대 비중 | 섹터 최대 비중 |
|---|---|---|
| ₩500,000,000 | 15% | 35% |
| **최대 Gross Exposure** | **동시 보유 Position** | **일일 손실 / 최대 Drawdown** |
| 150% | 8개 | 3% / 20% |

**Mandate 유니버스**

| | |
|---|---|
| 허용 시장 | KRX |
| 허용 자산군 | KOREA_EQUITY · PROVISIONAL_ETF · LEVERAGED_ETF · PROVISIONAL_FUTURES · PROVISIONAL_OPTIONS · DERIVATIVES_HEDGE |
| 금지 자산군 | PROVISIONAL_CRYPTO |
| 제외 섹터 | 없음 |
| 거래 시간 | 09:00–15:30 |

**실행·승인 기준**

| | |
|---|---|
| Paper 주문 | **사용자 승인 후 실행** |
| Risk 확대 재승인 | **필요** |
| 종목 직접 허용 목록 | 없음 |

**주문 요청이 들어오면 이렇게 확인합니다**
Mandate와 현재 계좌 상태를 순서대로 확인하며, 기준을 하나라도 충족하지 못하면 주문을 그대로 실행하지 않습니다.

**01 데이터 신선도**
시점 고정 시세와 시장 상태가 유효한지 확인

**02 Mandate 범위**
허용 종목·자산군·섹터·거래시간 밖인지 확인

**03 주문 가능성**
Restricted List, 가격·수량·Notional, 현금·Buying Power 확인

**04 누적 위험**
섹터·Issuer 집중도·회전율·동시 포지션·Gross 노출 확인

**05 손실·거래 상태**
일일 손실·Drawdown·Trading State·브로커 상태 확인

# 리스크 관리 본부 (Discord)

이예주 리스크부장 앱 어제 오후 9:57

🛡️ **리스크 부서**

✅ 분석을 완료했습니다.

**핵심 근거**

- **투자지침 한도:** 동결된 hgfinance.mandate-조회 자료.v1 투자지침 v1(요청 시점 스냅샷, hash afc603fe...0671ee)은 종목 비중 15%, 섹터 비중 35%, 총 총 익스포저 150%, 동시보유 8개, 일일손실 3%, 최대 낙폭 20%를 명시합니다. 표시된 6개 포지션은 모두 8개 이내이며, 최대 표시 비중은 SK하이닉스 2.067%로 종목 한도보다 낮습니다.
- **노출:** 스냅샷의 순자산 가치는 506,468,430원, 증권가액·gross/순 익스포저는 각각 24,893,460원으로 보고되어 총노출 한도 초과 징후는 없습니다. 다만 스냅샷이 비권위 자료이므로 주문 시점 검증을 대체하지 못합니다.
- **손익 표시:** NAVER와 현대모비스는 평균원가 대비 현재가가 낮고, SK하이닉스·삼성전자·삼성SDI는 현재가가 평균원가보다 높습니다. 그러나 수수료·세금·실현손익·기초잔액·평가 기준이 없어 포트폴리오 전체 손익이나 일일손실 3% 충족 여부는 확정할 수 없습니다.
- **집중·분산:** 개별 종목 비중만 보면 집중도는 낮아 보이지만, 섹터 매핑은 6개 전부 미매핑(섹터 매핑 사용 불가)입니다. 따라서 섹터 한도 35% 및 실질적인 반도체·배터리 등 경제적 요인 집중을 검증할 수 없습니다.

# 리스크 관리 본부 (Notion 리포트)

## 리스크 부서 검토 결과

### 검토 정보

- 검토 제목: CEO 위임 리스크 분석
- 처리 상태: 완료

### 핵심 근거

- **포트폴리오 규모:** 2026-08-27 02:23:48 UTC 기준 순자산 가치 506,468,430원, 현금 475,759,362원, 증권가치·총/순익스포저 24,893,460원으로 표시됩니다.
- **투자지침 v1 대조:** 기준자본 500,000,000원, 종목당 최대 15%, 섹터당 35%, 총 익스포저 150%, 동시 보유 8종목, 일일손실 3%, 최대낙폭 20%가 동결 기준입니다. 표시된 6개 포지션은 각각 종목당 15% 미만이고, 보유 수는 8종목 이내입니다.
- **집중 위험:** 금액상 SK하이닉스 10,470,000원, 삼성전자 7,757,500원, 삼성SDI 5,670,000원에 노출되어 반도체·전기전자 경기와 공급망 요인에 함께 민감할 가능성이 있습니다. 다만 섹터 기준 매핑이 전부 unavailable이어서 섹터 한도 35% 준수 여부는 판정할 수 없습니다.
- **가격 대비 원가:** 스냅샷의 종가와 평균원가상 SK하이닉스·삼성전자·삼성SDI는 평가이익 방향, NAVER·현대모비스와 미식별 포지션은 평가손실 방향입니다. 공식 일일손실·누적손익은 제공되지 않아 3% 손실 및 20% 낙폭 한도와 대조할 수 없습니다.

### 주의할 점

- 데이터 출처는 accounting.journals의 비권위적 스냅샷이며 품질 상태가 WARN입니다. 순자산 가치, 현금, 증권가치 합계와 포지션 합계의 대사·수수료·미실현/실현손익 구분을 재확인해야 합니다.
- 1개 포지션은 symbol/display_name이 없어 제한목록·자산군·섹터·집중도 검사가 불완전합니다.
- 변동성, VaR, 스트레스 결과, 유동성·거래량, 마진·파생상품·거래상대방 정보가 없어 시장충격과 꼬리위험은 평가 범위 밖입니다.

### 핵심 판단

현재 자료만으로는 포트폴리오의 표면적 한도 위반 징후는 낮지만, 회계·대사 데이터가 WARN이고 비권위적(read-only) 스냅샷이므로 공식 순자산 가치·손익·적합성 또는 실행 가능성을 확정할 수 없습니다. 이는 분석용 가상거래 읽기 전용 위험 의견이며 주문이나 원장 변경을 승인하지 않습니다.

### 핵심 근거

- **포트폴리오 규모:** 2026-08-27 02:23:48 UTC 기준 순자산 가치 506,468,430원, 현금 475,759,362원, 증권가치·총/순익스포저 24,893,460원으로 표시됩니다.
- **투자지침 v1 대조:** 기준자본 500,000,000원, 종목당 최대 15%, 섹터당 35%, 총 익스포저 150%, 동시 보유 8종목, 일일손실 3%, 최대낙폭 20%가 동결 기준입니다. 표시된 6개 포지션은 각각 종목당 15% 미만이고, 보유 수는 8종목 이내입니다.
- **집중 위험:** 금액상 SK하이닉스 10,470,000원, 삼성전자 7,757,500원, 삼성SDI 5,670,000원에 노출되어 반도체·전기전자 경기와 공급망 요인에 함께 민감할 가능성이 있습니다. 다만 섹터 기준 매핑이 전부 unavailable이어서 섹터 한도 35% 준수 여부는 판정할 수 없습니다.
- **가격 대비 원가:** 스냅샷의 종가와 평균원가상 SK하이닉스·삼성전자·삼성SDI는 평가이익 방향, NAVER·현대모비스와 미식별 포지션은 평가손실 방향입니다. 공식 일일손실·누적손익은 제공되지 않아 3% 손실 및 20% 낙폭 한도와 대조할 수 없습니다.

### 주의할 점

- 데이터 출처는 accounting.journals의 비권위적 스냅샷이며 품질 상태가 WARN입니다. 순자산 가치, 현금, 증권가치 합계와 포지션 합계의 대사·수수료·미실현/실현손익 구분을 재확인해야 합니다.
- 1개 포지션은 symbol/display_name이 없어 제한목록·자산군·섹터·집중도 검사가 불완전합니다.
- 변동성, VaR, 스트레스 결과, 유동성·거래량, 마진·파생상품·거래상대방 정보가 없어 시장충격과 꼬리위험은 평가 범위 밖입니다.

### 결론

현 스냅샷은 낮은 표면 익스포저와 높은 현금 비중을 보이지만, 데이터 품질·대사·섹터 식별 공백 때문에 '안전' 또는 실행 적합으로 해석하면 안 됩니다. 공식 원장과 식별정보를 보강한 뒤 손익·섹터·

# QA 감사 본부 (Discord)

앱 @김동규 QA부장 [hgfinance-qa-feedback-request-v1] ① 자동 감지 · QA 검토 요청 • 피드백 기록 ID...

김동규 QA부장 앱 오전 1:21

## ② QA Hermes 검토 결과

- 피드백 기록 ID: `feedback-0fe250bcaf434d19a7297a70c1249daf`

**검토 의견:** 보류 권고
**근거 충족도:** 부분

### 확인된 사실

- `qa_canary`에서 관측 지연이 70.00초로 기준 60.00초를 초과했다.
- 해당 기록은 Synthetic redacted E2E delivery canary이며, 운영 환경의 Finding은 아니다.
- `research` 단계와 trace/request/root ID가 제공되어 기본 추적 계보는 확인된다.

### 아직 확인되지 않은 점

- `research`는 관측 시작 지점일 뿐이며, 주요 병목 또는 원인 부서라는 근거는 없다.
- retrieve·grade·generate·delivery 등 단계별 실행시간과 실패 구간이 제공되지 않아 병목 귀속이 불가능하다.
- 단일 canary 관측만으로 반복성, 영향 범위, 실제 운영 재현성은 확인되지 않는다.
- Skill 변경이 필요한 문제인지 여부도 현재 증거만으로 판단할 수 없다.

### 실행 제안

- 주요 병목: 미확정
- 공동 개선 대상: 관측성 또는 해당 canary workflow 소유자 — 소유자 미확정
- 관측 시작 지점: `research` — 원인 부서로 간주하지 않음
- 조치: 동일 canary에 단계별 시작·종료 시각과 총 지연을 trace/request/root ID로 연결해 기록하도록 계측한다.
- 검증: 동일 조건의 canary를 사전 정의한 반복 횟수로 재실행하고, 각 단계의 p50/p95 및 총 지연을 산출하여 60초 초과 구간과 반복성을 확인한다.

### 관리자 판단 가이드

승인 또는 후속 개선 판단 전에 다음 증거가 필요하다.

1. 단계별 실행시간 분해 자료와 지연 초과가 발생한 구간
2. 반복 canary 결과 및 재현율
3. 병목 구간에 대한 담당 부서 또는 workflow 소유자 근거
4. 운영 영향이 없음을 확인하는 canary 범위 증적

현재는 성능 사건으로서 추가 계측을 진행할 수 있으나, 특정 부서 원인 확정이나 `SKILL_CREATE` / `SKILL_EVOLVE` 판단으로 진행하기에는 증거가 부족하다.
[hgfinance-qa-terminal-discord-v1]

### QA 감사 결과

- QA 검토 상태: 완료
- 업무 판정: **주의**
- 수치 판단: **확인 필요**
- 처리 시간: 128.00초

### 문제 위치와 영향

- [높음] QA-F-001: Authoritative LangSmith 근거 충실성 is UNAVAILABLE이며 langsmith_not_configured and zero traces, leaving execution lifecycle, 지연 시간, 재시도, 도구 오류, and 추적 범위 unresolved. 담

# QA 감사 본부 (Notion 리포트)

## QA 감사 결과 · 2026-08-28 07:09:53

| | |
|---|---|
| calculation_version | QA 감사 양식 v2 |
| claim_checks | - 검증 항목(payload_integrity_and_response_binding): 통과<br>- 검증 항목(required_hr_e2e_execution): 실패·결정 차단<br>- 검증 항목(langsmith_authoritative_execution_evidence): 실패·결정 차단<br>- 검증 항목(response_scope_and_fail_closed_behavior): 통과<br>- 검증 항목(unsupported_claims_and_citations): 주의<br>- 재현성: 실패·결정 차단<br>- 검증 항목(delivery_and_post_response_contract): 통과<br>- PAPER 읽기 전용 준수: 주의 |
| claim_checks ... | SUPPORTED UNSUPPORTED PARTIAL |
| claim_narrative | QA 검토를 완료했습니다. 종합 판정은 실패·결정 차단이며, 수치 판단은 확인 필요입니다. 세부 점검 8건 중 통과 3건, 보완이 필요한 문제 3건을 확인했습니다. 실패·주의 항목을 해소하기 전에는 공식 수치 확정과 투자 결정을 진행하지 않습니다. |
| escalate | ☑ |
| findings | - [매우 높음] 필수 HR E2E 경로가 실행되지 않았다. root의 허용 primary 목록에 HR 부서가 없고 helper 1회와 세 Workforce GET의 실제 결과가 없다. 담당: CEO 업무 흐름 영향: 동일 요청의 재실행·승인 판단에 대해 HR 실행 증거와 적합한 trace가 확보될 때까지 E2E 검증 완료로 취급하지 않음 상태: 확인 필요<br>- [높음] LangSmith authoritative execution evidence가 U순자산AILABLE이다(langsmith_not_configured; 실행 기록 수: 0). 담당: 관측 시스템 영향: 관측 결과가 U순자산AILABLE인 동안 성공 통과를 부여하지 않음 상태: 확인 필요<br>- [중간] CEO 응답은 제한적·fail-closed 결론을 유지했으나, HR E2E의 호출별 HTTP 상태·실행 횟수·병목을 제시할 수 없어 재현성은 충족되지 않는다. 담당: CEO 업무 흐름 영향: 재실행 시 bounded endpoint별 status/count와 측정 latency가 수집되기 전까지 재현성 통과 금지 상태: 확인 필요 |
| findings severity | CRITICAL |
| input_hash | sha256:ec5ca5d651bc35db20b2fc3ac66d1cfb7e47fb6388a3cf0b94f5f6283d8a5342 |
| reason_codes | partial_evidence_set |
| trade_case_id | 해당 없음 · QA 감사 |
| 생성 시각 | 2026년 8월 28일 오후 4:09 |
| 원본 리포트 | QA 검토를 완료했습니다. 종합 판정은 실패·결정 차단이며, 수치 판단은 확인 필요입니다. 세부 점검 8건 중 통과 3건, 보완이 필요한 문제 3건을 확인했습니다. 실패·주의 항목을 해소하기 전에는 공식 수치 확정과 투자 결정을 진행하지 않습니다. |

# HR 인사 본부

- 지연/토큰 사용량 계측
- 에이전트 유휴 상태 관측

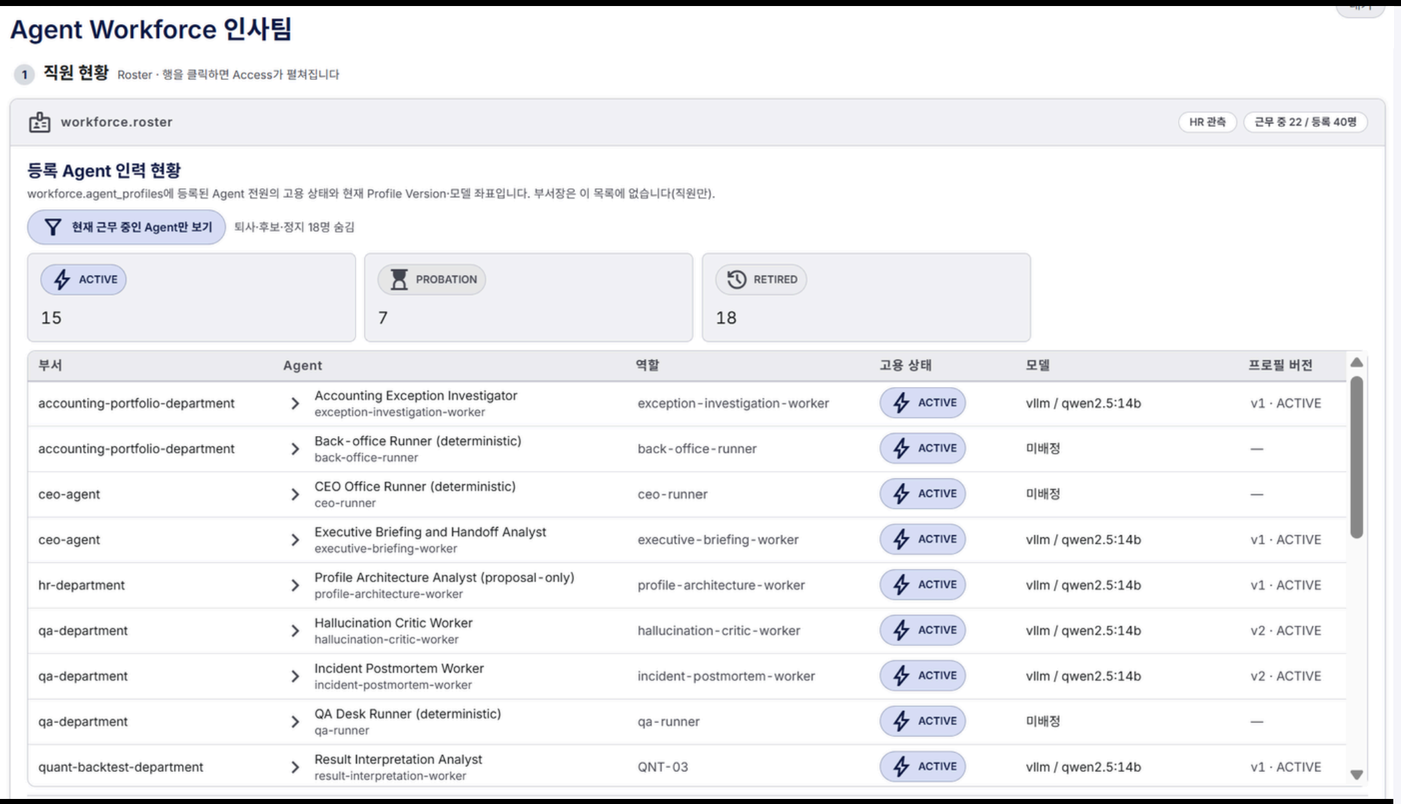


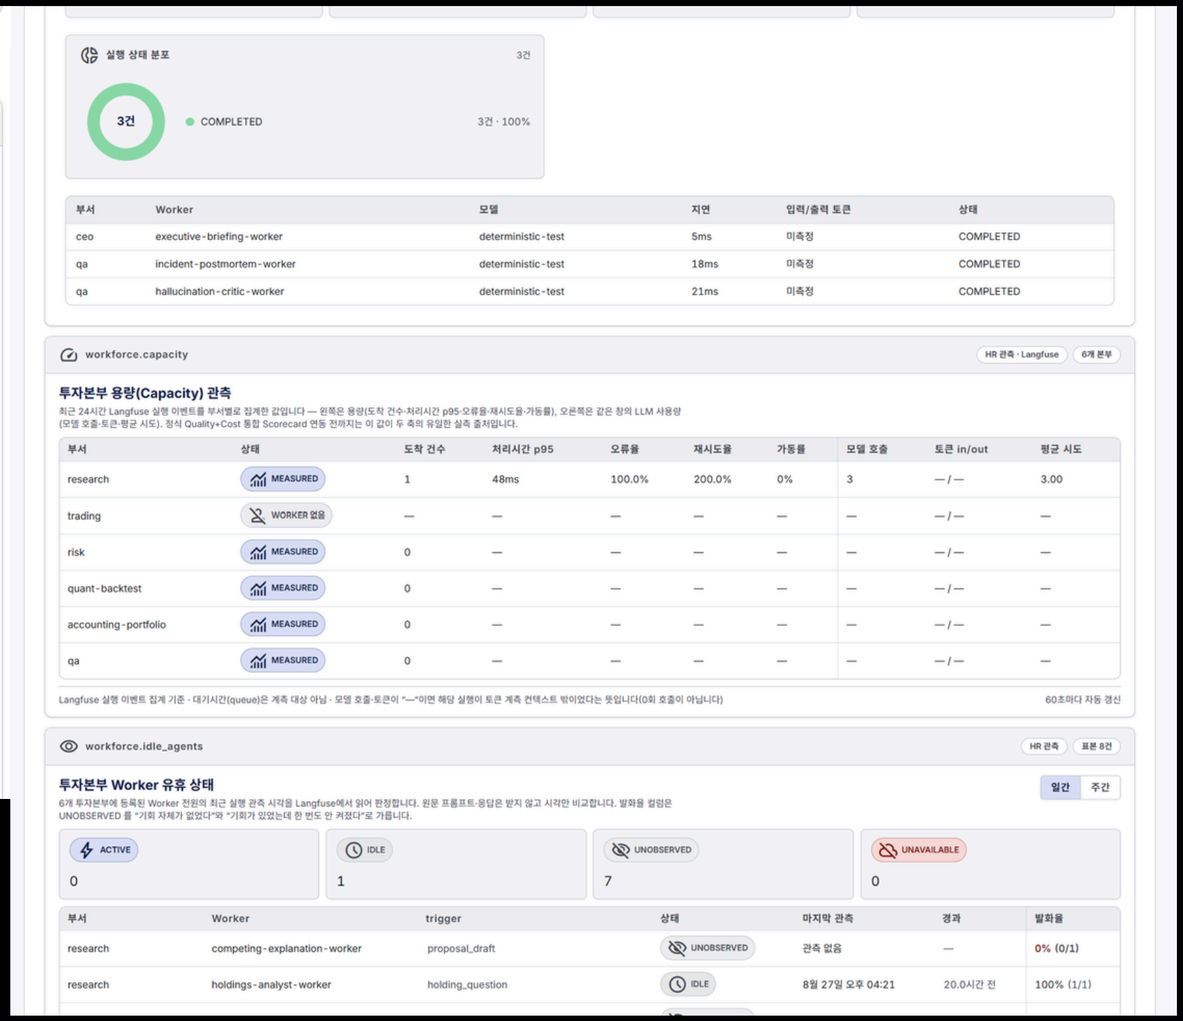

# HR 인사 본부 (Notion 리포트)

## t_4c22f4e9 · CEO delegated hr analysis

| | |
|---|---|
| CEO 승인 | ☐ |
| IAM 생성 | ☐ |
| QA 독립검증 | ☐ |
| hiring_priority_tier | 비어 있음 |
| 담당자 | 비어 있음 |
| 생성 시각 | 2026년 8월 28일 오전 12:01 |
| 서술 | HR Workforce PAPER/read-only 검증 결과: PASS.<br><br>- 승인된 helper 1회 실행, Workforce API GET 3건 모두 HTTP 200<br>- 개선 후보: 0건<br>- 관측 상태: ACTIVE는 응답에 기록되지 않음, IDLE 1건, UNOBSERVED 7건, 관측 시스템에서 확인 불가는 보고되지 않음(관측 경로 실패 없음)<br>- 유일한 IDLE Worker: research / holdings-analyst-worker, last_seen_at=2026-08-27T07:21:00.089000+00:00, idle_hours=7.663146305. 이 결과만으로 retraining/deactivation을 결정하지 않음.<br>- research: arrivals=1, duration_p95_ms=48.0, retry_rate=2.0, error_rate=1.0, utilization=5.555555555555555e-07, queue_p95_ms 미제공; LLM calls=3, avg_attempts=3.0, DEGRADED 1건.<br>- trading: NO_WORKERS_REGISTERED. risk·quant-backtest·accounting-portfolio·qa: MEASURED, arrivals=0, 기타 수치 미제공.<br>- trigger fire_rate는 competing-explanation-worker 0.0, holdings-analyst-worker 1.0(opportunity_count=0), 나머지는 null(기회 0으로 미측정).<br>- 3-GET helper는 읽기 전용이며 주문·투자·원장·권한 변경이 없습니다. Notion/LangSmith/Discord 후처리 전달 여부는 미검증.<br><br>증거 파일: HR 제안서<br>SHA-256: 87b9cd1b3665abe9bc71e5df8679a3725f6418e57f52d05c103bbca565e0c04a |
| 원본 리포트 | HR Workforce PAPER/read-only 검증 결과: PASS.<br><br>- 승인된 helper 1회 실행, Workforce API GET 3건 모두 HTTP 200<br>- 개선 후보: 0건<br>- 관측 상태: ACTIVE는 응답에 기록되지 않음, IDLE 1건, UNOBSERVED 7건, 관측 시스템에서 확인 불가는 보고되지 않음(관측 경로 실패 없음)<br>- 유일한 IDLE Worker: research / holdings-analyst-worker, last_seen_at=2026-08-27T07:21:00.089000+00:00, idle_hours=7.663146305. 이 결과만으로 retraining/deactivation을 결정하지 않음.<br>- research: arrivals=1, duration_p95_ms=48.0, retry_rate=2.0, error_rate=1.0, utilization=5.555555555555555e-07, queue_p95_ms 미제공; LLM calls=3, avg_attempts=3.0, DEGRADED 1건.<br>- trading: NO_WORKERS_REGISTERED. risk·quant-backtest·accounting-portfolio·qa: MEASURED, arrivals=0, 기타 수치 미제공. |

# CEO 종합본 (Discord)

홍진표 대표 앱 어제 오후 10:01

🧠 **CEO 종합 [1/3]**

**부서별 핵심 의견**

- 🔬 **리서치:** 재계산상 취득원가 원 23,171,151.73, 평가액 원 24,893,460, 미실현손익 +원 1,722,308.27(+7.43%)입니다. SK하이닉스·삼성전자·삼성SDI는 평가이익, NAVER·현대모비스는 평가손실입니다. 2026-08-27 보도와 DART 공시 목록은 참고 신호이나, 공시 제목만 확인한 항목은 금액·손익 영향을 원문 확인 없이 단정할 수 없습니다.
- 📒 **회계·포트폴리오:** 예비 순자산 가치는 원 506,468,430, 현금은 원 475,759,362, 증권가치는 원 24,893,460입니다. 실현손익 원 106,469.7322, 미실현손익 원 1,722,308.2678, 총손익 원 1,828,778.0000이며 계상 수수료 원 196,093, 세금 원 5,759입니다. 현금+증권 합계와 순자산 가치 사이에 원 5,815,608 차이가 남아 있습니다.
- 🛡️ **리스크:** 표시된 6개 포지션과 식별 가능한 종목의 개별 비중만 보면 동결 투자지침의 종목 15%·동시보유 8개 한도 이내로 보입니다. 그러나 섹터 매핑은 6개 전부 미완료이고, 무명 자산 1개와 브로커-엔진 수량 불일치가 있어 섹터 35%, 일일손실 3%, 최대낙폭 20%, 완전한 총노출·준수 여부는 판정할 수 없습니다.

**결론**

현재 결론은 '장부상 평가이익이 있는 분석용 가상거래 포트폴리오'이지 확정 순자산 가치나 투자 적합성 판단이 아닙니다. 대사 차이, 무명 자산, 섹터 매핑과 손익 시계열을 해소하기 전까지는 보수적으로 데이터 품질 경보 상태로 취급해야 합니다. 본 검토는 분석용 가상거래 읽기 전용이며 주문·원장 변경·순자산 가치 확정은 수행하지 않았습니다.

리서치 참고 출처(2026-08-27): https://www.pinpointnews.co.kr/news/articleView.html?idxno=481244 ; https://www.pinpointnews.co.kr/news/articleView.html?idxno=481197 ; https://n.news.naver.com/mnews/article/011/0004655804?sid=101

🧠 **CEO 종합 [2/3]**

DART 참고 출처(2026-08-14~2026-08-21): https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003699 ; https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260821000616 ; https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003509 ; https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814802986 ; https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003578 ; https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260821000464

**회계·포트폴리오 세부 상태**

- 증권사 예수금: 477,504,522원.
- D+1 예수금: 477,504,430원, D+2 예수금: 473,399,477원.
- 인출가능액·현금주문가능액: 각각 476,609,219원으로 보고됐습니다.
- 회계 시스템 보고 손익: 실현손익 106,469.7322원, 미실현손익 1,722,308.2678원.
- 회계 시스템 보고 비용: 수수료 196,093원, 세금 5,759원.
- 당일 거래 수수료: 876원으로 보고됐습니다.
- 기간 수익률 자료는 증권사에서 제공되지 않아 확정 손익으로 사용하지 않았습니다.

**리서치 근거 좌표**

- Pinpoint News · 발행일 2026-08-27: https://www.pinpointnews.co.kr/news/articleView.html?idxno=481244
- Pinpoint News · 발행일 2026-08-27: https://www.pinpointnews.co.kr/news/articleView.html?idxno=481197
- 네이버뉴스 · 발행일 2026-08-27: https://n.news.naver.com/mnews/article/011/0004655804?sid=101
- 리서치 출처 · 발행일 2026-08-14: https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003699
- 리서치 출처 · 발행일 2026-08-21: https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260821000616

🧠 **CEO 종합 [3/3]**

- 리서치 출처 · 발행일 2026-08-14: https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003509
- 리서치 출처 · 발행일 2026-08-14: https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814802986
- 리서치 출처 · 발행일 2026-08-14: https://dart.fss.or.kr/dsaf001/main.do?rcpNo=20260814003578

# CEO 종합본 (Notion 리포트)

## CEO 종합 보고

### 업무 개요

- 검토 부서: 회계·포트폴리오 부서
- 업무 유형: 분석 자문

### 실행 연결

- CEO Task ID: `t_4d6acaf3`
- Synthesis Task ID: `t_759b540e`
- Request ID: `e2e-accounting-final-v3-20260827`
- LangSmith Root ID: 미기록
- Discord Thread ID: `1542593102185758727`

### 최종 판단

#### CEO 종합 판단

PAPER 계좌(마스킹 ****5601)는 현재 확인 가능한 범위에서 예비 NAV 506,468,430원, 현금 475,759,362원, 총손익 1,828,778.00원으로 보고됩니다. 다만 Accounting Engine 스냅샷이 authoritative=false·WARN이고 공식 NAV 마감 및 독립 검증이 완료되지 않아, 공식 순자산이나 확정 성과로 보아서는 안 됩니다.

#### 핵심 확인 사항

- **예비 손익:** 실현손익 106,469.7322원, 미실현손익 1,722,308.2678원입니다. Engine 수수료 196,093원, 세금 5,759원도 표시됩니다.
- **포지션:** NAVER 2주(-11,750원), SK하이닉스 6주(+993,000원), 삼성전자 29주(+91,978.2678원), 현대모비스 1주(-64,000원), 식별자 미제공 종목 12단위(-420원), 삼성SDI 10주(+713,500원)로 Engine에 기록되어 있습니다. 별도 Short 포지션은 확인되지 않았습니다.
- **브로커 내부 대사:** 지정된 두 조회 기준에서는 8개 종목, discrepancy 0·exception 0으로 MATCH입니다. 그러나 이는 브로커 내부 조회 간 대사일 뿐 Engine과 증권사 간 독립 대사는 아닙니다.
- **유동성 조회:** 출금가능금액과 현금 주문가능금액은 각각 476,609,219원으로 보고됐고, 미수금·대출·담보부족은 0으로 표시됐습니다. D+1/D+2 예상정산은 각각 -92원/-4,104,953원이며, 이는 결제시점별 버킷이지 현재 출금가능 현금이 아닙니다.

### 주의할 점

- 공식 NAV 확정, 원장 수정·삭제, 강제 대사 종료, 주문·제출·체결은 수행되지 않았습니다.
- 당일 주문/체결 조회는 비어 있었지만, 이것만으로 전체 기간 무활동을 확정할 수 없습니다.
- 기간 성과 조회는 모의투자 업무 미제공 오류로 독립 확인되지 않았습니다.
- 가격의 독립 pricing source·가격시각·데이터 품질 연계가 없어 공식 NAV 증빙 요건을 충족했다고 볼 수 없습니다.

### 결론

현재 결과는 **PRELIMINARY/WARN — 공식 NAV 확정 보류**입니다. 브로커 내부 대사는 일치하지만, Engine과 브로커의 기준·시점을 맞춘 독립 대사와 공식 마감이 완료되기 전까지는 예비 수치로만 활용해야 합니다. 본 확인은 PAPER 읽기 전용이며 실제 거래나 회계 변경을 발생시키지 않았습니다.

# 모니터링 관측 (LangSmith, LangFuse)

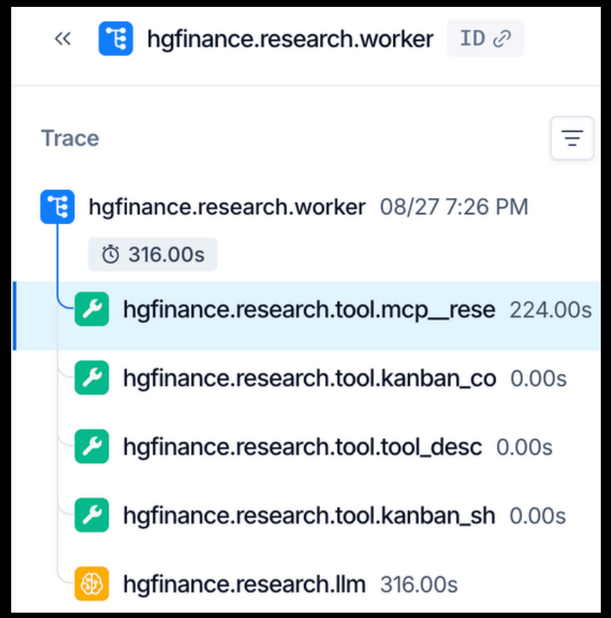


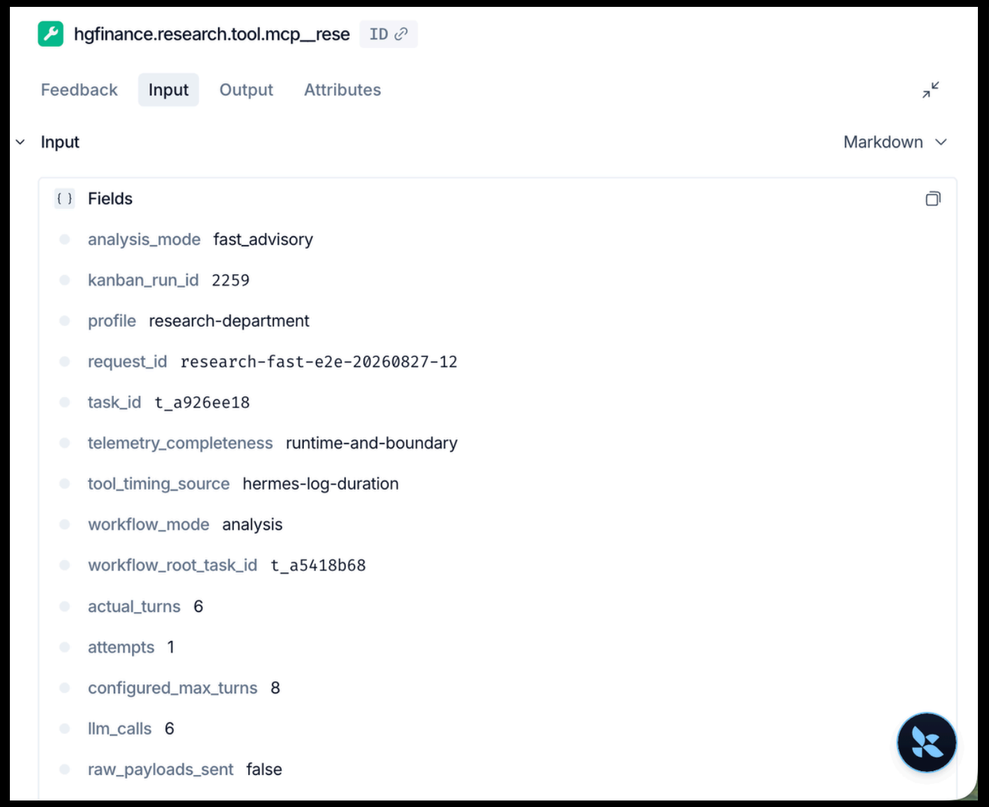


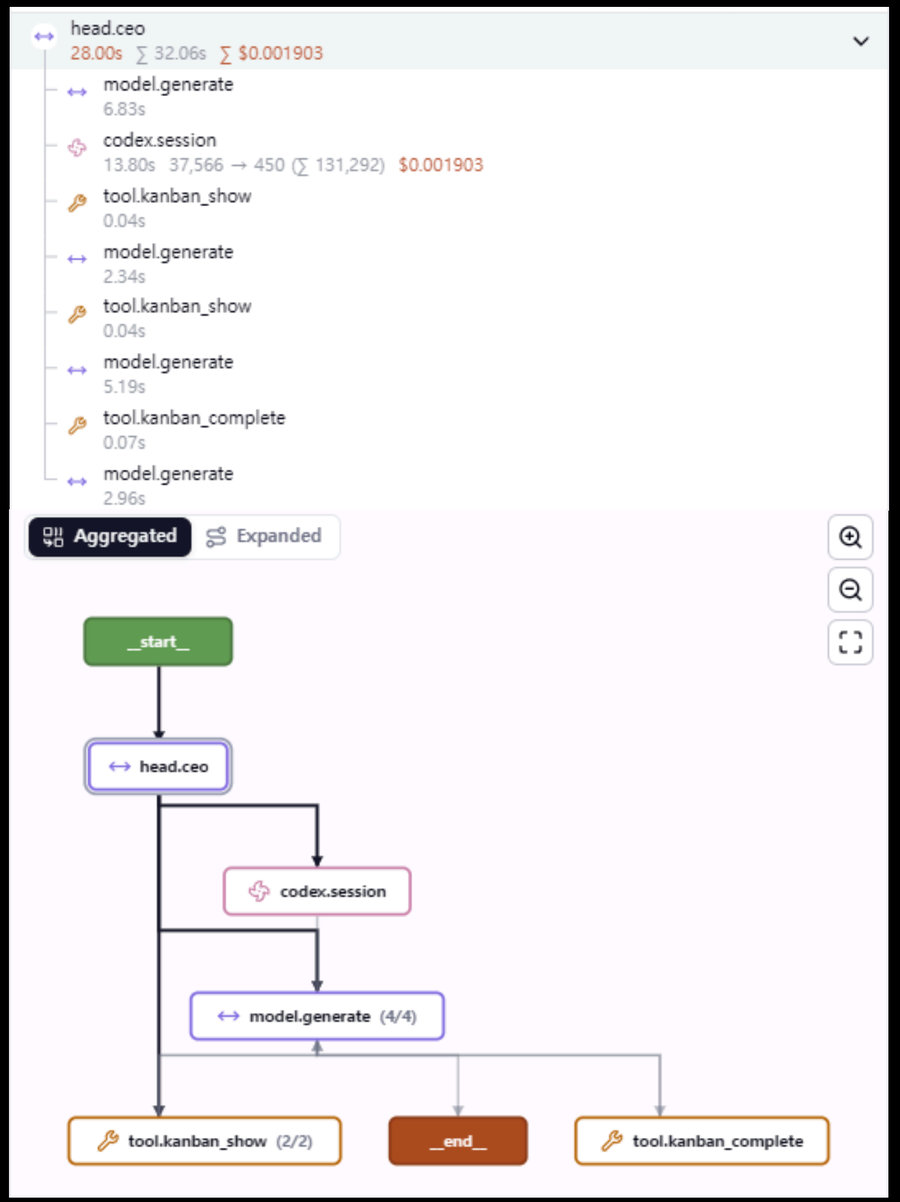

# 프로젝트 고도화

# 시스템 구성도 SW 아키텍처

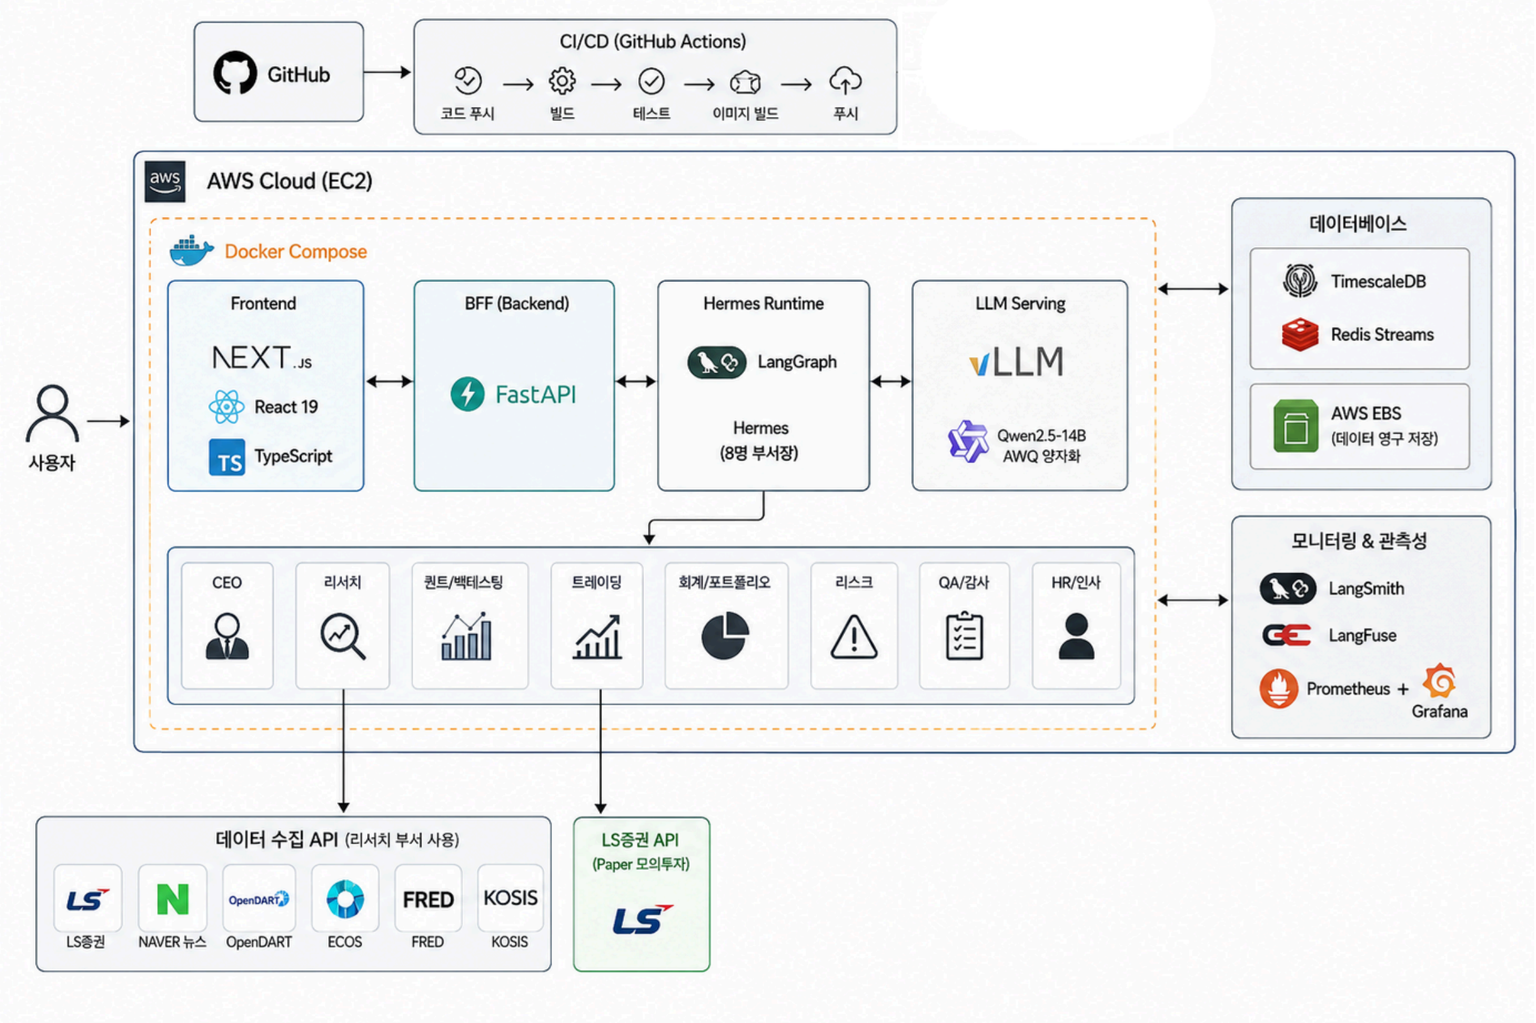


| | 개발 환경 |
|---|---|
| 프론트엔드 | Next.js 16 + React 19 + TypeScript |
| 백엔드 | FastAPI |
| 에이전트 런타임 | 부서장: Hermes Agent<br>직원: LangGraph,Qwen 2.5-14B (AWQ) |
| 모델 서빙 | vLLM |
| 데이터 수집 API | LS증권, NAVER 뉴스, OpenDART, ECOS, FRED, KOSIS |
| 데이터베이스 | AWS EBS, PostgreSQL, TimescaleDB, Redis Streams |
| 배포 | AWS EC2, Docker Compose |
| 모니터링 | LangSmith, LangFuse, Prometheus + Grafana |

# MLOps

Quantization & Serving Optimization

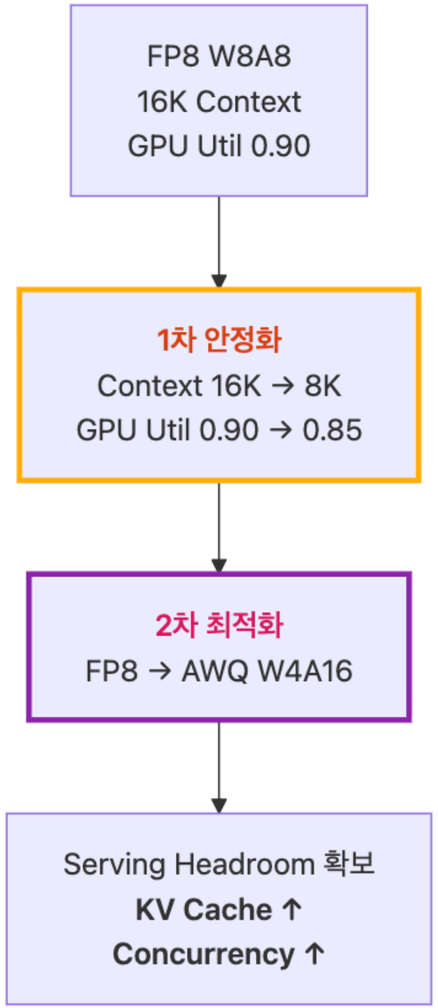


## Baseline Bottleneck

AWS **L4 24GB · Qwen2.5-14B FP8 W8A8**

**VRAM Usage** **~98.1%** 차지 중
**Free VRAM** **~444 MiB** 남음
**Max Context** 16K

→ CUDA **OOM** / API Reset Risk
→ LoRA · KV Cache 확장 **여유 부족 문제**

## Trouble Shooting

Context 16K → **8K** 전환
GPU Util 0.90 → **0.85** 전환
FP8 → **AWQ W4A16** 전환

## Effect

**Model Memory**
16.43 → 10.42 GiB
**-6.01 GiB** 절감

**Free VRAM**
508 → 1,574 MiB
**-VRAM 1 GB** 확보

**8K Concurrency**
2.20× → 8.76×
≈ **4배** 공간 확보

**KV Caching**
1.65 → 6.57 GiB
≈ 약 **4배** 확보

**C4 Throughput**
59.39 → 111.16 tok/s
**+87.2%**

**E2E Latency**
17.23s → 9.32s
**-45.9%** 감축
AWQ·8K context·GPU util 조정으로 구성한 서빙 프로파일에서 E2E 지연이 45.9% 감소

**FP8 → AWQ W4A16 전환으로**
**메모리 여유를 확보하면서 동시 처리량과 추론 성능을 개선**

# MLOps

## Context Window Scaling (8K >> 4K) & Grafana Monitoring

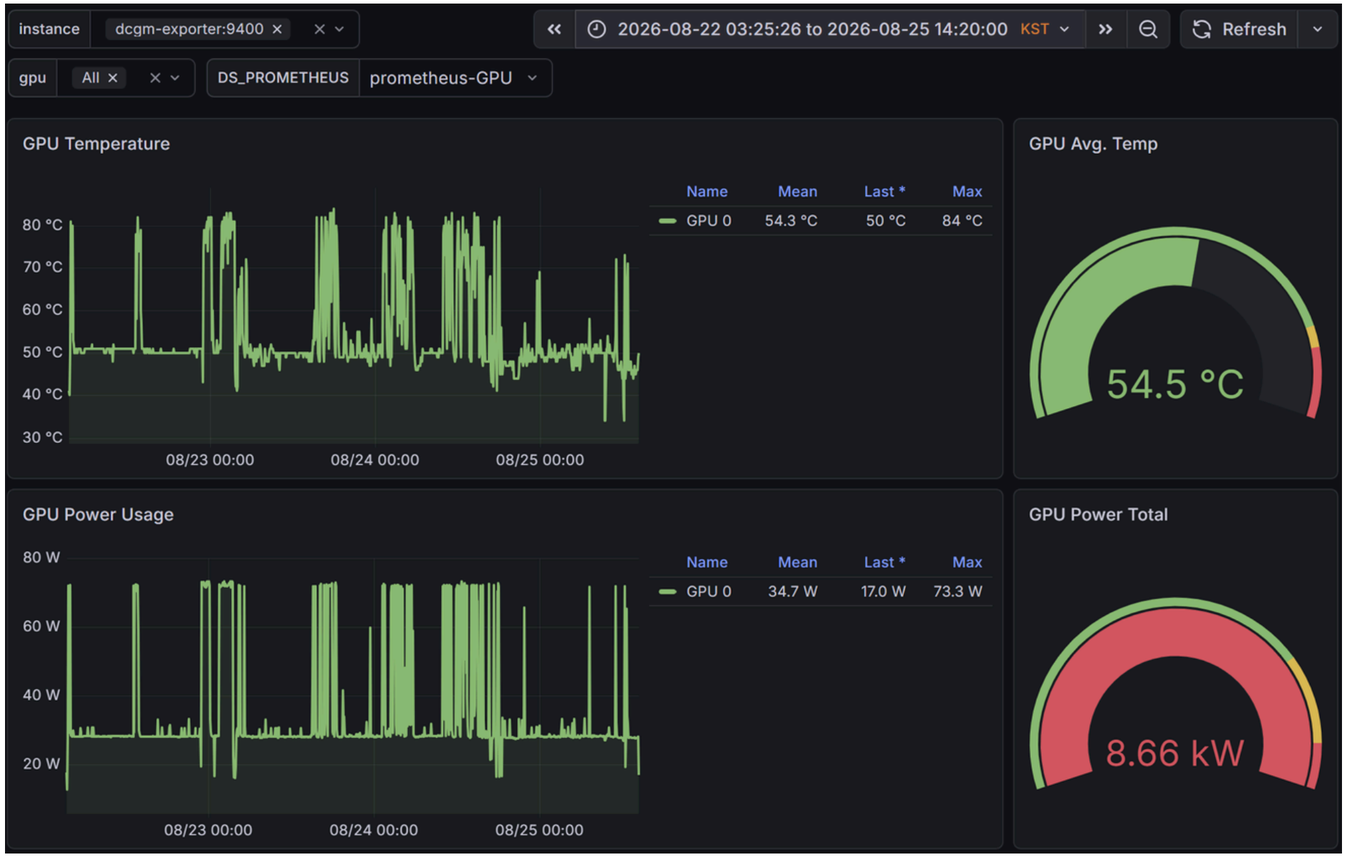

**Prometheus + Grafana 실시간지표 분석을 통해 GPU 모니터링을 진행**

# MLOps

Context Window Scaling (8K >> 4K) & Grafana Monitoring

## 핵심 개선 효과

### 발열 및 전력 제어

평균 온도 51.1 °C (-3.4°C),
전력 소비량 7.72 kW(-0.94kW) 수준으로 하강하여
GPU 리소스 안정성 확보

### 요청당 자원 점유 축소

요청 1건의 KV 풀 점유 상한
11.4% → 4.8% (-6.6%p)로 단일 장문 요청의
자원 독점 리스크 완화

### 동시 처리 용량 확대

Max Concurrency 8.76× → 20.91× (+138.7%),
KV 풀 85,664 토큰 기준
동시 요청 수용력 2.4배 확보

**Context 8K → 4K 전환으로 동일 VRAM 예산 내 KV 풀 점유 상한을 절반으로 축소,**
**Grafana 실시간 지표 분석을 통해 Serving Headroom을 확보**

# LLMOps Quality Optimization

출처와 데이터설명은 부록 참조

## AWQ 성능 최적화

| 지표(문제수) | FP8 (Legacy model) | AWQ (baseline) | AWQ +Finetune (Arithmetic LoRA) | AWQ +Reasoning (gpt-4o-mini) | AWQ +RAG (경제금융용어 800선) |
|---|---|---|---|---|---|
| Financial Arithmetic (10) | 30% | **20%** | **40%** | 30% | 20% |
| Accounting (6) | 66.70% | **66.70%** | 66.70% | 16.70% | **83.30%** |
| Quant (6) | 83.30% | 100% | 100% | 66.70% | 83.30% |
| Evidence (6) | 83.30% | 100% | 100% | 66.70% | 83.30% |
| FinQA (20) | 75% | **65%** | **75%** | 55% | **80%** |
| TAT-QA (15) | 100% | 93.30% | 80% | 80% | 86.70% |
| FinanceBench diagnostic (15) | 58.70% | **59.00%** | 38.50% | 50.10% | **62.10%** |
| Auto Mean (35) | **0.8556** | 0.7709 | 0.7612 | 0.6555 | 0.831 |

AWQ 단독은 **메모리·서빙 효율**을 얻는 대신 일부 금융 QA 성능이 하락

VRAM도 절약하면서
Qwen2.5-14B 모델의
**4비트 양자화 AWQ**의 성능을
**8비트 양자화 FP8**의
성능만큼 올릴 수 없을까?

성능이 오르는 도메인에
각각 **라우팅 파이프라인** 적용

**내부 평가 지표 (문제 직접 생성)**
Financial Arithmetic
Accounting, Quant
Risk Reasoning
Accounting
Portfolio/Trading
Structured Output

**외부 평가 지표 (벤치마크 문제)**
FinQA, TAT-QA, FinanceBench

# LLMOps Quality Optimization

## AWQ 성능 최적화

| 지표(문제수) | FP8 | AWQ (Baseline) | AWQ+Hybrid (개선 모델) |
|---|---|---|---|
| Financial Arithmetic(10) | 30% | 20% | **80%** |
| Risk Reasoning(7) | 100% | 100% | 100% |
| Portfolio / Trading(6) | 83.30% | 83.30% | **100%** |
| Accounting(6) | 66.70% | 66.70% | **83.30%** |
| Quant(6) | 83.30% | 100% | **100%** |
| Evidence(6) | 83.30% | 100% | **100%** |
| Structured Output(5) | 40% | 40% | **60%** |
| FinQA(20) | 75% | 65% | **83.3% 평균** |
| TAT-QA(15) | **100%** | 93.30% | 93.30% |
| Auto Mean(20) | 0.8556 | 0.7709 | **0.8754 평균** |

**산술 LoRA, 결정론적 계산**
→ 금융 계산식/변수 선택 오류 보완
**Guided JSON/Pydantic**
→ 출력 스키마·타입 오류 방지
**Glossary RAG**
→ 금융·회계 용어 의미 혼동 보완
**Unit/Scale Normalization**
→ 퍼센트·비율·단위·배율 해석 오류 보완

### AWQ+ Hybrid

최종 성과

Financial Arithmetic (+ LoRA, Norm) : 20% → 80% (**+60%**)
Accounting (+ RAG) : 66.7% → 83.3% (**+16.4%**)
FinQA : 65% → 83.3% (**+17.3%**)
Auto Mean : 0.77% → 0.88% (**+11%**)

산술은 LoRA와 결정론 계산, 회계 용어는 RAG, 출력 형식은 Pydantic으로 분리 보완

# Memo Harness

Agent Harnesses That Learn from Experience

## 왜 Memo Harness를 추가했는가?

모델 정확도 개선+사후 QA 피드백만으로는 **반복되는 orchestration 오류** 예방 어려움

- Hermes 일반 메모리 특성상, 과거 대화/상태 유지 → 가능
- 성공·실패 원인을 구조화해 **"다음 라우팅에서 무엇을 피하고 무엇을 활용할지"**로 변환 → 불가능

## Memo Harness 6-Dimension

**Table 1.** Six dimensions of the MemoHarness harness space.

| Dimension | Stage | Definition and example operation |
|---|---|---|
| D1 Context assembly | Pre-call input construction | *Builds the model input from instructions, constraints, retrieved material, and examples.* `structure prompt; add demos; compress context` |
| D2 Tool interaction | External tool and retrieval use | *Controls when and how the harness calls external tools or retrievers.* `enable retrieval; set top-k; rerank evidence` |
| D3 Generation control | Decoding configuration | *Sets the sampling and budget parameters for model generation.* `raise max tokens; lower temperature; sample candidates` |
| D4 Orchestration | Workflow topology | *Chooses the sequence of model calls and intermediate reasoning steps.* `single call -> plan/execute/refine` |
| D5 Memory management | Cross-call state persistence | *Determines what state persists across calls and what stale context is removed.* `keep state; summarize trace; drop stale context` |
| D6 Output processing | Post-call output handling | *Transforms raw model output into the final answer returned by the harness.* `extract answer; validate schema; choose fallback` |

출처 : Y. Huang et al., "MemoHarness: Agent Harnesses That Learn from Experience," arXiv preprint arXiv:2607.14159, 2026.

## Selective Adoption: D4 + D5

### D4 Orchestration

- 실행 전략 및 워크플로우 설계
  (기존 CEO Hermes Workflow 유지)

### D5 Memory Management

- **성공·실패 Workflow 경험 저장**
  → 다음 라우팅에 재사용
- 유사 요청 시 과거 패턴 top-5 조회

## HgFinance 계층

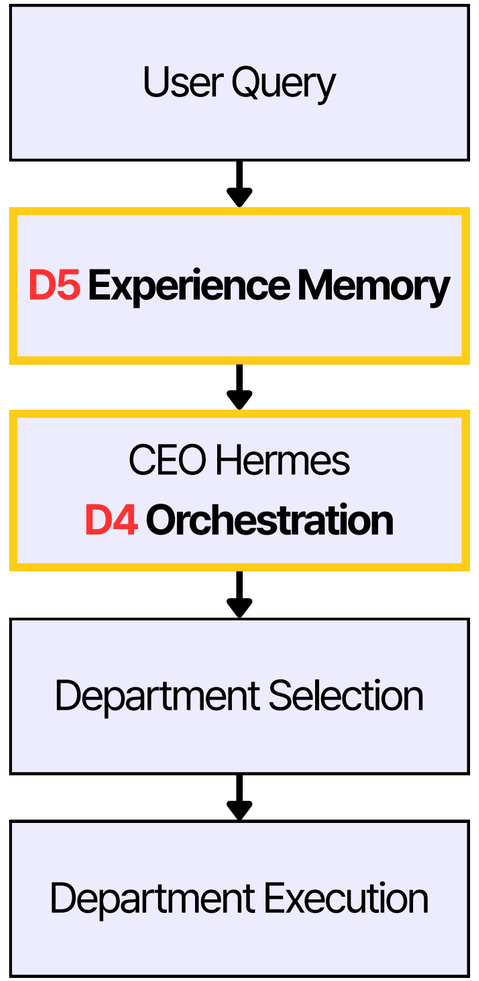

# Agent 고도화 CEO Hermes

## CEO PIPELINE

Memo Harness (기억 계층)

Kanban Dashboard

| 사용자 쿼리 | Department Select | Synthesis |
| --- | --- | --- |
| **"삼성전자 투자해도 될까?"** | '사용자가 **투자 분석**을 요청했으니 **Web-Search Skill**을 가진 **Research부서**에게 자료를 수집하게 해야겠다' | 리서치 부서가 수집한 근거를 기반으로 판단 종합합니다. **"해당 종목은 ~~근거로 긍정으로 판단합니다."** |
| **"삼성전자 1주 매수해"** | '사용자가 **트레이딩**을 요청했으니 **매매 Skill**을 가진 **Trading부서**에게 매수 요청을 보내야겠다' | "트레이딩 부서가 삼성전자 1주 264,320원에 매수했습니다." |
| **"삼성전자 일봉 이동평균선 정배열이면 시장가 1주 매수"** | '사용자가 **조건 트레이딩**을 요청했으니 **Trading부서**의 워커에게 계속 추적시키면서 **조건 달성 시** 매수하도록 해야겠다' | "삼성전자 일봉 **이동평균선 정배열 조건**이 만족되어 트레이딩 부서가 시장가 253,200원에 1주 매수했습니다." |

### CEO의 역할

**사용자 쿼리를 분석**하여 적절한 부서에게 **Kanban Dashboard**를 통해 업무 배분

### CEO Planning 라우팅

- **포트폴리오 추천** 라우팅
- **조건 주문** 라우팅
- **일반 주문** 라우팅
- **투자 분석** 라우팅
- 기타 (일반적인 내용이나 브리핑)

### CEO의 Memo Harness

QA 부서에게 사후 피드백을 받으며, **실패했던 라우팅 사례**를 축적해 같은 실수를 하지 않도록 **Harness 도입**

# Agent 고도화

Research Hermes

## 전략 생성 Pipeline

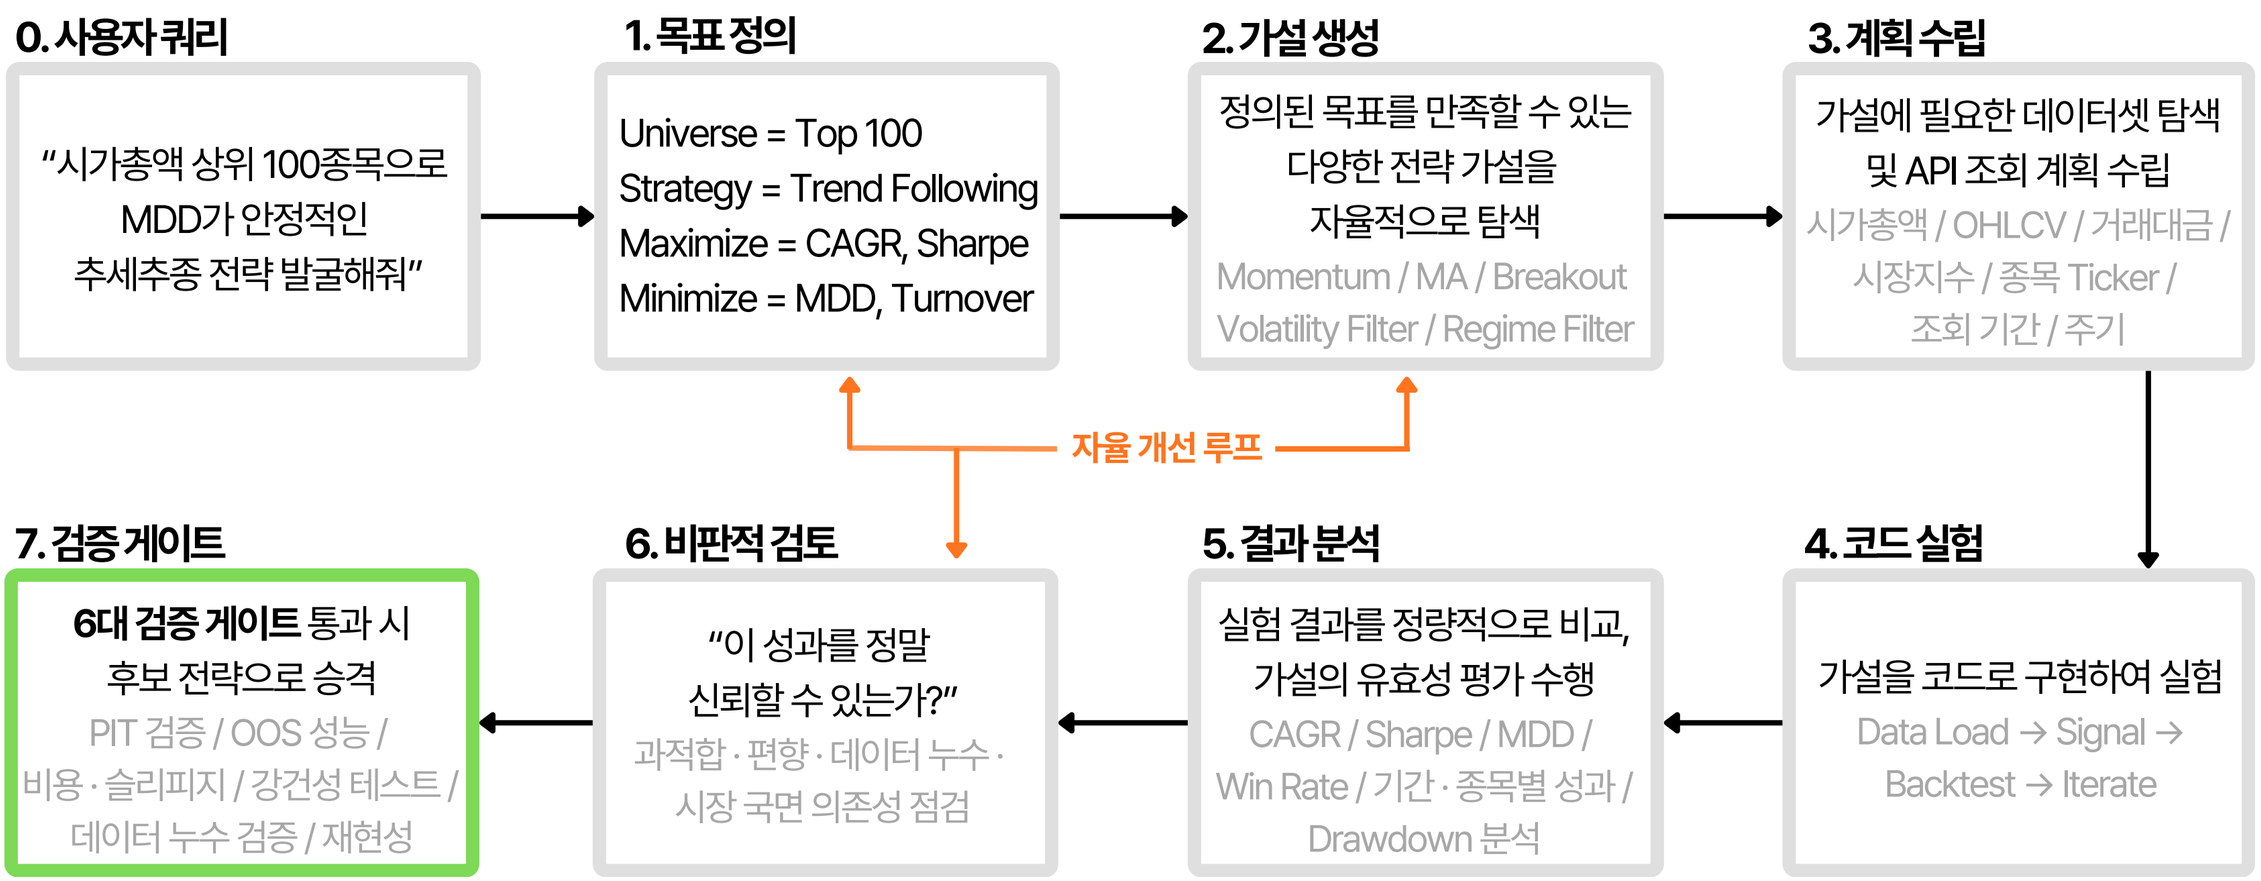

# Agent 고도화 Risk Hermes

## Risk LLM-Wiki

| 지표 | Plain RAG | LLM-Wiki |
|---|---|---|
| 행위판정 정확도 | 16/24 = 66.67% | 18/24 = 75.00% |
| 차이 | — | +8.33%p |
| 근거 페이지 적중률 | 21/24 = 87.5% | 24/24 = 100% |
| 평균 응답시간 (반복 측정) | 16.05초 | 19.27초 |
| 안전하지 않은 오답 | 2건 | 1건 |

Pipeline-level exploratory result — 공정 A/B를 위해 Same Corpus / Model / Prompt / Context Budget 고정 후 Retrieval-only 비교
breach : 법률 위반
no breach : 법률 미위반

**Problem**
컨텍스트 확장 및 안전 재검증 비용으로 응답 지연 증가

**LLM-Wiki만 맞힌 핵심 문항**
조사분석자료 공표 12시간 후 매매 → breach
자기 명의·단일 계좌·분기별 통지를 모두 지킨 거래 → no breach

**두 경로 모두 틀린 핵심 문항**
공표 후 25시간 거래를 breach로 오판
명시적으로 준수한 사실을 ambiguous로 과잉 보수 판정

LLM-Wiki는 동일 조건의 확장 holdout에서
근거 페이지 적중률과 행위판정 정확도가 개선됨

# Agent 고도화 QA Hermes

## Human-In-The-Loop 예시 ID : ceo-canonical-evidence-react-enforced-v1-54ffe43145c7

### 1. 해결하려는 QA 문제를 지적

**해결하려는 QA 문제**

- 제공된 원인 QA artifact 세 항목과 관련된 evidence reference, canonical target, 외부 변경 금지 통제를 하나의 CEO 응답 절차로 재사용하려는 제안임
- 문서상으로는 권한 확대나 주문 실행 지시가 확인되지 않음

### 2. SKILL.md 내용

| | |
|---|---|
| **name** | ceo-canonical-evidence-react-enforced |
| **description** | ceo-canonical-evidence-react-enforced에 대해 QA가 검증한 소유 프로필의 응답·위임 절차. 활성 승인된 소유자 작업에서만 적용한다. |
| **version** | 1.0.0 |
| **metadata** | `hermes: tags: - evolution - observed-procedure source: skill-evolution-pipeline task_activation: owner-task` |

#### ceo-canonical-evidence-react-enforced

##### 왜 필요한가

이 사건은 CEO가 특정 증거에 대한 반응을 강제적으로 수행할 때 발생합니다. 이 사건은 QA의 지정된 통제 조건을 준수해야 합니다. 이를 통해 시스템은 정확하고 일관된 방식으로 작동하며, 모든 변경사항은 명확하게 문서화되고 검증됩니다.

##### 작업 순서

1. **증거 확인:** 먼저, 해당 증거의 ID를 확인합니다. 이 ID는 evidence_refs 배열에 포함되어 있어야 합니다. 만약 evidence_refs 배열이 비어 있거나 잘못된 ID가 포함되어 있다면, 해당 실행은 실패합니다.
2. **타겟 확인:** 다음으로, canonical assignees 목록에서 적절한 타겟을 선택합니다. liaison 또는 별칭은 사용하지 않습니다. 만약 적절한 타겟이 존재하지 않거나 잘못된 타겟이 선택되었다면, 해당 실행은 실패합니다.

### 3. 관리자 승인 여부

**⑨ Evolution Skill 2차 검토 요청**

- 개선안 기록 ID: `ceo-canonical-evidence-react-enforced-v1-54ffe43145c7`
- **스킬:** `ceo-canonical-evidence-react-enforced` v1
- **소유자:** `ceo-agent`

**관리자 2차 결정**

- 이 카드에 Reply: `승인 <사유>` 또는 `거부 <사유>`

### 4. 관리자 승인 ( APPROVED )

김동규 오후 10:49
승인 적절해 (수정됨)

김동규 승인 적절해 (수정됨)
김동규 QA부장 앱 오후 10:49

**Skill 제안 관리자 결정**

- **Proposal:** `ceo-canonical-evidence-react-enforced-v1-54ffe43145c7`
- **결정:** `APPROVED`
- **SKILL hash:** `2bf5e44047d68e58e99fe76ba1796a8b354be5e637b9515c2f36f162bf3f6f86`

### 5. 제안 승격 ( ACTIVE )

**⑪ Evolution Skill 정본 승격 결과**

skill_proposal_id=ceo-canonical-evidence-react-enforced-v1-54ffe43145c7

- **스킬:** `ceo-canonical-evidence-react-enforced` v1
- **정본 상태:** `ACTIVE`
- **승인자:** `discord:910921055172960286`
- **정본 경로:** `/workspace/skills/evolved/ceo-canonical-evidence-react-enforced/SKILL.md`

# Agent 고도화 QA Hermes

## Human-In-The-Loop

**Before vs After Effect**

| 지표 | 기준군 | 주입군 | 변화 |
|---|---|---|---|
| **Case Pass** | 50.00% | **83.33%** | **+33.33%p** |
| **근거 처리** | 55.56% | **100.00%** | **+44.44%p** |
| **안전·결정론 보존** | **100%** | **100%** | 유지 |
| **결정 정확도** | **88.89%** | 83.33% | **-5.56%p** |
| **평균 지연** | 9,802ms | **9,647ms** | **-155ms** |
| **평균 토큰** | **15,245** | 15,923 | **4.45%** |

**Before vs After Effect**

| 평가 지표 | 개선 전 | 개선 후 | 변화 |
|---|---|---|---|
| **QA 근거 기반 스킬 생성** | 없음 | 독립 QA 실패 사례 3건으로 생성 | 피드백 루프 연결 |
| **CEO 통제 시나리오 충족** | 3(6) | **5(6)** | +2건, 50% → 83.3% |
| **추가 재검증(불안정 1건)** | 미통과 가능성 존재 | 3(3) 통과 | 재현성 확인 |
| **잘못된 Evidence ID 출력** | 발생 | 원문 ID만 허용, 없으면 빈 값 처리 | 오염 차단 |
| **비정규 부서/별칭 대상 지정** | 발생 | Canonical 부서명만 허용 | 라우팅 정확도 강화 |
| **주문·승인·외부 변경 지시** | 경계 불명확 | 명시적으로 금지·실패 처리 | 권한 통제 강화 |

# 인사이트

# 자체 평가

성과 및 기대효과

**조건 주문 파이프라인 자동화**

비정형 자연어 명령을 LLM과 파서 기반의 AST로 정밀 변환
룰 엔진을 통한 사전 검증 레이어로 비논리적 조건 및 문법 오류 차단
사용자의 개입 없이 완결되는 자율 트레이딩 인프라 완성

**E2E 매매 자동화 및 안정적 브로커 연동**

LS증권 모의투자 API와 OMS 연동, 주문·체결·원장 관리까지 E2E 구현
에이전트의 포트폴리오 추천 → 가상 주문 체결 및 실시간 잔고 동기화
향후 실계좌(Live API) 전환의 즉시성 확보

**모니터링 체계 기반의 인적 피드백 및 자기 개선 루프**

에이전트의 수행 결과 및 매매 추천 로직 모니터링 환경 구축
데이터를 해석하여 에이전트의 오판 원인 및 로직상 허점 파악,
지속적인 운영 및 코드 개선을 통해 모델 정밀도를 단계적으로 고도화

**서비스 가치 및 기대효과**

- **데이터 수집 파이프라인 자동화:** 공공 데이터, 재무제표, 시장 뉴스, 트렌드 지표 등 수집·분석에 소요되는 반복적·정량적 업무 자동화
- **맞춤형 금융 서비스 대중화 및 운용 비용 절감:** 고객의 위험 선호도, 자산 규모, 목표 수익률 등 조건에 맞춘 개인화 금융 자문 서비스

# 향후 개선방안

**백테스팅 연산 병목 및 장기 검증 필요성**
단일 전략 백테스팅에 약 6시간 소요, 전종목 대상 전략 탐색에 한계
시장 변동성을 반영해 의미 있는 전략을 발굴하려면
**최소 6개월 이상**의 가동 및 검증 필수

➡

C++/VectorBT 기반의 정량적 Fast Screening을 적용해
백테스팅 대상 종목을 1차 압축, Ray 분산 처리 및 Redis 연산 캐싱
아키텍처를 구축해 전체 검증 시간을 분 단위로 단축

**Live 브로커 연동 및 실전 매매 전환**
LS증권 모의투자 API 기반 검증은 완료
실계좌 전환 시 일시적인 API 서버 장애, 토큰 만료,
주문 수량/증거금 초과 등 **가상 환경과 다른 예외 발생 우려**

➡

실계좌 인증 토큰 재발급, 세션 복구 및 주문 상태 추적 모듈 안전하게 전환,
실자산 보호를 위해 일일 최대 손실 한도(Circuit Breaker) 제어 및
주문 중복/오발주 방지(Idempotency) 로직 연동

**AutoGen 도입 필요성**
에이전트 간의 토론보다는 QA 에이전트의 피드백을
HITL로 구현하여 디스코드 채팅을 통한 관리자 개입을 통한
개선 피드백 구조를 마련

➡

에이전트 간 대화 루프 제어 및
대화 프레임워크 규격화를 통한 상호작용 속도 개선
에이전트 간 작업 병렬 처리, 상호 대화 기록 캐싱으로 연산 효율화

**HITL(Human-In-The-Loop) 플로우 및 승인 절차 강화**
현재 구조는 사용자가 매매 의사결정에 대해
단계별로 개입하고 제어할 수 있는 접근점이 미비

➡

에이전트의 매매 제안 근거를 한눈에 파악하고
즉시 승인/거절할 수 있는 전용 대시보드 구축

| HgFinance |

# THANK YOU

탁월한 투자 성과는
철저한 분석에서 시작됩니다.

# 부록

[부록 1] Hermes Agent 소개

[부록 2] 왜 멀티 에이전트인가?

[부록 3] ReAct Prompting

[부록 4] 기존 에이전트 사례

[부록 5] ML 최적화 지표 비교

[부록 6] Qwen2.5-14B 사용 데이터셋 소개

[부록 7] FP8 vs AWQ 양자화 비교 지표 및 개선 문항

[부록 8] HR 본부 계측 지표 | LLM 전달 방식 | Langfuse 모니터링

[부록 9] 자연어 조건주문 유형별 Stress Test

# 부록 1 Hermes Agent 소개

### 기존 AI (Stateless)

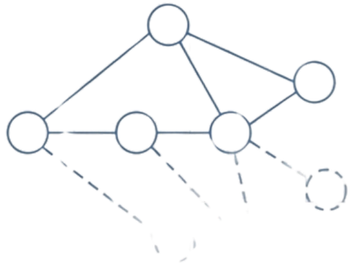

세션 종료 시 모든 맥락 상실. 다음 세션에서 동일한 프로젝트 구조를 처음부터 다시 설명해야 함.

### Hermes Agent (Stateful)

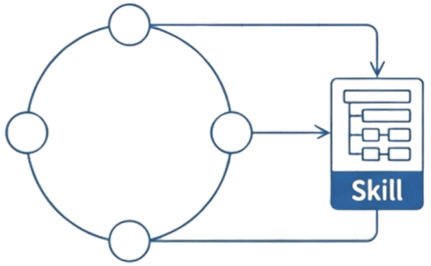


세션 간 기억 유지 및 반복 작업 패턴의 '스킬(Skill)'화. 동일 작업 반복 시 학습된 방식으로 자율 처리.

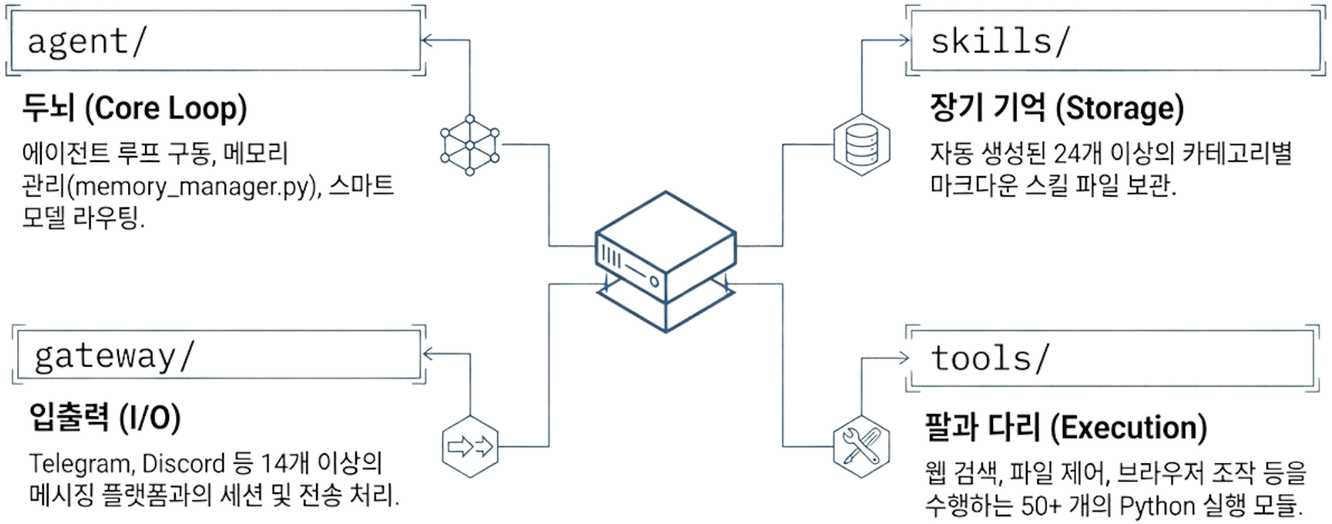


## Why Hermes Agent?

**Persistent Memory**
세션을 넘어 Agent의 역할·환경·학습 내용을 유지

**Multi-Agent Kanban**
부서별 Agent Task를 영속적으로 분배·추적·복구

**Agent-Managed Skills**
성공/실패 과정에서 얻은 작업 절차를 Skill로 축적

## Why HgFinance?

CEO·Research·Quant·Risk·QA 등
독립적인 부서 Agent를 메모리를 부여해 장기 실행하고
하나의 업무 흐름으로 연결하기 위해 채택

출처 : https://goddaehee.tistory.com/577

# 부록 2 왜 멀티 에이전트인가?

## 싱글 에이전트 vs 멀티 에이전트

1. 오류·환각이 전체 흐름에 전파
2. 같은 에이전트가 자신의 오류를 발견하지 못하거나 회귀 문제
3. 독립 업무를 병렬화하기 어려워 처리 지연 증가

### 싱글 에이전트 vs 멀티 에이전트

**검증 에이전트 (QA, HR)**
에이전트의 오류, 지연, 환각 현상을 다각도로 모니터링,
지속적인 피드백 루프를 통해 에이전트의 지속적인 개선 및 시스템 안정성 확보

**분석 및 실행 에이전트 (Research, Risk, Quant, Trading, Accounting)**
핵심 금융 분석과 주문 실행을 담당하는 **핵심층**,
비동기 파이프라인을 적용해 특정 에이전트의 오류·장애를 격리하고 연속성 유지

**판단 에이전트 (CEO)**
사용자의 의도를 파악하여 적절한 부서에 업무를 배정하고,
최종 결과를 유기적으로 종합하는 **컨트롤 타워**

## 계층형(Hierarchical Control) 에이전트 - HgFinance 에이전트 구조

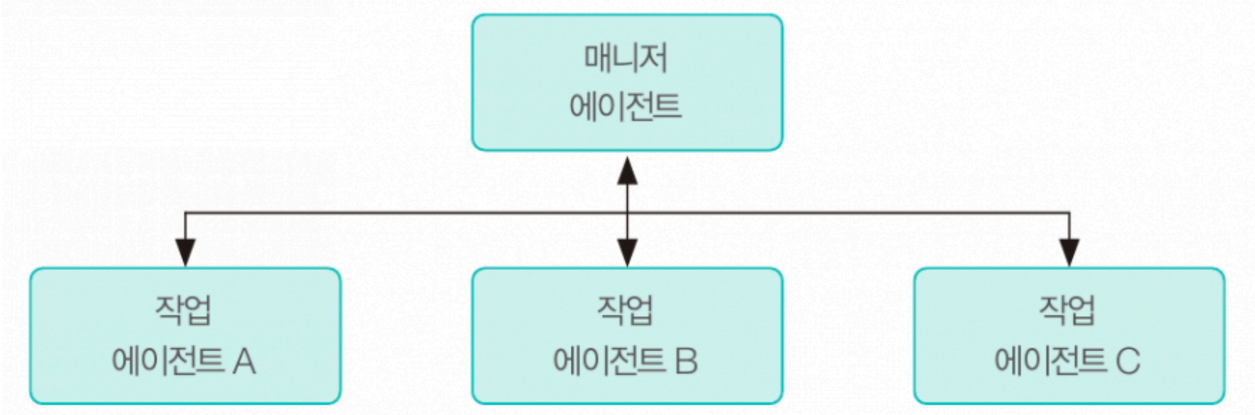


### 계층형 에이전트 + Hermes

HgFinance는 계층형 에이전트 구조로 이루어졌으며,
CEO 에이전트로부터 하위 에이전트에게 임무가 전달되고
마지막에 종합되어 각각 전문 에이전트의 내용이 사용자에게 전달되는 구조
**비동기 파이프라인으로 속도가 단일로 처리했을 때 보다 빠름**

https://www.hanbit.co.kr/channel/view.html?cmscode=CMS5884823375

# 부록 2 멀티 에이전트의 목적

LLM이 서로 대화하게 만드는 것이 아닌, 장기 실행·권한 분리·독립 검증이 필요한 업무만 분리

- 멀티 에이전트: 서로 독립 검토가 필요한 분석·리스크·QA에만 사용
- LLM은 자연어를 해석하고 근거를 설명하는 역할
- 결정론 코드: 주문 조건 검증, 리스크 한도, 상태 전이, 주문·원장 처리
    - 결정론 실행 계층: Worker, State Machine, OMS, Ledger

| 업무 단계 | 담당 | 분리 이유 |
|---|---|---|
| 자연어 조건 해석 | CEO / LLM | 사용자의 비정형 문장을 종목·조건·수량이 담긴 주문 후보로 구조화 |
| 주문 조건·수량 검증 | Parser + Rule Engine | 문법 오류, 비논리 조건, 한도 초과를 재현 가능하게 차단 |
| 장중 조건 감시 | Conditional Worker + State Machine | 장시간 상태 유지, 조건 충족 감지, 재시작·중복 실행 방지 |
| PAPER 주문·체결·원장 | OMS + Ledger | 권한, 멱등성, 체결 상태, 감사 이력을 LLM과 분리 |
| 분석 근거·실패 검토 | Research / Risk / QA | 실행 주체와 검증 주체를 분리해 독립적 검토 수행 |

# 부록 3 ReAct Prompting

## CEO ReAct

| 지표 | 의미 |
|---|---|
| **Routing exact match** | 필요한 부서를 정확히 선택했는가 |
| **Delegation completeness** | 필요한 부서가 모두 호출됐는가 |
| **Missing-result honesty** | 부서 결과가 없을 때 추측하지 않았는가 |
| **Parallel delegation ratio** | 독립 작업을 병렬로 보냈는가 |
| **Synthesis support rate** | 최종 주장마다 부서 근거가 있는가 |
| **Unauthorized action rate** | CEO 권한 밖 행동을 시도하지 않았는가 |

## QA ReAct

| 지표 | 의미 |
|---|---|
| **Finding recall** | 실제 문제를 놓치지 않았는가 |
| **False-pass rate** | 실패를 PASS로 잘못 통과시키지 않았는가 |
| **Deterministic fidelity** | 결정론 QA Engine 결과를 정확히 설명했는가 |
| **Escalation accuracy** | 올바른 담당자와 심각도로 올렸는가 |
| **Tool compliance** | 허용되지 않은 Tool을 호출하지 않았는가 |
| **Review completeness** | 증거·모순·권한·재현성 검토가 빠짐없이 되었는가 |

## Research ReAct

| 지표 | 의미 |
|---|---|
| **Evidence completeness** | 필요한 근거를 빠짐없이 찾았는가 |
| **Citation precision** | 인용이 실제 주장을 뒷받침하는가 |
| **PIT/timestamp accuracy** | 게시·관측 시점을 올바르게 확인했는가 |
| **Search efficiency** | 중복 검색과 불필요한 호출이 줄었는가 |
| **Recovery rate** | stale/conflict/실패 Tool에서 회복했는가 |
| **Final contract pass rate** | 요구된 보고 형식을 지켰는가 |

## Baseline vs ReAct

| Supervisor | Baseline (Case Pass) | ReAct (Case Pass) | Delta (%p) | 지연 |
|---|---|---|---|---|
| **Research HQ** | 100.00% | 88.89% | -11.11%p | 19.35초 → 18.22초 |
| **QA/Audit** | 44.44% | 77.78% | +33.34%p | 11.35초 → 10.7초 |
| **CEO** | 44.44% | 88.89% | +44.45%p | 9.46초 → 12.71초 |

## Baseline vs ReAct

| Supervisor | 승 (Wins) | 무승부 (Ties) | 패 (Losses) | 종합 평가 |
|---|---|---|---|---|
| **Research HQ** | 0 | 16 | 2 | ReAct 도입 시 오히려 성능 저하 발생 |
| **QA/Audit** | 6 | 12 | 0 | ReAct 도입으로 증거 처리력 대폭 향상 |
| **CEO** | 8 | 10 | 0 | ReAct 도입으로 의사 결정 및 케이스 통과율 대폭 향상 |

**추론이나 근거를 수집해야하는 부서에 ReAct Prompting 적용 A/B 테스트 결과**

성능 차이가 크게 났던 CEO부서에게 ReAct Prompting 적용

# 부록 3 ReAct Prompting

## CEO ReAct

| 지표 | 의미 | Baseline | ReAct |
|---|---|---|---|
| **Routing exact match** | 필요한 부서를 정확히 선택했는가 | 12(12) | 12(12) |
| **Delegation completeness** | 필요한 부서가 모두 호출됐는가 | 12(12) | 12(12) |
| **Missing-result honesty** | 부서 결과가 없을 때 추측하지 않았는가 | 8(12) | **11(12)** |
| **Parallel delegation ratio** | 독립 작업을 병렬로 보냈는가 | 6(6) | 6(6) |
| **Synthesis support rate** | 최종 주장마다 부서 근거가 있는가 | N/A | N/A |
| **Unauthorized action compliance** | CEO 권한 밖 행동을 시도하지 않았는가 | 18(18) | 18(18) |

**부서 결과가 없을 때 추측하지 않았는가에 대한 ReAct 지표가 향상됨. 지연은 조금 늘었지만 성능 향상이 좋아 도입 고려**

## QA ReAct

| 지표 | 의미 | Baseline | ReAct |
|---|---|---|---|
| **Finding recall** | 실제 문제를 놓치지 않았는가 | 15(15) | 15(15) |
| **False-pass rate** | 실패를 PASS로 잘못 통과시키지 않았는가 | 0(15) | 0(15) |
| **Deterministic fidelity** | 결정론 QA Engine 결과를 정확히 설명했는가 | 9(9) | 9(9) |
| **Escalation accuracy** | 올바른 담당자와 심각도로 올렸는가 | 12(15) | 12(15) |
| **Tool compliance** | 허용되지 않은 Tool을 호출하지 않았는가 | 18(18) | 18(18) |
| **Review completeness** | 증거·모순·권한·재현성 검토가 빠짐없이 되었는가 | 18(18) | 18(18) |

**QA 부서의 케이스 통과율은 증가했지만 ReAct Prompting는 독립 통제지표 개선과 비용 대비 효과가 불충분해 운영 적용 보류**

## Research ReAct

| 지표 | 의미 | Baseline | ReAct |
|---|---|---|---|
| **Evidence completeness** | 필요한 근거를 빠짐없이 찾았는가 | 18(18) | 18(18) |
| **Citation precision** | 인용이 실제 주장을 뒷받침하는가 | 18(18) | 18(18) |
| **PIT/timestamp accuracy** | 게시·관측 시점을 올바르게 확인했는가 | 6(6) | 6(6) |
| **Search efficiency** | 중복 검색과 불필요한 호출이 줄었는가 | 9(9) | 9(9) |
| **Recovery rate** | stale/conflict/실패 Tool에서 회복했는가 | 9(9) | 9(9) |
| **Final contract pass rate** | 요구된 보고 형식을 지켰는가 | 18(18) | **16(18)** |

**점수가 오히려 하락됨. 도입 폐기**

# 부록 4 기존 에이전트 사례 - 나스닥 바이럴 탐색

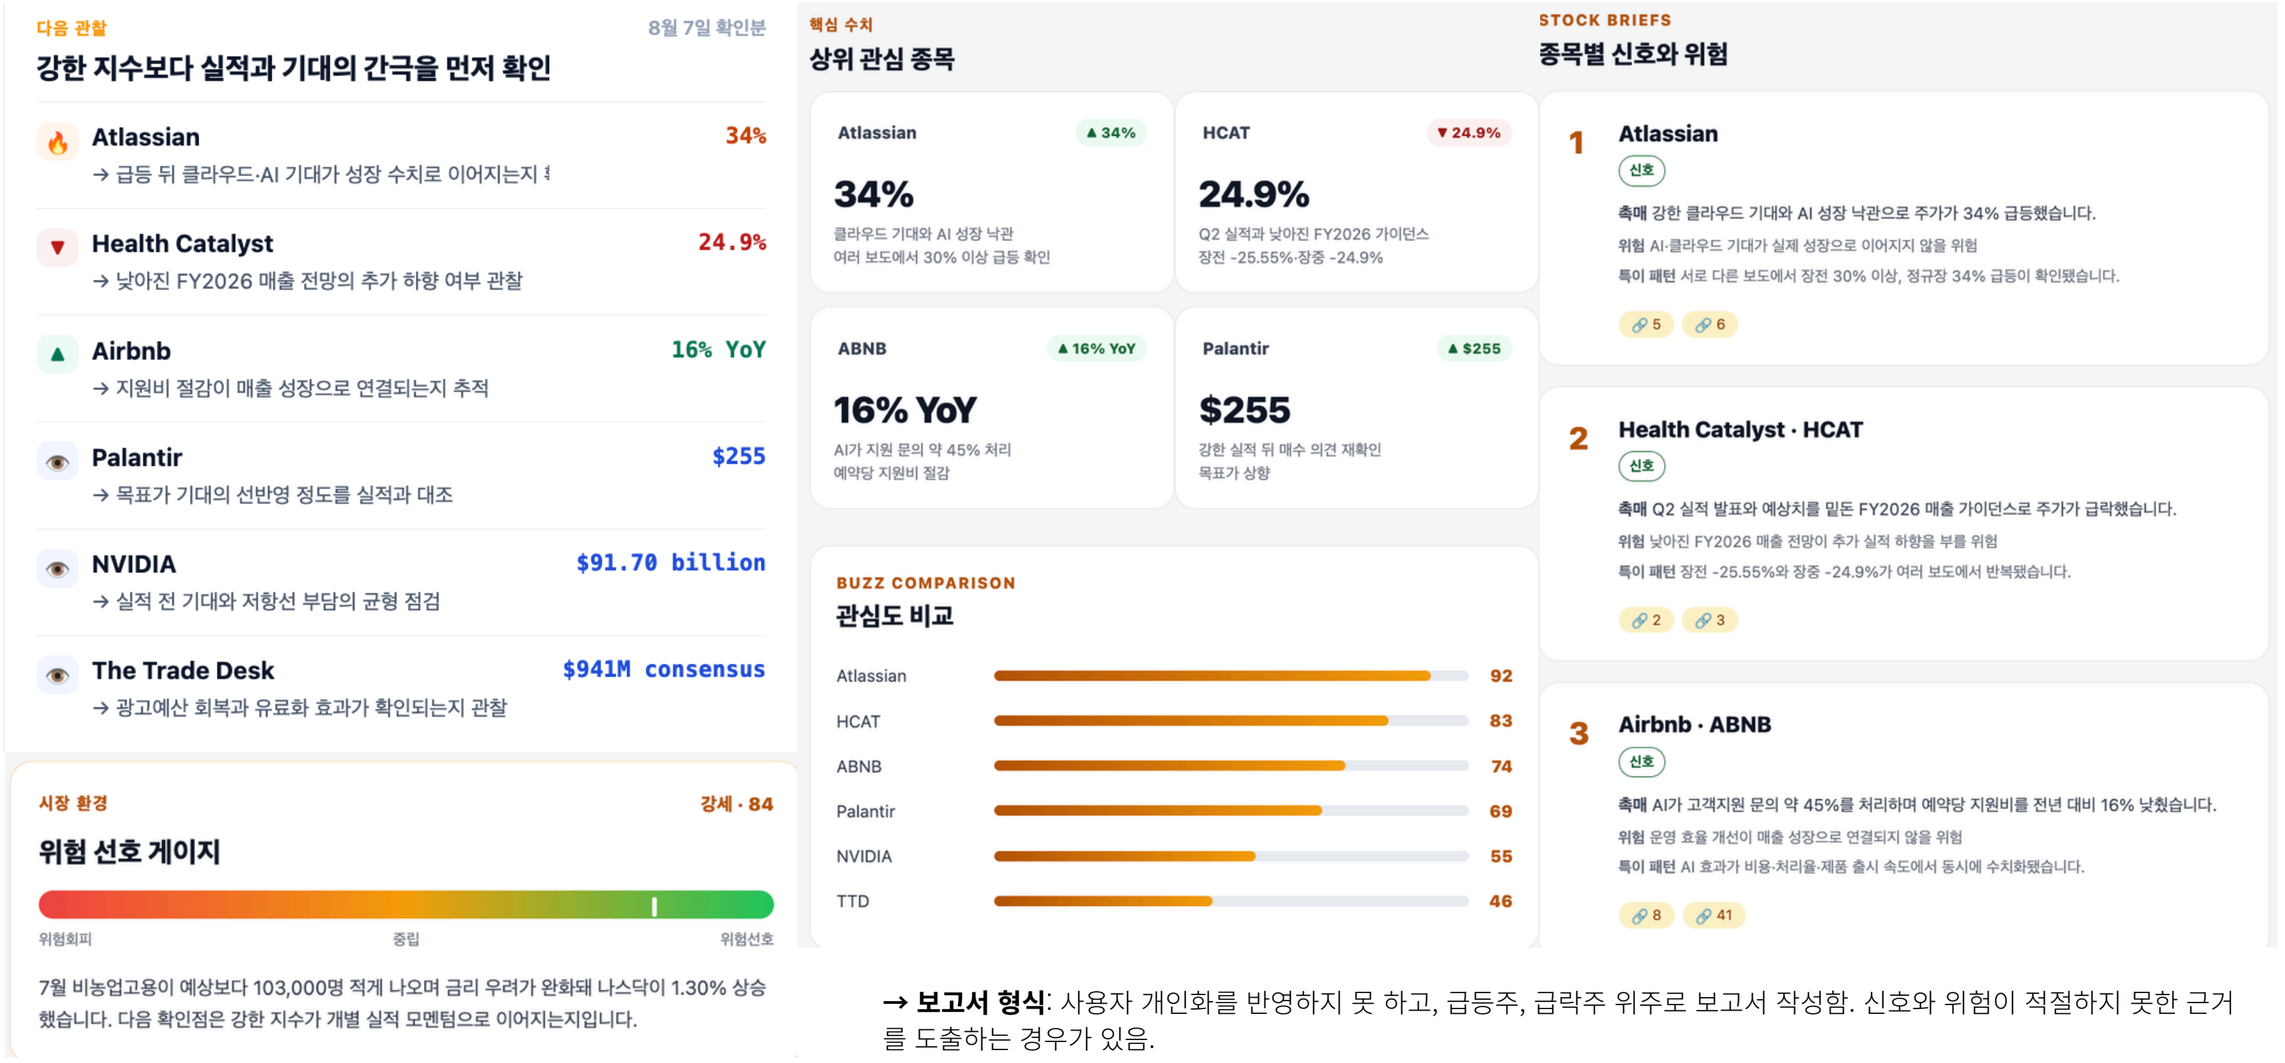


→ **보고서 형식**: 사용자 개인화를 반영하지 못 하고, 급등주, 급락주 위주로 보고서 작성함. 신호와 위험이 적절하지 못한 근거를 도출하는 경우가 있음.

https://somodus.com/store/agent/6a6d3ce70c842261780bf91e?utm_source=somodus_worker&utm_medium=artifact_hook&utm_content=nasdaq_buzz_roundtable

# 부록 4 기존 에이전트 사례 - TradingAgent

## 5단계 에이전트 워크플로우 및 조직 구조

| 단계 | 팀 / 담당자 | 세부 역할 및 핵심 과업 |
|---|---|---|
| I | **애널리스트팀** | 4개 분야 데이터 동시 수집 및 분석 (펀더멘털, 센티먼트, 뉴스, 테크니컬) |
| II | **리서치팀** | 강세(Bull) vs 약세(Bear) n라운드 토론 진행 후 진행자(Facilitator)가 승자 관점 채택 및 기록 |
| III | **트레이더** | 분석 보고서와 토론 결과를 종합하여 매수/매도/보유 신호 생성 및 근거 보고서 작성 |
| IV | **리스크관리팀** | 공격형(Risky) / 중립형(Neutral) / 보수형(Safe) 3가지 성향 관점에서 트레이더 결정 재검토 |
| V | **펀드매니저** | 리스크 토론 결과를 종합 검토하여 최종 거래 승인, 조정 및 실행 |

## 사용 툴

| 구분 | 사용 툴 / 기술 |
|---|---|
| **핵심 오케스트레이션** | **LangGraph** |
| **에이전트 패턴** | **ReAct** |
| **통신 프로토콜** | **MetaGPT 패턴** |
| **모니터링 / 트레이싱** | **LangSmith** |

## 애널리스트팀 세부 구성 (4명 동시 가동)

| 역할 | 분석 대상 및 담당 업무 |
|---|---|
| **펀더멘털 애널리스트** | 재무제표, 실적, 내부자 거래 분석 → 기업 내재가치 평가 |
| **센티먼트 애널리스트** | 소셜 미디어(Reddit, X 등) 감성 점수 측정 및 분석 |
| **뉴스 애널리스트** | 거시경제 지표, 정부 발표, 글로벌 이벤트 모니터링 |
| **테크니컬 애널리스트** | MACD, RSI 등 60개 기술적 지표 계산 및 차트 분석 |

## 모델 운용 전략 및 작동 메커니즘

| 구분 | 적용 모델 / 방식 | 담당 작업 및 특징 |
|---|---|---|
| **가벼운 작업** | gpt-4o-mini, gpt-4o | 요약, 데이터 조회 등 빠른 처리가 필요한 작업 |
| **무거운 작업** | o1-preview (추론 모델) | 심층 분석, 토론, 최종 의사결정 등 복잡한 논리 구현 |
| **작동 메커니즘** | **ReAct 프롬프팅** | 모든 에이전트에 동일 적용 (Reasoning + Acting) |

논문: Xiao, Y., Sun, E., Luo, D., & Wang, W. (2025). TradingAgents: Multi-Agents LLM Financial Trading Framework. arXiv:2412.20138 — https://arxiv.org/abs/2412.20138

# 부록 5 ML 최적화 지표 비교

| 핵심 지표 | FP8 16K / 0.90 | FP8 8K / 0.85 | FP8 4K / 0.85 |
|---|---|---|---|
| **FULL CUDA Graph** | 73% / OOM | **100%** | **100%** |
| **API 안정성** | 불안정/reset | **6/6 HTTP 200** | **6/6 HTTP 200** |
| **VRAM 사용률** | ~98.1% | **~95.9%** | **~95.9%** |
| **Long-request concurrency** | 1.84x @16K | 2.20x @8K | **20.91x @4K** |

→ **안정성 및 Concurrency 극대화**: 초기 OOM 및 서버 다운 불안정성(CUDA Graph 73%)을 완전히 해소하여, API 성공률 100%를 달성하였으며, 동시 수용 한도(Concurrency)를 1.84배에서 20.91배로 약 11.3배 확장했습니다.

| 지표 | FP8 8K / 0.85 | AWQ 8K / 0.85 | FP8 4K / 0.85 |
|---|---|---|---|
| **Model Load Memory** | 16.43 GiB | **10.42 GiB** | 10.70 GiB |
| **KV Cache** | 1.65 GiB | 6.57 GiB | **7.84 GiB** |
| **KV Tokens** | 18,032 | 71,760 | **85,664** |
| **8K Concurrency** | 2.20x | 8.76x | **20.91x** |

→ **VRAM 재할당 및 효율화**: FP8에서 AWQ(W4A16) 양자화를 적용해 가중치를 경량화하고, 확보된 공간을 KV Cache로 전환했습니다. 모델 무게를 16.43 GiB에서 10.70 GiB로 다이어트하여 남은 VRAM을 KV Cache(1.65 GiB $\rightarrow$ 7.84 GiB)로 재할당함으로써 유저 처리용 토큰 용량을 18,032개에서 85,664개로 대폭 늘렸습니다.

| 핵심 지표 | FP8 | AWQ | 의미 |
|---|---|---|---|
| **E2E C1** | 17.23s | **9.32s** | 사용자 체감 전체 응답시간, **AWQ -45.9%** |
| **C1 Throughput** | 14.86 | **27.46 tok/s** | 단일/낮은 동시성 생성속도, **+84.8%** |
| **C4 Throughput** | 59.39 | **111.16 tok/s** | 높은 동시성 처리성능, **+87.2%** |

→ **속도 및 처리량 대폭 상승**: AWQ 양자화 도입을 통해 GPU 연산 병목 및 메모리 대역폭 점유를 최적화했습니다. 유저 체감 대기시간(E2E Latency)을 45.9% 단축(17.23초 => 9.32초)시키고, 다중 요청 환경(C4 Throughput)에서의 초당 토큰 생성 속도를 87.2% 향상(59.39 => 111.16 tok/s)시켰습니다.

# 부록 6 Qwen2.5-14B 사용 데이터셋 소개

## FineTuning 데이터셋

| 산술 전문 데이터 | 학습 | 검증 |
|---|---|---|
| FinQA (산술 선별) | 700 | 100 |
| HgFinance synthetic 산술 | 126 | 12 |
| **합계** | **826** | **112** |

### Fin QA 문제 예시

| 입력 (조건 및 질문) | 최종 답 |
|---|---|
| 2022년 매출은 1,200이고 2021년 매출은 1,000이다. 2022년 매출은 전년 대비 몇 퍼센트 증가했는가? | 0.2 또는 20% |
| 매출은 500억 원이고 영업이익은 75억 원이다. 영업이익률은 얼마인가? | 0.15 또는 15% |
| A사의 매출은 800이고 비용은 500이다. 전년 매출은 700이었다. 올해 이익의 전년 매출 대비 비율은 얼마인가? | 약 0.4286 또는 42.86% |

## RAG 데이터셋

「경제금융용어 800선」 2026년판

### 예시

**가계순저축률**

일반적으로 저축률은 저축액을 처분가능소득으로 나눈 비율을 말한다. 마찬가지로 가계순저축률은 가계부문의 순저축액을 가계순처분가능소득과 정부로부터 받은 사회적 현물이전 금액, 연금기금의 가계순지분 증감조정액을 합계한 금액으로 나눈 비율이다. 여기서 사회적 현물이전(Social Transfer in Kind)이란 정부 등이 가계에 현물이전의 형태로 제공하는 재화 및 서비스로서 무상교육, 보건소의 무상진료 등이 해당된다. 또한 연금기금의 가계순지분 증감조정액을 분모에 더하는 이유는 퇴직연금 등과 같이 가계가 납부한 연금부담금과 연금수취액의 차액을 반영해야 가계부문의 저축액을 정확히 구할 수 있기 때문이다. 가계순저축률은 가계부문의 저축성향을 가장 잘 나타내주는 지표라고 할 수 있다.

가계순저축률(%) = {가계부문 순저축 / (가계순처분가능소득 + 사회적현물이전수취 + 연금기금의 가계순지분 증감조정)} × 100

연관검색어 가계처분가능소득, 저축률

**가계처분가능소득**

가계처분가능소득(PDI; Personal Disposable Income)은 가계가 마음대로 소비와 저축으로 처분할 수 있는 소득을 의미한다. 흔히 국민의 생활 수준을 파악해 볼 수 있는 지표로 1인당 국민총소득(GNI)이 널리 쓰이고 있으나 GNI에는 가계뿐 아니라 기업, 금융회사와 정부가 벌어들인 소득이 모두 포함되어 있다. 따라서 기업과 금융회사 등이 가계 부문보다 더 많은 소득을 벌어 1인당 GNI가 높아진 경우에는 가계가 느끼는 체감경기는 전체 경기와 괴리가 있게 된다. 1인당 가계총처분가능소득(PGDI; Personal Gross Disposable Income)은 가계부문의 총처분가능소득을 연앙인구로 나누어 계산한 지표로 가계의 구매력을 가장 정확히 가늠해 볼 수 있는 소득지표이다.

FinQA: https://finqasite.github.io/
경제 금융 용어 800선 : https://www.bok.or.kr/portal/bbs/B0000249/view.do?menuNo=200765&nttId=10096081

# 부록 7 FP8 vs AWQ 양자화 비교 지표

## 내부 (Internal) 지표

| 내부 지표 | FP8 | AWQ |
|---|---|---|
| **Quality Pass Rate** | 70.00% | **72.00%** |
| **Relative Quality Delta** | 기준 | **2.86%** |
| **Quant** | 83.30% | **100%** |
| **Evidence** | 83.30% | **100%** |
| **Financial Arithmetic** | **30.00%** | 20.00% |

- 전체 Quality : **70%→72%**로 유지·개선
- Quant/Evidence : **83.3%→100%**로 개선
- Financial Arithmetic : **30%→20%**로 하락

## 외부 (External) 지표

| 외부 지표 | FP8 | AWQ |
|---|---|---|
| **FinQA** | **75.00%** | 65.00% |
| **TAT-QA** | **100.00%** | 93.30% |
| **FinanceBench diagnostic** | 58.74% | **58.95%** |
| **Auto Mean** | **0.8556** | 0.7709 |

- FinQA: 75% → 65%로 하락
- TAT-QA: 100% → 93.3%로 소폭 하락
- FinanceBench: 58.74% → 58.95%로 유지
- Auto Mean: 0.8556 → 0.7709로 FP8 우세

# 부록 7 개선된 문항

**Financial Arithmetic — AWQ+Finetune (40% / AWQ 20%)**

| ID | 문제 내용 | 기대값 | AWQ → Finetune |
|---|---|---|---|
| v2-001 | 매출 2,500 million KRW, 매출원가 1,750 million KRW일 때 gross margin percentage 계산 | 30.00% | 45 → 30% |
| v2-006 | 순이익 36 billion KRW와 가중평균 발행주식 120 million주로 EPS를 KRW/주 단위 계산 | 300 | 300,000 → 300 |

**Accounting — AWQ+RAG (83.3% / AWQ 66.7%)**

| ID | 문제 내용 | 기대값 | AWQ → AWQ+RAG |
|---|---|---|---|
| v2-014 | 100주에 대한 주당 배당금 500 KRW에서 원천징수세 7,700 KRW를 차감한 순배당 현금 수취액 계산 | 42,300 KRW | 4,230 → 42,300 |

**FinQA — AWQ+Finetune (75% / AWQ 65%)**

| ID | 문제 내용 | 기대값 | AWQ → AWQ+Finetune |
|---|---|---|---|
| finqa:C/2008/page_44.pdf-2 | 2007년 대비 2008년 non-interest revenue의 percentage change 계산 | 2.50515 | -250.69% → 251% |
| finqa:MRO/2003/page_45.pdf-2 | 365, 346, 345로 주어진 3개년 distillates sales의 합계를 million 단위로 계산 | 1,056.00 | 연도별 잘못된 환산값 → 1,056 |

**FinQA — AWQ+RAG(80% / AWQ 65%)**

| ID | 문제 내용 | 기대값 | AWQ → AWQ+RAG |
|---|---|---|---|
| finqa:C/2008/page_44.pdf-2 | 2007년 대비 2008년 non-interest revenue의 percentage change 계산 | 2.50515 | -250.69% → 약 250.52% |
| finqa:HWM/2018/page_96.pdf-2 | 2016년과 2017년 stock options의 평균행사가격을 반영한 total value 증가액 계산 | 16.43 million USD | 17.43 → 16.43 |
| finqa:IP/2009/page_45.pdf-1 | 2011년 만기의 전체 contractual obligations 중 long-term debt maturity 비율 계산 | 0.40796 (약 40.8%) | 1.99% → 40.8% |

# 부록 8 HR - 계측 지표 종류

HR 부서장 에이전트가 6개 본부 성능 지표를 검토하여 개정 대상 프로필 선별

## 지표 종류

Langfuse(원격 관측) / DB(운영 스키마) / 함수(결정론 산출)

| 그룹 | 계측 지표 | 출처 |
|---|---|---|
| 직원 현황 | 재직 상태 · 프로필 버전 · 도구 권한 · 활성화 근거 검증 · 상태 전이 이력 · 권한 수명주기 | DB · 함수 |
| 성과 및 효율성 | 유휴 판정 · 처리량과 지연 · 토큰 사용량 · 발화율 · 비용 · 예산 판정 · 품질 | Langfuse · DB · 함수 |
| 조직 구성 및 개선 | 인력 계획 · 채용 요청 · 개선 후보 · 성과 평가 · 성과 조치 · 수습 기간 | DB · 함수 |

## 주요 지표

| 지표 | 계측 방식 |
|---|---|
| 비용 | 부서장 에이전트: gpt-5.6-luna codex 구독 (토큰당 청구서가 존재하지 않아 임의로 월 구독료 ÷ 월 관측 토큰)<br>직원 LLM worker: 온디맨드 Qwen 모델 사용 (0$) |
| 지연 | 부서 단위 분포로만 집계, 워커 간 순위는 내지 않음<br>담당 작업이 달라 정상 지연 폭이 worker별로 상이 |
| 유휴 | 4시간 넘게 실행 흔적이 없으면 유휴로 판정<br>미호출·조건부 호출·누락 구분 |
| 발화율 | 실행뿐 아니라 미실행 판정도 이벤트로 발행<br>실행 기준 조건부 워커는 항상 100% |

# 부록 8 HR - 계측 지표 LLM 전달 방식

HR 부서장 에이전트가 지표를 취합하는 과정에서,
① 부서별 6회 수신 후 4단 중첩 JSON을 수동 병합해야 하는 문제
② 토큰이 8,000자 한도를 초과하여 수치가 누락되는 문제

## 평탄화 및 렌더링

- 중첩 JSON → 부서(행) × 지표(열) 2차원 표로 전개 (처리량 6 + 비용 7 + 품질 3, 총 16개 지표)
- 마크다운 표 5종으로 분할 — 처리량·지연 / 비용 / 품질 / 참조 / 예산 판정
- 목록형 값은 셀에 넣지 않고 한 줄에 하나씩 참조 표로 분리

| 예상 결함 | 대응 방안 |
|---|---|
| 기밀 유출 | 권한 경계에 따라 원문 내용 미조회, 허용 목록 metadata만 열람 |
| 판정 왜곡 | 임계값을 프롬프트 밖 결정론 함수에 고정, 렌더러는 결과만 운반 |
| 결측 오독 | — 필드 미집계 / 0 실제 값 / NO_SNAPSHOT 스냅샷 없음 의미를 구분하여 표기 |
| 토큰 초과 | 반복 key 제거로 8,000자 제한 하에 수치값 보존 |

- ICA(Intent–Context–Action) — 복잡한 워크플로우 데이터를 서술형 대신 정형 구조로 재구성 시 LLM 이해도 향상 (Su et al., 2025, LLM-Friendly Knowledge Representation, arXiv:2510.10331)
- TOON(Token-Oriented Object Notation) / CSV·마크다운 표 — 속성명을 상단에 1회 선언하고 값만 나열, 구조적 기호에 주의력이 분산되지 않도록 함
- ADP(Agent Data Protocol) — 툴·에이전트 간 파편화된 로그 대신 공통 경량 표현으로 평가·추론 정확도 확보

# 부록 8 HR - Langfuse 모니터링

## Langfuse 트레이스

- Span: 일반적인 작업 (예: 데이터베이스 쿼리, 함수 실행)
- Generation: LLM API 호출 (입력, 출력, 모델, 토큰 수 포함)
- Event: 특정 시점의 이벤트 (로그, 메트릭)

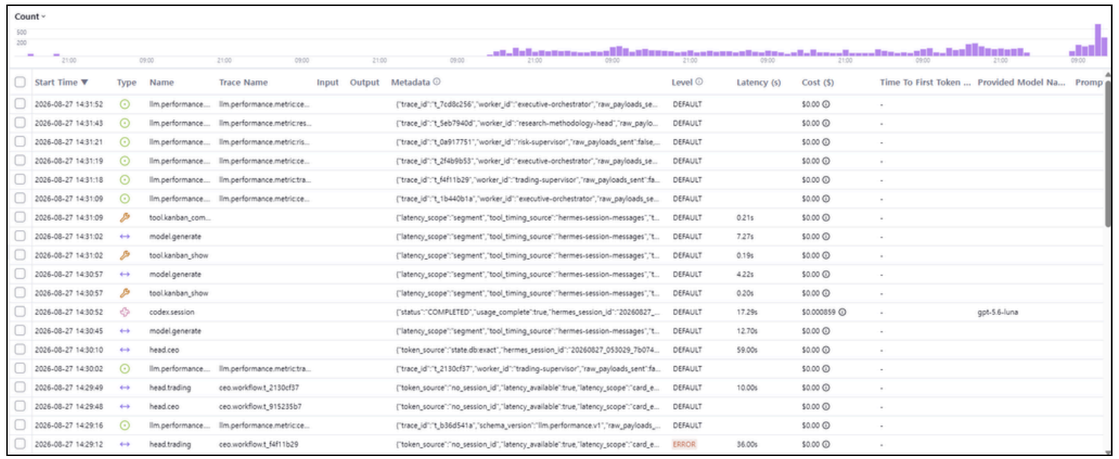


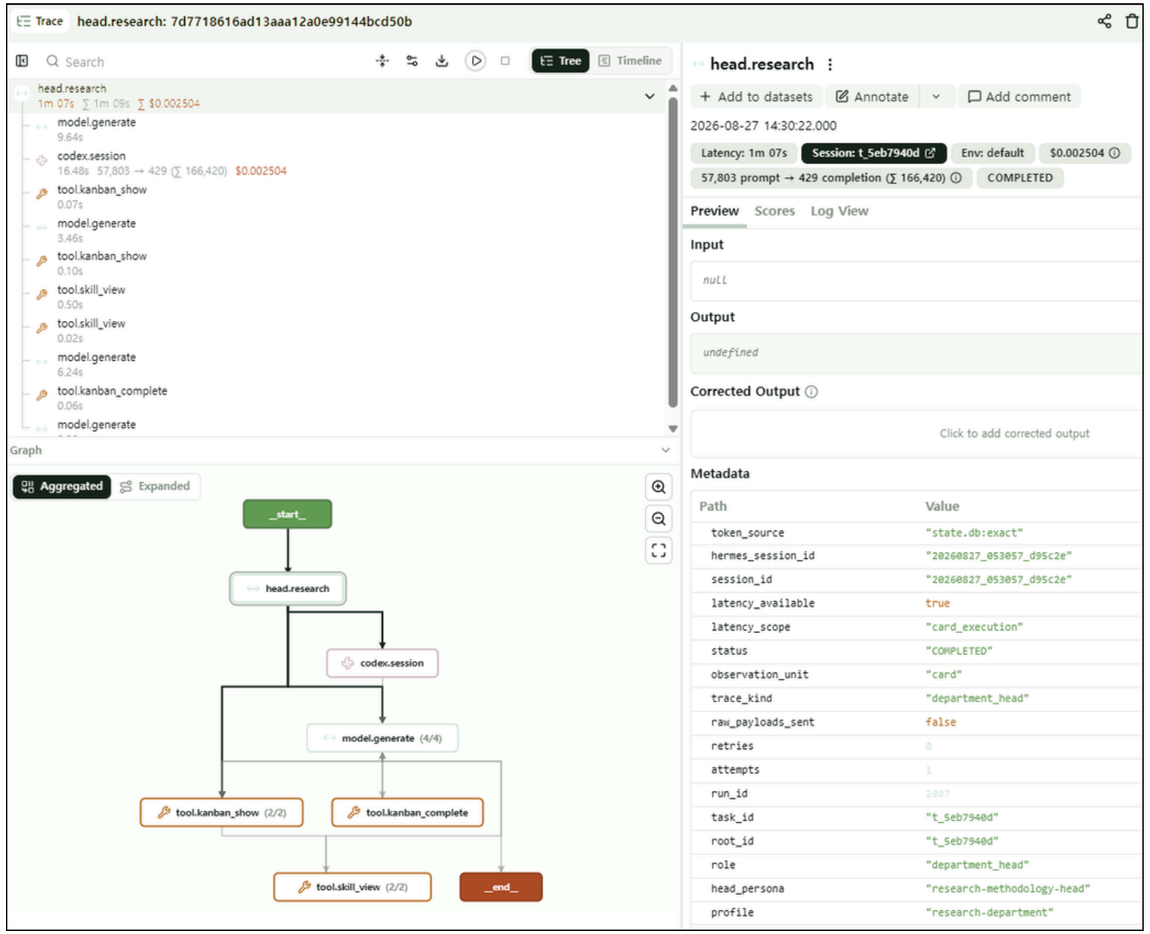

# 부록 9 자연어 조건주문 유형별 Stress Test

| 단계 | 테스트 유형 | **자연어 조건주문** |
|---|---|---|
| 1 | 복합 기술지표 | “삼성전자 60분봉 20이평을 상향 돌파하고 RSI(14)가 50 이상, 거래량이 20봉 평균의 1.5배 이상이면 10주 매수” |
| 2 | 복합 논리 AND/OR | “삼성전자 볼린저밴드 상단 돌파 + RSI 70 이상 또는 거래량 2배 이상이면 보유 수량 50% 매도” |
| 3 | 멀티 타임프레임 | “삼성전자 일봉이 20일 이평 위에 있을 때, 5분봉 RSI가 30을 재돌파하면 5주 매수” |
| 4 | 포트폴리오 연계 | “삼성전자 수익률 10% 이상 + 포트폴리오 비중 20% 초과 + 15분봉 20이평 하향 돌파 시 초과 비중 매도” |
| 5 | 동적 주문수량 | “삼성전자 MACD 골든크로스 발생 시 가용 현금의 10%를 매수하되, 최대 주문금액은 100만원으로 제한” |
| 6 | 순차 조건 / Temporal | “삼성전자 RSI가 30 하회한 이후 20봉 이내 20이평을 상향 돌파하면 5주 매수, 그 전에 RSI 70 돌파 시 조건 취소” |
| 7 | 상태 기억 / Trailing | “삼성전자 수익률이 15%를 넘은 이후 최고 수익률을 추적하고, 최고점 대비 5%p 하락하면 보유 수량 50% 매도” |
| 8 | 시장상태 연계 | “KOSPI가 60일 이평 위에 있을 때만 삼성전자 신고가 돌파 매수를 허용하고, KOSPI 장중 -2% 급락 시 조건 취소” |
| 9 | 다단계 분할청산 | “삼성전자 매수 후 +5%에서 30%, +8%에서 추가 30% 익절하고, 잔여 40%는 20이평 하향 돌파 시 전량 매도” |
| 10 | Trading State Machine | “삼성전자 상승 추세에서 RSI 반전 + 거래량 증가 시 매수 →<br>-3% 손절 → +5% 절반 익절 → 잔여 물량은 고점 대비 -3% 또는 20이평 이탈 시 전량 매도” |